

Manuscrit de thèse en vue de l'obtention du diplôme de doctorat

Thèse CIFRE issue d'un partenariat entre :

l'école CentraleSupélec
l'université Paris Diderot
SAFRAN

Représentations pour la détection d'anomalies
Application aux données vibratoires des moteurs d'avions

Mina ABDEL-SAYED

11 mars 2018

Table des matières

Table des matières	VI
Résumé	1
Abstract	1
Introduction	3
Le contexte industriel	3
Problématique	4
Les approches préconisées	6
Contributions	8
Structure du mémoire	8
I L'analyse vibratoire et détection de nouveautés	9
1 L'analyse et les données vibratoires	13
1.1 Introduction	13
1.2 Les moteurs d'avions	13
1.2.1 Les caractéristiques des moteurs	13
1.2.2 Les vibrations du moteur	15
1.2.3 L'acquisition des mesures vibratoires et des vitesses de rotation	16
1.3 Conversion des signaux temporels en spectrogrammes	16
1.3.1 Intérêt de cette conversion	16
1.3.2 La transformation du signal temporel en spectrogramme	18
1.3.3 Gains et limites de cette représentation	19
1.4 Construction de la base de données	21
1.4.1 L'annotation manuelle des experts	21
1.4.2 Extraction automatique des zones anormales sur les données textuelles .	23
1.4.3 La base de données enrichie	24
1.5 Étude des spectrogrammes par patch	25
1.5.1 Localisation des signatures inusuelles sur le spectrogramme	25
1.5.2 Subdivision du spectrogramme en patchs	26
1.5.3 Labélisation ponctuelle du patch - enrichissement de la base de données .	29
1.5.4 La grande variabilité des signatures inusuelles	30
1.6 L'état de l'art de l'analyse vibratoire	31
1.6.1 L'état de l'art provenant de la littérature	31
1.6.2 Les algorithmes d'analyse vibratoire de Safran Aircraft Engines	34
1.7 Une première approche de détection	36
1.7.1 Représentation des patchs par leurs histogrammes d'intensités vibratoires	37
1.7.2 Représentation des histogrammes dans un espace réduit	39
1.8 Conclusions	39

2 La détection de nouveautés	41
2.1 Définition	41
2.2 État de l'art de la détection de nouveautés	42
2.2.1 Les approches probabilistes	43
2.2.2 Les approches basées sur les distances	44
2.2.3 Les approches basées sur la reconstruction des données	44
2.2.4 Les approches basées sur la caractérisation des limites des données normales	45
2.2.5 Les approches basées sur la théorie de l'information	46
2.3 La détection de nouveautés appliquée aux données vibratoires	46
2.3.1 Application aux données temporelles et fréquentielles	46
2.3.2 Application sur les harmoniques du signal	47
2.3.3 Application aux spectrogrammes	48
2.4 Caractérisation de la base de données construite	49
2.4.1 Répartition des données en sous-ensembles	49
2.4.2 Visualisation des résultats	51
II Les approches de représentation globale par dictionnaire	53
3 Représentation par dictionnaire fixe - les curvelets	57
3.1 Introduction	57
3.1.1 La représentation par dictionnaire	57
3.1.2 Les dictionnaires non-adaptatifs	59
3.2 La transformée en curvelet	60
3.2.1 La transformée en ridgelet	60
3.2.2 Les ridgelets multi-échelles	61
3.2.3 La construction de la transformée en curvelet	62
3.2.4 Le dictionnaire des curvelets	64
3.3 Application des curvelets aux spectrogrammes vibratoires	64
3.3.1 Caractérisation des raies vibratoires à partir des curvelets	64
3.3.2 Comparaison des représentations en curvelet	66
3.4 Normalité définie dans le dictionnaire des curvelets	68
3.4.1 Le modèle de normalité	68
3.4.2 Normalité définie par optimisation avec contraintes de parcimonie	72
3.4.3 Comparaison des supports normaux	73
3.5 Le score de détection d'anomalies sur le patch	75
3.5.1 Les scores de détection	75
3.5.2 Le score de normalité	76
3.5.3 Résultats sur la base de test	78
3.6 L'étude des résidus ponctuels	80
3.6.1 Les résidus du modèle de normalité $\mathcal{D}_{Supp^*}^C$	80
3.6.2 La détection d'anomalies	81
3.6.3 Calibration des paramètres des modèles sur Ω_{Val}	83
3.6.4 Résultats sur la base de test Ω_{Test}	89
3.7 Conclusions	93
4 Représentation par dictionnaire data-driven-NMF	95
4.1 Les dictionnaires adaptatifs/data-driven	95
4.1.1 Définition mathématique du problème	95
4.1.2 Les méthodes de résolution	96
4.1.3 Quelques exemples de dictionnaires data-driven (adaptatifs)	97
4.1.4 Les dictionnaires appris pour caractériser les spectrogrammes	98

4.2	Non-Negative Matrix Factorization (NMF)	99
4.2.1	Formulation mathématique	99
4.2.2	Résolution de la problématique	99
4.3	Le modèle de normalité défini à partir de la NMF	100
4.3.1	L'apprentissage du dictionnaire	100
4.3.2	Définition du rang du dictionnaire	101
4.3.3	Représentation de la normalité à partir du dictionnaire de la NMF	102
4.4	Détection d'anomalies sur les patchs	105
4.4.1	Les scores de détection	105
4.4.2	Résultats sur la base de test	108
4.5	Les erreurs ponctuelles issues du dictionnaire de la NMF	109
4.5.1	Les résidus de la NMF	109
4.5.2	La détection des points inusuels	110
4.5.3	Calibration des paramètres	112
4.5.4	Résultats sur la base de test Ω_{Test}	115
4.5.5	Complémentarité des approches adaptatives et non-adaptatives	116
4.6	Conclusions	119
III	Analyse ponctuelle des spectrogrammes	121
5	Analyse ponctuelle indépendante	125
5.1	Introduction	125
5.1.1	Considération ponctuelle des points des spectrogrammes	125
5.1.2	La base de données	126
5.1.3	Les modèles de normalité	127
5.2	Modélisation paramétrique de la distribution de normalité	127
5.2.1	Le modèle de normalité	127
5.2.2	Le score de détection	128
5.2.3	Calibration des seuils de détection sur la base de validation Ω_{Val}	129
5.2.4	Résultats sur la base de test Ω_{Test}	130
5.3	Estimation non paramétrique de la densité par noyau	135
5.3.1	Formulation	135
5.3.2	L'estimation de la densité par noyau gamma	136
5.3.3	Estimation de l'échelle du noyau	137
5.4	Distribution de normalité estimée par les noyaux gaussiens	139
5.4.1	Le modèle de normalité	139
5.4.2	Le score de détection	140
5.4.3	Calibration des seuils	142
5.4.4	Résultats sur la base de test Ω_{Test}	143
5.5	Distribution de normalité estimée par les noyaux gamma	147
5.5.1	Le modèle de normalité	147
5.5.2	Le score de détection	148
5.5.3	Calibration des seuils de détection	150
5.5.4	Résultats sur la base de test Ω_{Test}	151
5.6	Conclusions	153
6	Analyse ponctuelle conditionnelle au voisinage	155
6.1	Considération des points voisins	155
6.1.1	Dépendance par rapport au voisinage des points	155
6.1.2	Modèle de normalité par rapport au voisinage	156
6.2	Estimation de densité conditionnelle par noyau	157

6.2.1	L'estimation de densité par noyau dans un cadre multidimensionnel	157
6.2.2	Calibration de la matrice d'échelle	158
6.2.3	L'estimation de la densité conditionnelle par noyau	159
6.3	Le modèle de normalité défini à partir du voisinage d'ordre 1	160
6.3.1	La structure du voisinage	160
6.3.2	Le modèle de normalité	161
6.3.3	Le score de détection	162
6.3.4	Calibration du modèle	165
6.3.5	Résultats sur la base de test Ω_{Test}	167
6.4	Normalité défini en fonction de la direction du voisinage	169
6.4.1	Le voisinage directionnel	169
6.4.2	Le modèle de normalité	170
6.4.3	Le score de détection	171
6.4.4	La caractérisation des signatures inusuelles	172
6.4.5	Calibration du seuil de détection	173
6.4.6	Résultats sur la base de test Ω_{Test}	173
6.5	Fusion des différentes approches	180
6.5.1	Comparaison des approches par dictionnaire et ponctuelles	180
6.5.2	Fusion des approches par dictionnaire et ponctuelles	180
6.6	Conclusions	184
Conclusions et perspectives		187
Conclusions		187
Perspectives		191
Bibliographie		193
Table des figures		200
Liste des tableaux		207
Annexes		209
A Les tests multiples		209

Liste des symboles

f	Fréquence
N_2	Régime de l'arbre haute pression du moteur
N_1	Régime de l'arbre basse pression du moteur
S^i	Spectrogramme vibratoire du moteur i
S_{f,N_2}^i	Intensité vibratoire à la fréquence f et au régime N_2 du moteur i
\mathcal{K}	Subdivision du spectrogramme en patchs
\mathcal{K}_j	Elément j de la subdivision \mathcal{K} du spectrogramme en patchs
$Z_{\mathcal{K}_j}^i$	Patch correspondant à la l'élément j de la subdivision \mathcal{K} extrait du spectrogramme i
$\hat{Z}_{\mathcal{K}_j}^i$	Estimation normale du patch correspondant à la l'élément j de la subdivision \mathcal{K} extrait du spectrogramme i
Ω_{App}^j	Base d'apprentissage du patch j de la subdivision \mathcal{K}
Ω_{Val}^j	Base de validation du patch j de la subdivision \mathcal{K}
Ω_{Test}^j	Base de test du patch j de la subdivision \mathcal{K}
Ω_{App}^{f,N_2}	Base d'apprentissage des points aux coordonnées (f, N_2)
Ω_{Val}^{f,N_2}	Base de validation des points aux coordonnées (f, N_2)
Ω_{Test}^{f,N_2}	Base de test des points aux coordonnées (f, N_2)
$Y_{Z_{\mathcal{K}_j}}^i$	Vérité terrain de la classe normale ou atypique pour le spectrogramme i du patch Z_j provenant de l'élément j de la subdivision \mathcal{K}
$\hat{Y}_{Z_{\mathcal{K}_j}}^i$	La classe normale ou atypique estimée pour le spectrogramme i du patch Z_j provenant de l'élément j de la subdivision \mathcal{K}
Y_{f,N_2}^i	Vérité terrain sur la classe normale ou atypique du point de coordonnées (f, N_2) pour le spectrogramme i
\tilde{Y}_{f,N_2}^i	La classe, normale ou atypique, estimée sans filtrage par voisinage du point de coordonnées (f, N_2) pour le spectrogramme i
\hat{Y}_{f,N_2}^i	La classe, normale ou atypique, estimée avec filtrage par voisinage du point de coordonnées (f, N_2) pour le spectrogramme i
\mathcal{V}_{f,N_2}	Voisinage du point de coordonnées (f, N_2)
\mathcal{V}_{f,N_2}^k	Voisinage du point de coordonnées (f, N_2) dans la direction k
\mathcal{D}^C	Dictionnaire des curvelets
\mathcal{D}^{NMF}	Dictionnaire de la NMF

$SuppZ_{\mathcal{K}_j}^i$	Atomes des curvelets activés pour le patch $Z_{\mathcal{K}_j}^i$
$Supp^*$	Atomes des curvelets activés pour un pourcentage des données d'un patch de la base d'apprentissage
$R(Z_{\mathcal{K}_j}^i)$	Résidus de reconstruction du patch $Z_{\mathcal{K}_j}^i$
$R^+(Z_{\mathcal{K}_j}^i)$	Résidus positifs de reconstruction du patch $Z_{\mathcal{K}_j}^i$
$R^-(Z_{\mathcal{K}_j}^i)$	Résidus négatifs de reconstruction du patch $Z_{\mathcal{K}_j}^i$
$\mathcal{N}(\mu, \sigma)$	Loi et densité gaussienne de paramètre (μ, σ)
f_X	densité de la variable aléatoire X
$f_{\mathcal{N}}$	Densité de la loi gaussienne
$F_{\mathcal{N}}$	Fonction de répartition de la loi gaussienne
$K^{\mathcal{N}}$	Noyau gaussien
K^{Γ}	Noyau gamma
h	Echelle du noyau en une dimension
H	Matrice d'échelle du noyau multidimensionnel
\mathcal{F}	Transformée de Fourier
$\mathbf{1}$	Fonction indicatrice
$\ x\ _0$	norme 0, $\ x\ _0 = \text{card}(i : x_i \neq 0)$ avec $x = (x_1, \dots, x_n)$
$\ x\ _1$	norme 1, $\ x\ _1 = \sum x_i $ avec $x = (x_1, \dots, x_n)$
$\ x\ _2$	norme 2, $\ x\ _2 = \sqrt{\sum x_i ^2}$ avec $x = (x_1, \dots, x_n)$

Résumé

Les mesures de vibrations sont l'une des données les plus pertinentes pour détecter des anomalies sur les moteurs. Les vibrations sont acquises sur banc d'essai en phase d'accélération et de décélération pour assurer la fiabilité du moteur à la sortie de la chaîne de production. Ces données temporelles sont converties en spectrogrammes pour permettre aux experts d'effectuer une analyse visuelle de ces données et de détecter les différentes signatures atypiques. Les sources vibratoires correspondent à des raies sur les spectrogrammes. Dans cette thèse, nous avons mis en place un outil d'aide à la décision automatique pour analyser les spectrogrammes et détecter tout type de signatures atypiques, ces signatures ne proviennent pas nécessairement d'un endommagement du moteur. En premier lieu, nous avons construit une base de données numérique de spectrogrammes annotés. Il est important de noter que les signatures inusuelles sont variables en forme, intensité et position et se trouvent dans un faible nombre de données. Par conséquent, pour détecter ces signatures, nous caractérisons les comportements normaux des spectrogrammes, de manière analogue aux méthodes de détection de nouveautés, en représentant les patchs des spectrogrammes sur des dictionnaires comme les curvelets et la Non-negative matrix factorization (NMF), ainsi qu'en estimant la distribution de chaque point du spectrogramme à partir de données normales dépendamment ou non de leur voisinage. La détection des points atypiques est réalisée par comparaison des données tests au modèle de normalité estimé sur des données d'apprentissage normales. La détection des points atypiques permet la détection des signatures inusuelles composées par ces points.

mots clés : apprentissage de dictionnaire, curvelets, estimation de densité par noyau, détection de nouveautés, détection d'anomalies, vibrations

Abstract

Vibration measurements are one of the most relevant data for detecting anomalies in engines. Vibrations are recorded on a test bench during acceleration and deceleration phases to ensure the reliability of every flight engine at the end of the production line. These temporal signals are converted into spectrograms for experts to perform visual analysis of these data and detect any unusual signature. Vibratory signatures correspond to lines on the spectrograms. In this thesis, we have developed a decision support system to automatically analyze these spectrograms and detect any type of unusual signatures, these signatures are not necessarily originated from a damage in the engine. Firstly, we have built a numerical spectrograms database with annotated zones, it is important to note that data containing these unusual signatures are sparse and that these signatures are quite variable in shape, intensity and position. Consequently, to detect them, like in the novelty detection process, we characterize the normal behavior of the spectrograms by representing patches of the spectrograms in dictionaries such as the curvelets and the Non-negative matrix factorization (NMF) and by estimating the distribution of every points of the spectrograms with normal data depending or not of the neighborhood. The detection of the

unusual points is performed by comparing test data to the model of normality estimated on learning normal data. The detection of the unusual points allows the detection of the unusual signatures composed by these points.

keywords : dictionary learning, curvelets, kernel density estimation, novelty detection, anomaly detection, vibrations

Introduction

Le contexte industriel

Les moteurs manufacturés par Safran Aircraft Engines suivent une série de tests afin de vérifier leur viabilité avant d'être envoyés aux clients. Un de ces tests consiste en l'acquisition et l'analyse des signaux vibratoires sur banc d'essai durant différentes phases. Les moteurs d'avions sont des machines tournantes et subissent de nombreuses vibrations durant leurs services. Leurs mesures vibratoires contiennent des informations pouvant être liées au mauvais fonctionnement de différents éléments du moteur comme par exemple les roulements ou les engrenages (Figure 1). Les informations vibratoires inusuelles présentes sur les signaux ne sont pas nécessairement liées à un endommagement du moteur ou au mauvais fonctionnement de ce dernier, elles peuvent être issues de l'acquisition ou à l'excitation de certains modes non usuels du moteur. D'autres signatures présentes dans ces signaux sont normales et liées au fonctionnement nominal du moteur comme celles liées au fan (Figure 1). Ces dernières sont prévisibles et observables dans les signaux.

De nombreuses méthodes d'analyse des signaux vibratoires pour détecter des anomalies existent déjà [91]. Ces dernières se basent principalement sur les signaux vibratoires temporels sur lesquels sont appliquées diverses méthodes de traitement du signal comme la transformée de Fourier, la transformée en ondelettes [80], des moyennes synchrones, la cyclostationnarité [8]. Des représentations de type temps-fréquence sont également utilisées pour étudier les comportements vibratoires non-stationnaires, tels que les spectrogrammes ou les scalogrammes [117].

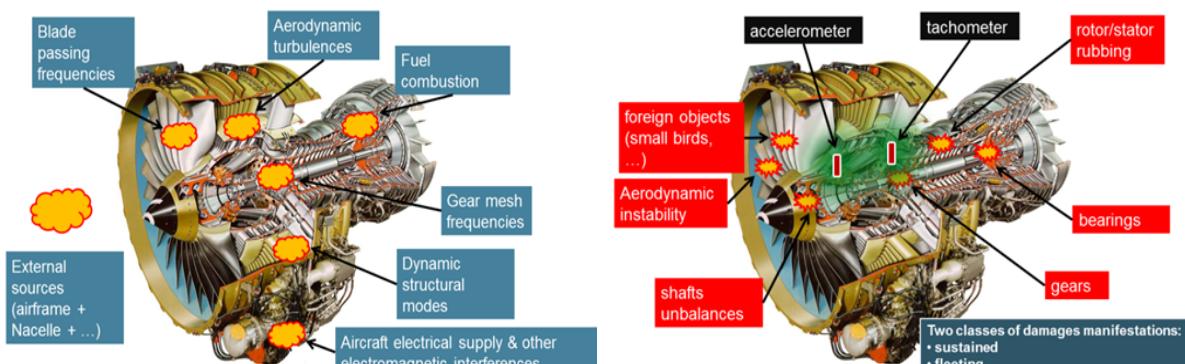


FIGURE 1 – Sources de vibrations normales des moteurs (gauche) et de vibrations anormales (droite)

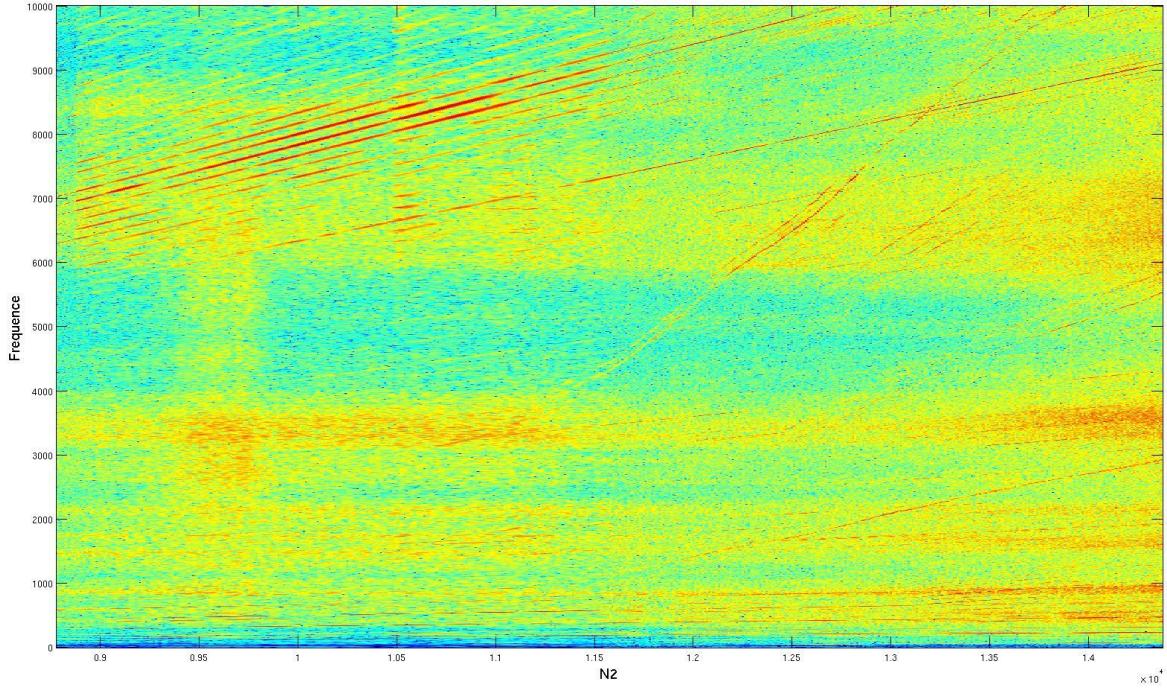


FIGURE 2 – Spectrogramme indexé en ordre (fréquence de vibration du moteur dépendant de la vitesse de rotation) durant une décélération lente. L'axe des abscisses correspond à une vitesse de rotation. Pour chaque vitesse, un spectre est calculé et est représenté sur l'axe des ordonnées, les couleurs allant du bleu au rouge donnent l'intensité de l'énergie pour la vitesse de rotation et la fréquence observée.

Problématique

Nous nous intéressons principalement à un type particulier de spectrogramme acquis pendant des transitoires lents (accélération et décélération) dont l'abscisse horizontale qui initialement représente le temps est remplacée par la vitesse de rotation d'un arbre du moteur, le régime moteur (Figure 2). Ces spectrogrammes sont représentatifs des signaux vibratoires sur banc d'essai de réception (avant livraison au client) pour lesquels nous cherchons des représentations pertinentes pour la détection automatique de signatures non usuelles potentielles. Les spectrogrammes vibratoires représentent l'intensité vibratoire à différentes fréquences f et différents régimes N_2 (une des vitesses de rotation du moteur). Ces mesures sont fortement bruitées, chaque point du spectrogramme peut être considéré comme une variable aléatoire. La construction des spectrogrammes à partir des mesures vibratoires est donnée dans le chapitre 1. A l'heure actuelle, les spectrogrammes (enregistrés dans un format numérique) sont analysés visuellement et annotés manuellement dans un format textuel par des experts. Il faut souligner qu'aucune trace numérique des signatures détectées n'est conservée. Par ailleurs, certains algorithmes sont utilisés pour rechercher des signatures spécifiques sur les spectrogrammes.

Nous disposons d'une base de données numérique des spectrogrammes issus des bancs d'essais, cette base ne contient qu'un unique moteur connu comme étant endommagé. Ces moteurs proviennent de la chaîne de production et ne contiennent que très rarement des signatures anor-

males liées à des endommagements. Endommager volontairement un moteur afin d'obtenir des données contenant des signatures anormales n'est pas envisageable car les moteurs ainsi que ces campagnes d'essai sont très coûteux. De plus, le nombre de possibles endommagements du moteur, bien qu'excessivement rares, est très large étant donnée la complexité du système. Un moteur est déclaré comme endommagé en cas de signature anormale trop importante et non pas uniquement en cas de présence d'un artéfact sur l'image du spectrogramme. Ainsi les moteurs déclarés comme normaux par les experts peuvent contenir des signatures inusuelles sans risque annotées et analysées par ces mêmes experts. Nous cherchons à détecter et mettre en évidence toutes les signatures inusuelles de manière automatique pour apporter une aide à la décision aux experts. Ces signatures atypiques correspondent aux artefacts des spectrogrammes devant être contrôlés par les experts. Ces signatures particulières, n'étant pas relatives à des endommagements du moteur, sont d'intensités faibles à des niveaux proches du bruit et donc peuvent être difficilement détectables visuellement sur les spectrogrammes. La mise en place de méthodes permettant de mettre en évidence ces anomalies automatiquement est pertinente pour l'efficacité de l'analyse vibratoire.

Ces spectrogrammes sont de grande dimension, chaque spectrogramme consiste en 1.5 million de points environ, chaque point étant lié à une fréquence f et un régime N_2 . Les signatures inusuelles présentes sur les spectrogrammes consistent en général en une infime partie de ces derniers (une signature inusuelle peut ne consister qu'en une centaine de points). Etudier le spectrogramme dans sa globalité compliquerait la tâche de représentation et de détection car les signatures atypiques seraient noyées par de l'information vibratoire normale et non pertinente. Nous avons donc décidé de travailler sur une décomposition des spectrogrammes en patchs (sous-zones du spectrogramme) définis par des plages de fréquences et de régimes. Les signatures inusuelles restent largement minoritaires sur les patchs et possèdent différentes localisations sur les spectrogrammes. Une forte disproportion entre les patchs contenant des signatures atypiques (nettement moins nombreux) et ceux pouvant être considérés comme totalement normaux est présente dans la base de données. La plupart des éléments de la subdivision contiennent aucune ou très peu de données possédant une signature inusuelle sur cet élément. Une autre caractéristique des spectrogrammes est la grande variabilité aussi bien au niveau de la nature des signatures atypiques au sein d'un même patch que de l'intensité vibratoire.

Nous notons $Y_{Z_{\mathcal{K}_j}}^i \in \{0, 1\}$ et $Y_{f, N_2}^i \in \{0, 1\}$ les variables aléatoires représentant la classe normale (valeur 0) ou atypique (valeur 1) pour respectivement le patch j de la subdivision \mathcal{K} (section 1.5.2) et le point de fréquence f et de régime N_2 du spectrogramme issu du moteur i . La classe atypique correspond à la présence d'une signature inusuelle sur le patch ou le point considéré. Nous cherchons dans notre étude à estimer ces variables aléatoires pour chaque moteur. Nous verrons par la suite qu'il est possible de disposer d'une vérité terrain pour $Y_{Z_{\mathcal{K}_j}}^i$ et Y_{f, N_2}^i . La vérité terrain des patchs a été obtenue à partir de l'extraction des annotations manuelles des experts, la vérité terrain des différents points du patch a été établie manuellement pendant cette thèse pour quelques points uniquement.

Les approches préconisées

Le sujet de cette thèse correspond à une problématique de modélisation des patchs des spectrogrammes à des fins de classification. Pour répondre à la problématique, nous utilisons des méthodes de machine learning [49, 15], consistant à apprendre un modèle sur les données et à calibrer un classifieur. Les méthodes de classification sont généralement supervisées avec un apprentissage des modèles pour les différentes classes présentes dans la base de données entièrement labélisée et équilibrée (la base de données contient une proportion suffisante de données de chaque classe).

Dans notre cas d'étude, les approches supervisées ne sont pas adaptées. La base de données contient un unique spectrogramme issu d'un moteur endommagé et les patchs contenant des signatures inusuelles ne sont pas en quantité suffisante. De plus, la grande variabilité de ces signatures atypiques ainsi que le manque d'exemples des différentes signatures possibles sont des obstacles à la création d'un modèle d'anomalie (Figure 3). Nous cherchons à détecter les différentes signatures inusuelles présentes sur les spectrogrammes vibratoires, cependant notre base de données ne contient pas toutes les anomalies possibles étant donnée la complexité du système. Il est important que la méthodologie mise en place permette la détection de signatures inusuelles jamais observées dans la base de données.

Nous nous sommes orientés vers des approches non-supervisées de type *one-class* (Figure 3), un modèle est appris pour une unique classe de la base de données, les données sont comparées au modèle défini afin de tester leur appartenance à cette classe. Ces approches s'apparentent à la détection de nouveautés [90, 83, 84], d'anomalies [26] ou d'*outliers*¹ [25, 60]. Ces termes sont considérés comme des synonymes dans la littérature du fait de leur proximité. Ce type de méthode mesure la non similarité entre les données tests et les données d'apprentissage appartenant à une certaine classe, elle est utilisée lorsqu'il existe une grande disparité entre le nombre de données labélisées normales et le nombre de données labélisées inusuelles. Ce phénomène est assez fréquent dans le monde industriel où le produit manufacturé est trop complexe et/ou coûteux pour pouvoir être testé dans différentes conditions afin d'obtenir une base de données de cas atypiques. Ce type d'approche est également très présent dans le milieu médical. Ces méthodes s'appuient sur des données normales pour apprendre un modèle de normalité des données, et cherchent à détecter les différences entre ce modèle et les nouvelles données. Dans le cadre des spectrogrammes, il s'agit donc de représenter (à travers des modèles) leurs comportements normaux et usuels.

Nous avons utilisé deux approches différentes. Une première approche consiste à utiliser des dictionnaires [75, 13, 80] pour représenter les données, qui sont alors projetées sur un sous-espace engendré par les éléments du dictionnaire. Ce sous-espace est défini sur des données normales et permet une reconstruction des données sans signature inusuelle. Le dictionnaire est appris sur les patchs et non pas sur le spectrogramme entier. Les dictionnaires n'ayant pas été calibrés avec les signatures atypiques, ces dernières sont susceptibles d'être mal reconstruites, elles se trouveraient

1. donnée aberrante

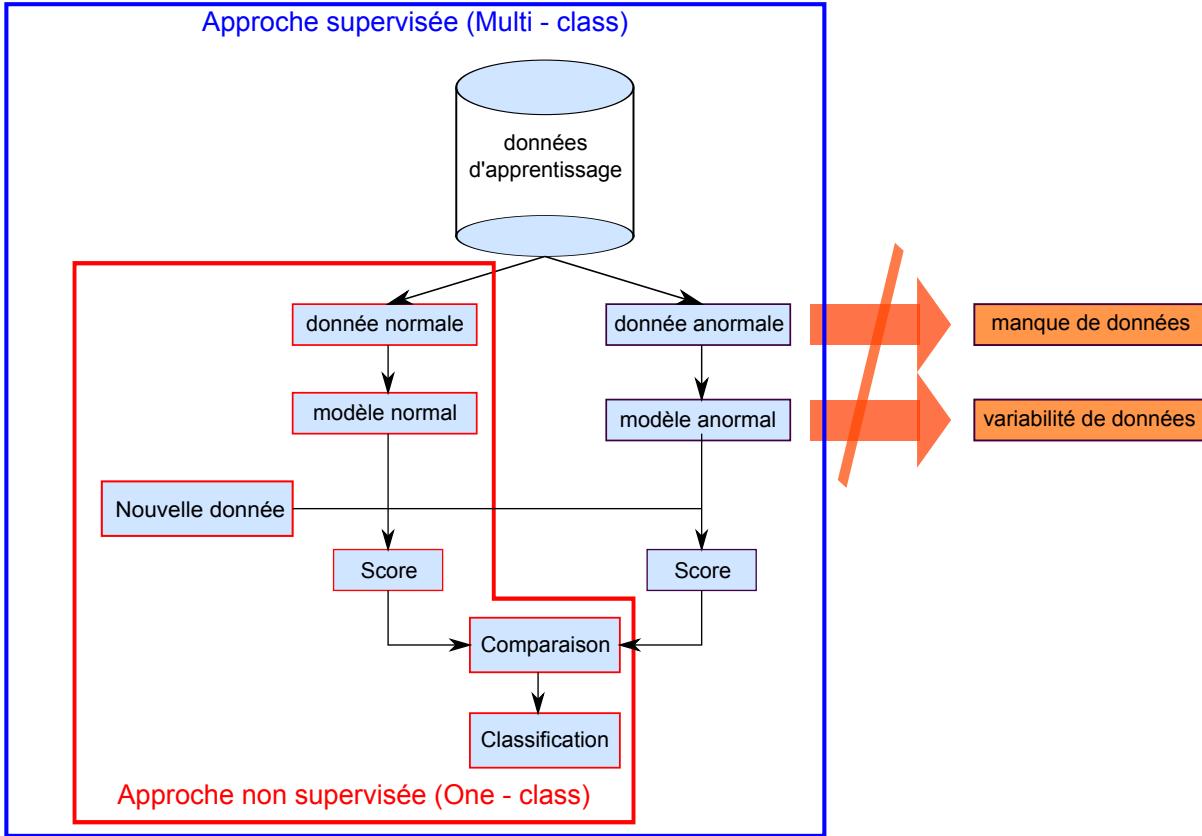


FIGURE 3 – Illustration des approches multi-class (en bleu) et one-class (en rouge). Les éléments sur le côté donnent les arguments dans nos données contre les approches multi-class.

donc dans les résidus de la reconstruction. Différents dictionnaires ont été étudiés :

- La Non-Negative Matrix Factorization (NMF) [70] : il s'agit d'un dictionnaire appris à partir des données (data-driven), ce dictionnaire s'adapte donc aux données,
- Les curvelets [22] : ce dictionnaire est défini par des fonctions et est donc indépendant du type de données.

Une seconde approche, localisée cette fois, reconside le spectrogramme comme une mesure physique en chaque point à une fréquence f et un régime N_2 . Ainsi la distribution de chaque point est apprise de manière non paramétrique [49] sur les spectrogrammes considérés comme normaux et des tests statistiques permettent de déterminer la conformité ou non des différents points du spectrogramme.

Nous avons ainsi conçu un outil d'aide à la décision qui permet d'analyser les spectrogrammes automatiquement et de guider les experts vers les signatures inusuelles présentes. Cet outil permet de donner à l'expert les points composant les signatures inusuelles, ce dernier devra alors analyser ces signatures afin de définir si la signature correspond à un endommagement et de juger de la sévérité de l'endommagement si celui-ci est présent.

Contributions

Cette thèse a donné lieu à trois articles présentés dans des conférences internationales :

- [3] *NMF-based Decomposition for Anomaly Detection applied to Vibration Analysis* (International Conference on Condition Monitoring and Machinery Failure Prevention Technologies CM-MFPT2015, Oxford, UK),
- [1] *Anomaly detection on spectrograms using data-driven and fixed dictionary representations* (European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning ESANN2016, Bruges, Belgique),
- [2] *Dictionary Comparison for Anomaly Detection on Aircraft Engine Spectrograms* (International Conference on Machine Learning and Data Mining MLDM2016, New-York, Etats-Unis).

Ces articles portent principalement sur les approches par dictionnaire, nous sommes en cours de rédaction d'un article de journal sur les différentes approches par dictionnaire et ponctuelles mises en place au cours de cette thèse pour la détection d'anomalies sur les spectrogrammes.

Nous avons mis en place dans cette thèse des outils d'aide à la décision pour l'analyse des spectrogrammes vibratoires permettant la mise en évidence des signatures atypiques. Les codes en langage MATLAB liées à cet outil ont été livrés à Safran Aircraft Engines.

Structure du mémoire

Ce mémoire de thèse est divisé en trois parties, chacune portant sur une échelle d'analyse différente de nos données.

La première partie correspond à une présentation globale des spectrogrammes et du type d'approche proposée. Le chapitre 1 contient une description de nos données et de l'analyse vibratoire. Le chapitre 2 donne un aperçu de la détection de nouveautés.

Nous présentons dans la seconde partie les approches par dictionnaire avec lesquelles nous étudions les spectrogrammes à l'échelle du patch. Le dictionnaire fixe des curvelets est étudié dans le chapitre 3. Le chapitre 4 porte sur le dictionnaire adaptatif déduit de la NMF.

Les spectrogrammes sont analysés ponctuellement dans la troisième partie à partir de la définition d'un modèle de normalité pour chaque point paramétré par une fréquence et un régime. Les différents points des spectrogrammes sont considérés comme indépendants dans le chapitre 5. La dépendance entre les points et leurs voisinages est prise en compte dans le chapitre 6.

Première partie

L'analyse vibratoire et détection de nouveautés

Introduction

L'analyse vibratoire donne des informations sur l'état de santé de systèmes mécaniques complexes tels que les moteurs d'avions. Les spectrogrammes constituent une représentation des mesures vibratoires à différents régimes et fréquences dans des conditions non stationnaires. Ces spectrogrammes correspondent à des données en grande dimension et les signatures inusuelles n'en constituent potentiellement qu'une infime partie. Les données dont nous disposons contiennent principalement des données normales avec un nombre limité de signatures atypiques. La grande variabilité des signatures inusuelles et leur faible nombre nous empêchent de mettre en place des modèles mathématiques représentatifs d'anomalies spécifiques. Nous avons donc décidé de caractériser les informations normales présentes au sein des spectrogrammes dans un premier temps afin de mettre en évidence dans un second temps les signatures inusuelles. Cette méthodologie correspond à des problématiques de détection de nouveautés [90].

Nous donnons dans cette partie une description des données, de leurs divers contenus et des problématiques associées indispensables pour la compréhension de la suite de ce manuscrit. Nous donnons également une description des méthodes de détection de nouveautés.

Chapitre 1

L'analyse et les données vibratoires

1.1 Introduction

L'analyse des vibrations est fondamentale pour la détection d'anomalies de systèmes complexes tels que les moteurs d'avions. Le système peut se mettre à vibrer à des fréquences non référencées correspondant à l'endommagement ou l'usure de l'une de ses pièces. Nous donnons dans ce chapitre une introduction à l'analyse vibratoire des moteurs d'avions ainsi qu'un état de l'art des différentes méthodes de détection d'anomalies sur les signaux vibratoires temporels, fréquentiels ou en temps-fréquence. Des explications sur l'acquisition des données et sur la construction des spectrogrammes étudiés sont également apportées avec les différentes contraintes associées à ce type de donnée. Les différents prétraitements effectués sur les spectrogrammes comme les subdivisions et l'extraction des informations d'experts sont également détaillés.

1.2 Les moteurs d'avions

1.2.1 Les caractéristiques des moteurs

Les moteurs d'avions sont des machines tournantes très complexes composées des éléments suivants :

- un arbre haute pression (HP) composé d'une turbine et d'un compresseur possédant une vitesse de rotation N_2 ,
- des compresseurs qui aspirent et compressent l'air pour l'amener à des vitesses, températures et pressions optimales pour la chambre de combustion,
- des turbines qui récupèrent une partie de l'énergie issue de la combustion des gaz pour le fonctionnement de la tuyère, des compresseurs et des accessoires ; chaque turbine fait fonctionner son propre compresseur,
- un arbre basse pression (BP) composé d'une turbine et d'un compresseur possédant une

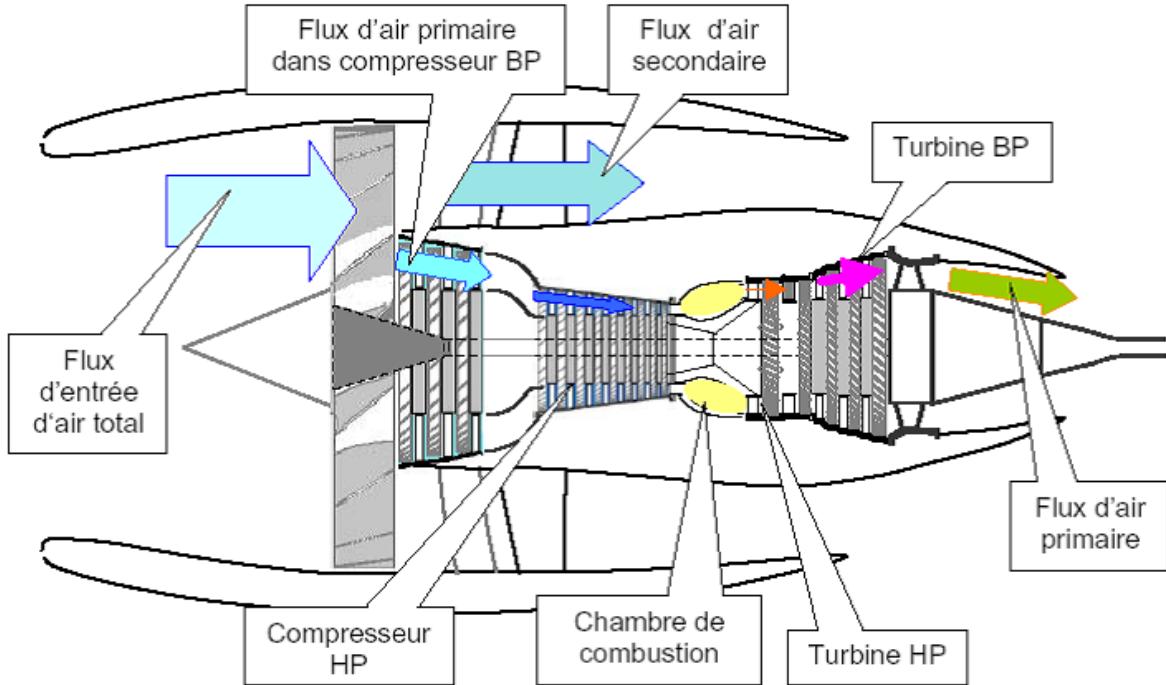


FIGURE 1.1 – Circulation de l'air lors du fonctionnement du moteur [108]. L'air est aspiré par le fan et divisé en 2 flux d'air, le flux d'air primaire est compressé dans les compresseurs BP et HP, puis chauffé dans la chambre de combustion et détendu dans les turbines HP et BP. Le flux d'air secondaire passe entre le moteur et la nacelle et permet un refroidissement du moteur.

vitesse de rotation N_1 ,

- un fan à l'avant du moteur qui permet d'effectuer la première étape de compression et de séparer le flux d'air entrant en un flux secondaire qui va contourner le moteur et un flux primaire qui suivra le cycle de compression-chauffe-détente (Figure 1.1),
- une chambre de combustion qui chauffe l'air à la sortie de la turbine HP afin d'apporter l'énergie nécessaire à mouvoir les turbines ainsi que suffisamment de poussée à la tuyère,
- une tuyère expulsant les gaz chauds sous pression sortant des turbines en leur communiquant le maximum de vitesse afin d'obtenir une poussée optimale,
- des paliers qui supportent et guident les arbres de transmission, il s'agit généralement de roulements (à billes et à rouleaux). Le palier dit "palier #4" est un des roulements les plus importants car il établit la jonction entre l'arbre HP et l'arbre BP, il est donc lié aux 2 vitesses de rotation.

La majorité des éléments présentés ci-dessus font partie du rotor (c'est-à-dire sont en rotation lorsque le moteur est en marche), les autres éléments font partie du stator et constituent les éléments non tournants.

Les moteurs fonctionnent en aspirant l'air capté par la nacelle et accéléré par le fan effectuant une première compression et en divisant le flux d'air en deux (Figure 1.1) :

- Le flux secondaire (ou flux froid) qui s'écoule autour du moteur et est éjecté à l'arrière du moteur. Ce flux permet de refroidir certaines parties du moteur et d'effectuer un coussin d'air afin d'empêcher l'air du flux primaire de s'échapper. Cette architecture permet de

limiter la consommation de carburant et d'augmenter le rendement de la propulsion par augmentation du taux de dilution. En effet, 80% de la poussée est apporté par le flux secondaire.

- Le flux primaire (flux chaud) subit une série de compressions à travers les compresseurs BP et HP. L'air sous pression est brûlé dans la chambre de combustion à l'aide de carburant afin de produire de l'énergie, cette énergie est récupérée par les turbines permettant le fonctionnement du fan et des compresseurs. Les gaz chauds et sous pression arrivent alors à la tuyère où ils sont accélérés avant d'être éjectés (avec le flux secondaire).

La propulsion de l'avion est due à la différence des vitesses entre la sortie d'air qui est nettement supérieure et l'entrée d'air. Cette différence de vitesse entraîne de la poussée F , force entraînant le mouvement de l'appareil.

$$F = G(V_1 - V_0)$$

V_0 et V_1 correspondent respectivement aux vitesses d'entrée et de sortie d'air, G est le débit massique.

1.2.2 Les vibrations du moteur

Les vibrations correspondent aux déplacements des différentes pièces au cours du temps (il s'agit d'oscillations), elles sont des images des forces internes de systèmes mécaniques. Les vibrations peuvent donc être mesurées comme un déplacement, une vitesse ou une accélération. Les vibrations périodiques sont majoritairement excitées par la rotation des deux arbres (HP ou BP), les fréquences vibratoires correspondent alors à des harmoniques entières d'un de ces deux arbres ou du Radial Shaft Speed (RDS) (1.1). Il s'agit de l'arbre auxiliaire transversal qui entraîne la boîte d'engrenage située sous le moteur et dont le rôle est de fournir de l'énergie aux différents accessoires comme les pompes, le générateur de courant, le calculateur,... La chambre de combustion entraîne également des vibrations.

$$\begin{aligned} \{f = \alpha N_2, \alpha \in \mathbb{N}\} \\ \{f = \beta N_1, \beta \in \mathbb{N}\} \\ \{f = \gamma \text{RDS}, \gamma \in \mathbb{N}\} \end{aligned} \tag{1.1}$$

α , β et γ sont alors considérés comme respectivement les ordres du N_2 , N_1 et RDS. Il s'agit de vibrations normales du moteur d'avion, ces signatures sont prévisibles et observables sur les signaux. Des vibrations atypiques peuvent également apparaître sur les signaux, il peut s'agir de vibrations issues des paliers et de leur modulation. Ces signatures sont à détecter impérativement. Des ordres non entiers d'une de ses 3 entités sont souvent considérés comme des signatures inusuelles. Les équations des fréquences vibratoires des paliers peuvent également être obtenues à partir de la connaissance de la géométrie des roulements, par exemple des vibrations à des fréquences multiples du $(N_2 - N_1)$ sont issues du palier #4 et doivent être impérativement détectées car elles indiquent une potentielle irrégularité sur ce roulement. Une signature inusuelle présente sur le signal vibratoire n'est pas nécessairement synonyme d'un endommagement.

1.2.3 L'acquisition des mesures vibratoires et des vitesses de rotation

Les vibrations sont acquises sous condition ambiante au cours du temps par des accéléromètres (capteurs piézoélectriques) situés sur le moteur aussi bien sur banc d'essai qu'en vol (les mesures sur banc d'essai sont à plus haute fréquence que celles récupérées en vol). Les vibrations consistant en un déplacement libèrent des charges électriques au niveau du capteur piézoélectrique qui sont amplifiées et converties en volt. Ce signal analogique est alors converti en signal numérique. Comme nous l'avons vu dans la section précédente, la connaissance des vitesses de rotation des arbres est indispensable afin de pouvoir expliquer certaines vibrations normales ou atypiques. Ainsi, deux tachymètres mesurent les vitesses de rotation des deux arbres.

Sur banc d'essai, les signaux sont acquis en phase d'accélération et de décélération, le moteur va monter en régime pendant environ 2 minutes jusqu'à atteindre les pleins gaz, suit alors une phase de descente de régime pendant environ deux minutes également. Lors de ces essais, nous sommes donc dans des phases non stationnaires. Les signatures atypiques sont plus facilement détectables lors de ces phases. Les capteurs récupèrent tout au long des essais les vibrations et les signaux tachymétriques à une fréquence d'échantillonnage $F_e = 52100\text{Hz}$.

Les signaux vibratoires (Figure 1.2a) correspondent à des signaux temporels où sont représentés en abscisse le temps et en ordonnée l'amplitude vibratoire. Les signaux du tachymètre (Figure 1.2b) sont des charges positives et négatives, la conversion en vitesse passe par le nombre de dépassements en front montant d'un seuil (ou en front descendant avec un seuil négatif) du signal tachymétrique (Figure 1.2c). La vitesse (Figure 1.2d) correspond alors au nombre de tours par minute d'un des deux arbres en fonction du temps. En vol, ces signaux sont acquis à une plus faible résolution due aux difficultés de volumétrie des données et d'émission en plein vol.

1.3 Conversion des signaux temporels en spectrogrammes

1.3.1 Intérêt de cette conversion

Le signal temporel vibratoire contient potentiellement des informations liées à des endommagements du moteur. Cependant sous la forme temporelle du signal, ces informations sont difficilement observables. Dans la figure 1.3, nous présentons les signaux temporels de deux moteurs issus des bancs d'essai, le premier à gauche (Figure 1.3a) en bleu concerne un moteur normal sans endommagement, le second à droite (Figure 1.3b) en rouge possède un endommagement au niveau du palier #4. Comme nous pouvons le voir, il n'y a visuellement aucune information notable permettant de discriminer l'un des moteurs par rapport à l'autre. Cela est dû au fait que les capteurs récupèrent l'information vibratoire de l'ensemble du moteur. Le signal correspond donc à un mélange des différentes sources vibratoires tels que le fan, la chambre de combustion, les arbres, etc. Une information vibratoire inusuelle, si elle existe, est alors noyée dans le signal par l'ensemble des vibrations normales. Des méthodes de séparation de sources [6] des signaux

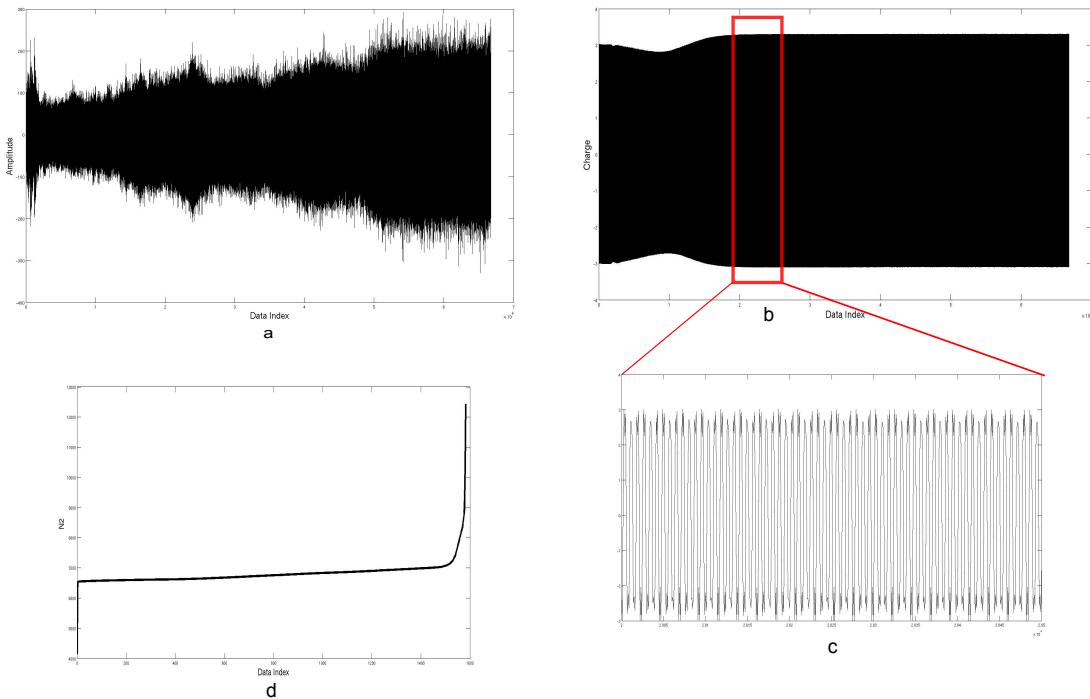


FIGURE 1.2 – Signaux acquis sur banc d’essai. Signal vibratoire issu des accéléromètres (a), le signal tachymétrique (b) correspond aux charges récupérées sur le tachymètre, zoom de ce signal (c) permettant de voir les fronts montants et descendants à partir desquels il est possible de calculer la vitesse de rotation de l’arbre HP (d) en comptabilisant le temps entre 2 fronts montants (ou fronts descendants). Le seuil défini pour la détermination des fronts est non-nul car il existe de petites fluctuations autour de 0 pouvant être interprétées comme un front montant et entraînant une mauvaise estimation de la vitesse de rotation.

vibratoires ont été utilisées dans la littérature afin de retrouver les différentes sources vibratoires afin de discriminer les sources normales des sources anormales pour la détection d’anomalies. Dans le cadre de l’analyse vibratoire, le signal est décomposé selon les sources périodiques, les sources stationnaires aléatoires et les sources non-stationnaires aléatoires.

La représentation des signaux vibratoires du domaine temporel au domaine fréquentiel permet une bonne séparation des sources vibratoires. En effet, les différents éléments (principalement tournants et faisant donc partie du rotor) du moteur possèdent des fréquences de vibrations bien spécifiques dépendant de la vitesse de rotation (vitesse d’un des deux arbres N_1 ou N_2) et du nombre de pales ou de dents de la pièce concernée. Un élément tournant ayant k pales et une vitesse de rotation N_2 aura une fréquence de vibration égale à $f = kN_2$, la fréquence de vibrations varie donc avec la vitesse de rotation.

Le passage du domaine temporel au domaine fréquentiel se fait par la transformée de Fourier [80]. Les pics vibratoires du spectre correspondent aux fréquences de vibrations spécifiques d’une pièce. Les pics non usuels permettent de détecter des irrégularités. Une telle interprétation de la transformée de Fourier d’un signal temporel suppose la stationnarité de ce dernier. En effet les fréquences des éléments tournants dépendant de la vitesse, si celle-ci n’est pas constante, de nombreuses fréquences devraient alors être assignées à une même source. Ainsi, la transformée

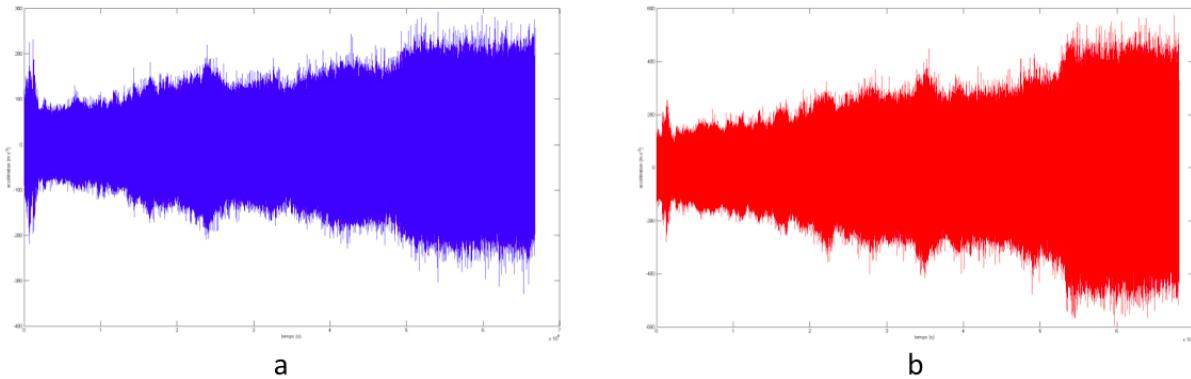


FIGURE 1.3 – Signaux bruts d'un moteur sans endommagement (à gauche) et avec endommagement (à droite)

de Fourier ne peut pas être appliquée aussi simplement à nos signaux acquis dans des phases non-stationnaires telles que l'accélération et la décélération. Les spectrogrammes permettent d'obtenir une représentation fréquentielle et d'analyser les signaux non-stationnaires.

1.3.2 La transformation du signal temporel en spectrogramme

Le signal temporel peut être converti en spectrogramme temporel (Algorithme 1), il s'agit de la concaténation de différents spectres calculés à partir de la Short-Time Fourier Transform (STFT) sur de petites fenêtres temporelles rectangulaires. Ces fenêtres sont suffisamment petites afin de pouvoir considérer la vitesse stationnaire sur ces dernières et ainsi pouvoir appliquer la transformée de Fourier. La taille de fenêtre sélectionnée est de $T = 0.2$ seconde. Avec une fréquence d'échantillonnage F_e , chaque fenêtre contient donc $T \times F_e = 10420$ points.

Algorithme 1 : Conversion du signal temporel en spectrogramme temporel

Données : Le signal temporel $x(t)$, le temps (taille) d'une fenêtre T , le taux de recouvrement des fenêtres w

Résultat : Un spectrogramme en temps-fréquence $S_t(t, f)$

Initialisation : $S_t = \emptyset$;

pour i allant de 1 : nombre de fenêtres(w, T) **faire**

$s = \mathcal{F}(x(i))$; Transformée de Fourier du signal dans la fenêtre i

$S_t = [S_t, s]$; Concaténation des spectres

Décaler la fenêtre de $(1 - w)T$

fin

retourner S_t

Cet algorithme permet d'obtenir un spectrogramme temporel, c'est-à-dire avec les fréquences en ordonnée et le temps en abscisse. Sous ce format les différentes sources vibratoires ont la forme de raies. Cette représentation ne permet pas de distinguer visuellement les raies vibratoires issues de l'arbre HP de celles issues de l'arbre BP. L'expertise des spectrogrammes se fait visuellement,

ainsi pour une meilleure distinction de l'information vibratoire, il est préférable d'échantillonner les spectrogrammes selon la vitesse de rotation de l'un des deux arbres (donc N_1 ou N_2). Dans notre cas, c'est la vitesse de rotation de l'arbre HP, donc N_2 , qui a été sélectionnée avec un pas d'échantillonnage $F_N = 10\text{rpm}$ (rotations par minute) (Algorithm 2).

Algorithme 2 : Conversion du signal temporel en spectrogramme en ordre

Données : Le signal temporel $x(t)$, le pas d'échantillonnage du régime HP F_N , la durée T d'une fenêtre pour le calcul de la STFT

Résultat : Un spectrogramme en régime-fréquence $S_N(N_2, f)$

Initialisation : Définition des régime N_2^{\min} et N_2^{\max} comme le plus petit et le plus grand régime multiples de F_N sur les données temporelles ;

pour n allant de N_2^{\min} à N_2^{\max} par pas de F_N **faire**

Trouver l'instant minimal t_{\min} dans x tel que $N_2(t_{\min}) = n$

Récupérer $X_{t_{\min}} = x(t_{\min} - T/2 : t_{\min} + T/2)$: signal sur la fenêtre temporelle centrée en t_{\min} et de durée T

$S_N(n) = \text{STFT}(X_{t_{\min}})$ spectre associé au régime n

fin

retourner S_N

Seul le spectre relatif au premier instant où la vitesse voulue est atteinte est conservé dans cette construction de spectrogramme. Les autres spectres, que ce soit ceux dont la vitesse N_2 n'est pas un multiple de T_N ou ceux dont la vitesse N_2 est identique à un spectre déjà sélectionné, ne sont pas pris en compte, entraînant une perte d'information.

Sous cette configuration, les vibrations issues de l'arbre HP sont représentées par des droites (voir Eq 1.1). Les vibrations issues de l'arbre BP ont des formes isomorphes à la relation entre le N_1 et le N_2 . La figure 1.5 présente cette relation pour différents moteurs avec en abscisse le régime N_2 et en ordonnée le régime N_1 . Nous pouvons remarquer que la relation, bien que relativement similaire en forme, est assez variable selon les moteurs du fait de différentes conditions extérieures. Cela entraîne le décalage des raies vibratoires liées au N_1 sur les spectrogrammes échantillonnés en N_2 . Les vibrations n'ayant pas la forme de droite (à coefficients entiers du N_2 ou du RDS) ou des formes liées au N_1 sont considérées comme atypiques (Figure 1.4). Notre base de données correspond à une collection de spectrogrammes échantillonnés en N_2 .

1.3.3 Gains et limites de cette représentation

L'avantage principal du spectrogramme est la possibilité de détecter visuellement les signatures inusuelles qui sont facilement observables en zoomant sur la zone correspondante (Figure 1.4c). De plus, comme le spectrogramme est rééchantillonné en N_2 , tous les spectrogrammes possèdent ainsi une plage de régimes identiques (les fréquences entre les différents spectrogrammes sont déjà identiques). Ainsi il est possible de comparer exactement les mêmes éléments sur les spectrogrammes. De plus les raies vibratoires de même ordre fréquentiel issues de l'arbre HP ont

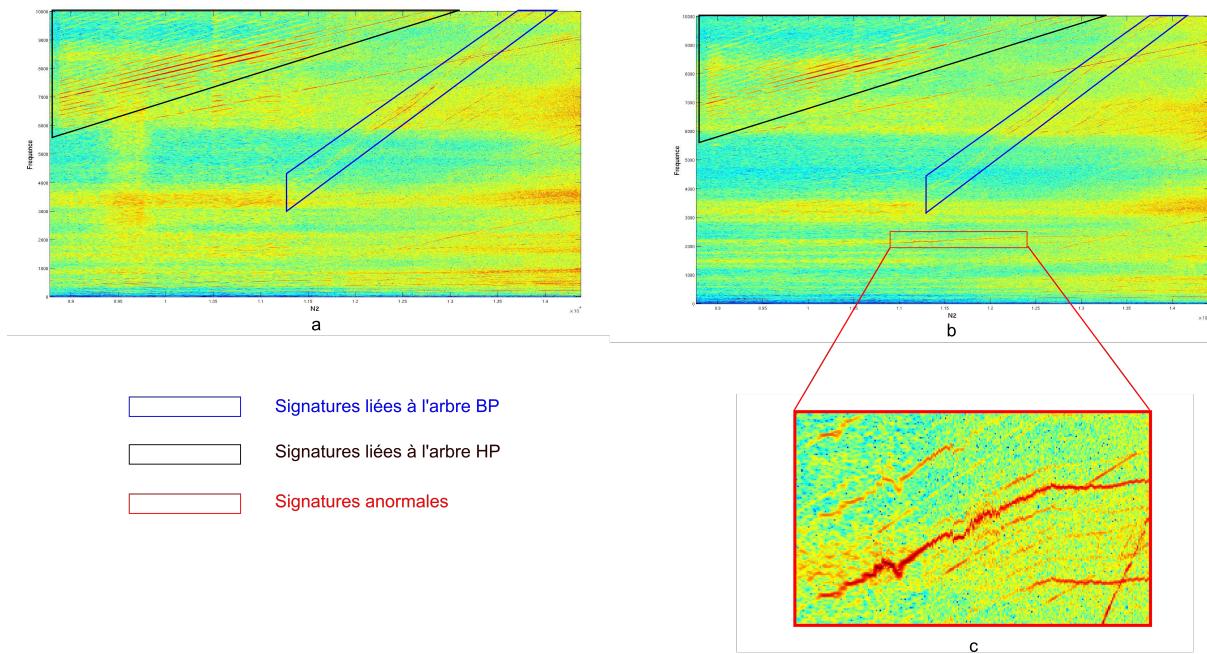


FIGURE 1.4 – Spectrogramme rééchantillonné en N_2 . Spectrogramme d'un moteur déclaré comme sans endommagement (a) et d'un moteur endommagé (b) avec zoom sur les signatures anormales (c). Les signatures liées à l'endommagement sont visibles uniquement en zoomant sur la zone.

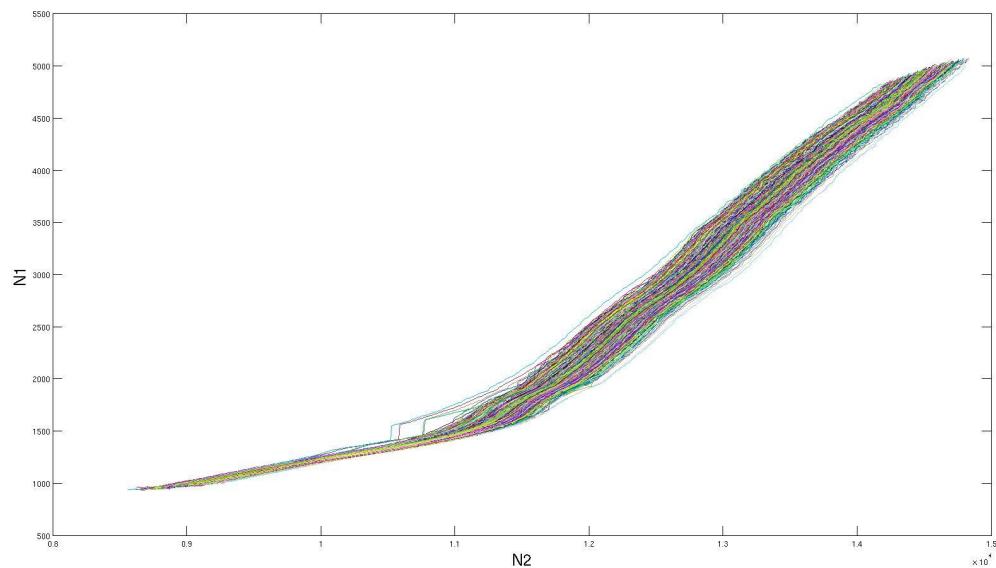


FIGURE 1.5 – Variabilité de la relation entre le N_1 et le N_2 . Chaque couleur de la figure correspond à la relation d'un moteur différent, la relation entre le N_1 et le N_2 est donc variable entraînant le décalage des raies liées au N_1 sur les spectrogrammes échantillonnés en N_2 .

exactement la même localisation sur les différents spectrogrammes.

Cette représentation possède également quelques inconvénients compliquant la mise en place d'algorithmes de détection automatique. La figure 1.5 montre une grande variabilité sur les relations N_1/N_2 des différents moteurs pouvant dépendre de la température ambiante. Ainsi bien que les signatures vibratoires de même ordre fréquentiel issues de l'arbre HP se trouvent toujours à la même localisation, cette affirmation est erronée en ce qui concerne les signatures vibratoires de même ordre issues de l'arbre BP. Une seconde contrainte liée à cette représentation est sa grande dimension, chaque spectrogramme possède 1.5 million de mesures vibratoires à différents régimes et fréquences. Cependant comme on l'observe sur la figure 1.4, les signatures non usuelles consistent en une infime partie du spectrogramme caractérisée par quelques centaines de points sur ce dernier. Les informations pertinentes que sont les signatures inusuelles risquent fortement d'être noyées par des informations non pertinentes, comme les raies normales ou du bruit, en cas d'étude du spectrogramme dans sa globalité. Nous verrons par la suite comment nous pallions cette disproportion. Les informations non pertinentes que sont les signatures normales et le bruit de mesures peuvent être assimilées à du bruit par rapport à notre étude. Nous pouvons alors dire que le rapport signal sur bruit du spectrogramme est très faible.

Les spectrogrammes consistent en une concaténation de spectres eux même bruités. Les intensités des signatures inusuelles peuvent être proches du niveau du bruit sur les spectrogrammes. Nous cherchons à détecter toute trace de ces signatures atypiques sur les spectrogrammes et non pas uniquement celles synonymes d'endommagement du moteur, donc également celles ayant des intensités proches du bruit.

La dernière contrainte présente dans nos données est l'absence d'étiquetage numérique des différentes vibrations inusuelles présentes sur les spectrogrammes. Cette contrainte n'est pas liée aux spectrogrammes en eux-même, à l'acquisition ou la transformation des données. La base de données numérique dont nous disposons contient uniquement les spectrogrammes des moteurs, mais manque d'informations sur les signatures atypiques présentes dans ces derniers. Dans la section suivante, nous discutons de la création d'une base de données annotées.

1.4 Construction de la base de données

1.4.1 L'annotation manuelle des experts

L'analyse par les experts des spectrogrammes s'effectue visuellement et manuellement. Safran Aircraft Engines dénomme cette opération le "screening visuel". Pour chaque nouveau moteur, les spectrogrammes en phase d'accélération et de décélération sont observés et les experts encadrent (en jaune) les zones suspectées de contenir des signatures atypiques. Cette annotation est effectuée sur des captures d'écran de plages de fréquences des spectrogrammes (Figure 1.6). Les plages de fréquences observées sont les mêmes pour chaque spectrogramme analysé. Ces informations

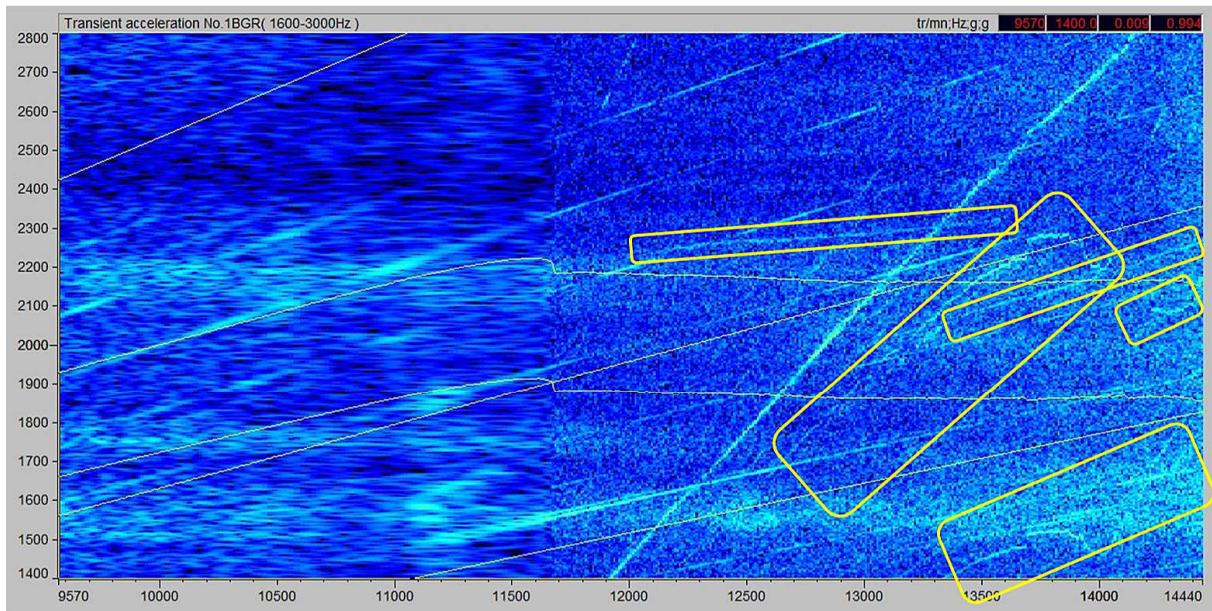


FIGURE 1.6 – Annotation manuelle des spectrogrammes par des experts. Chaque cadre jaune correspond à une zone suspectée par un expert de contenir une signature inusuelle. Les plages de fréquences observées peuvent contenir plusieurs signatures atypiques, ces dernières peuvent également se superposer.

ne permettent pas de donner la localisation précise des signatures inusuelles sur les différents spectrogrammes. Il n'existe pas de traces numériques de ces signatures, les seules informations disponibles étant :

- les données numériques des spectrogrammes moteurs sans annotations des signatures inusuelles,
- les données textuelles des captures d'écran des annotations manuelles des experts encadrant les zones contenant des signatures inusuelles.

Plusieurs signatures atypiques peuvent être présentes sur le spectrogramme au niveau de la plage de fréquences étudiées.

La figure 1.6 montre une capture d'écran annotée par un expert sur la plage de fréquences 1400–2800Hz. Les éléments caractérisés sont des zones du spectrogramme contenant la signature décrétée comme atypique. Cela ne signifie pas que tous les points de la zone encadrée sont à détecter, mais qu'une signature inusuelle est présente dans la zone. Même au sein de la zone encadrée, une grande partie des points restent normaux. La figure montre également une grande diversité des signatures inusuelles au sein d'une même zone, cette diversité et leurs faibles nombres empêchent de mettre en place des modèles de données atypiques. Notre avons construit une base de données numérique associant les données numériques des spectrogrammes aux données textuelles des captures d'écran d'annotations manuelles (Figure 1.6) des experts.

La visualisation, par les experts de Safran Aircraft Engines, de ces spectrogrammes permet de vérifier que les signatures atypiques présentes ne sont pas liées à un endommagement du moteur. Les travaux réalisés durant cette thèse ont pour but de mettre en évidence ces signatures atypiques, et ainsi de pouvoir acquérir automatiquement ces différentes signatures inusuelles.

1.4.2 Extraction automatique des zones anormales sur les données textuelles

Nous cherchons à mettre en place des algorithmes de détection d'anomalies sur les spectrogrammes. Cependant pour se faire, il est nécessaire de connaître les zones contenant des signatures inusuelles afin de sélectionner les données sur lesquelles les modèles de normalité (caractérisant les informations normales sur les spectrogrammes) sont calibrés. Les captures d'écran des annotations manuelles des experts contiennent cette information. Nous avons extrait les cadres (zones) définis par les experts pour convertir cette information textuelle en données numériques pour la construction d'une base de données numérique de spectrogrammes annotés. L'algorithme 3 d'extraction analyse les captures d'écran sur lesquelles nous cherchons à détecter les pixels de couleur jaune (Figure 1.6). Nous récupérons une information de position des pixels sur l'image que nous projetons sur les axes des régimes et fréquences connus afin d'avoir une estimation des fréquences et régimes des pixels concernés. La plage de fréquences est connue car elle est identique sur tous les spectrogrammes analysés. La plage des régimes N_2 est également connue car les spectrogrammes sont analysés sur la plage totale des régimes dont nous disposons dans notre base numérique de spectrogrammes. Une fois l'ensemble des pixels déterminés, nous cherchons un chemin fermé de ces points. Ce chemin constitue le (ou les cadres) annoté(s) par les experts. Plusieurs cas de figures peuvent apparaître :

1. le cadre (rectangle) extrait par le chemin fermé est droit et n'est pas superposé avec un autre cadre (Figure 1.7a) ; dans ce cas, le chemin des pixels jaunes et le cadre récupéré correspond à celui annoté par les experts
2. le cadre est oblique et n'est pas superposé avec un autre cadre (Figure 1.7b) ; pour plus de simplicité, nous cherchons à caractériser les zones atypiques uniquement par des rectangles droits. Ainsi, pour caractériser ces cadres obliques, nous récupérons le plus petit rectangle droit englobant le rectangle oblique.
3. Différents cadres se superposent (qu'ils soient droits ou obliques) (Figure 1.7c). Nous n'avons pas cherché à discriminer un cadre par rapport à un autre dans ce cas de figure, bien que des techniques plus avancées de reconnaissance de forme le permettraient. Le croisement des différents cadres entraînent des bifurcations pour les chemins fermés. Pour caractériser ces zones atypiques, nous prenons encore une fois le plus petit rectangle droit englobant l'ensemble des différents cadres superposés.

Les zones atypiques extraites sont définies par une plage de fréquences et de régimes définissant un rectangle droit dans le spectrogramme, même si la zone annotée initiale correspondait à un rectangle oblique. Ces cadres englobent donc plus d'informations normales et donc non significatives que les cadres créés par les experts mais contiennent bien les signatures inusuelles. Cette extraction a permis la mise en place d'une base de données numérique annotée contenant les spectrogrammes ainsi qu'une information sur les positions des signatures inusuelles dans ces derniers. Nous considérons donc ces zones comme contenant des signatures inusuelles mais nous ne considérons pas tous les points de ces zones comme atypiques.

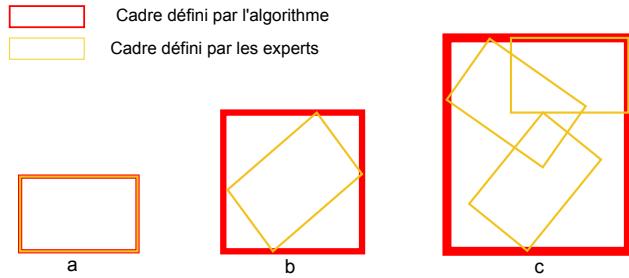


FIGURE 1.7 – Les différents cas de figure d'extraction des zones atypiques (rouge) sur les annotations manuelles (jaune).

Algorithme 3 : Extraction des annotations manuelles

Données : Les annotations manuelles, le spectrogramme vibratoire, l'axe des régimes et l'axe des fréquences

Résultat : L'ensemble des zones contenant des signatures inusuelles

Conversion de l'annotation manuelle en image.

Détection de tous les pixels associés à la couleur jaune sur l'image.

Récupération des formes connexes parmi les pixels détectés.

pour chaque composante connexe **faire**

Détermination des coordonnées de pixels minimales et maximales.

Projection de ces coordonnées sur l'axe des régimes et des fréquences.

Définition du rectangle englobant.

fin

1.4.3 La base de données enrichie

Nous disposons dans notre base de données de $n = 493$ moteurs (492 déclarés sans endommagement et 1 avec endommagement) annotés par les experts. Les labels des signatures inusuelles ne sont pas indiqués, ces zones sont donc indexées par un simple numéro. Chaque spectrogramme ne possède pas le même nombre de zones atypiques. Chaque donnée contient les différentes informations nécessaires à l'étude des spectrogrammes (Figure 1.8) :

- le spectrogramme du moteur i , $S^i \in \mathbb{R}^{\text{card}(f) \times \text{card}(N_2)}$ représentées comme une matrice de dimension la taille $\text{card}(f)$ de l'échantillonnage fréquentiel calculé par la transformée de Fourier et la taille $\text{card}(N_2)$ de la discréttisation des vitesses de rotation N_2 de l'arbre HP atteint par le moteur sur le banc d'essai. Les fréquences sont les mêmes pour tous les spectrogrammes de la base de données, l'échelle des régimes N_2 possède une plage commune de régimes sur l'ensemble de la base,
- les vitesses de rotation de l'arbre HP du moteur i , N_2^i correspondant aux régimes sur lesquels le spectrogramme a été calculé,
- les vitesses de rotation de l'arbre BP du moteur i , N_1^i qui correspondent aux régimes BP associés aux régimes HP,
- les zones atypiques (Zone_Ano) détectées par l'algorithme 3 paramétrées par des fréquences minimale et maximale et des régimes N_2 minimal et maximal,

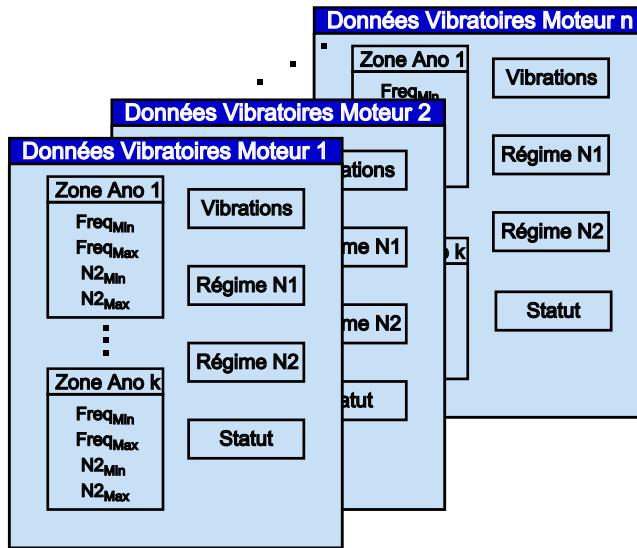


FIGURE 1.8 – Illustration de la base de données et de ses éléments. Chaque observation de la base de données contient le spectrogramme (Vibrations) avec ses différentes zones atypiques définies par une plage de fréquences et de régimes N_2 . Les régimes N_1 , N_2 et le statut normal ou endommagé du moteur sont également des attributs de l’observation.

- le statut du moteur correspondant à l’état normal ou endommagé du moteur défini par les experts ; notre base contient presque intégralement des moteurs classés comme normaux.

Nous notons cette base de données \mathcal{B}_0 . A partir de cette base, il est possible de manière simple de sélectionner une partie spécifique du spectrogramme et de déterminer les moteurs dont les spectrogrammes sont normaux ou atypiques sur cette partie. Il n’est cependant pas possible pour le moment de sélectionner un structure de signature et d’en déterminer l’ensemble des spectrogrammes où la signature est présente.

1.5 Étude des spectrogrammes par patch

1.5.1 Localisation des signatures inusuelles sur le spectrogramme

Les moteurs déclarés comme normaux par les experts peuvent posséder des signatures inusuelles sur leurs spectrogrammes ne correspondant pas nécessairement à un endommagement du moteur. Ces signatures atypiques restent des informations très localisées sur ces derniers. Une même anomalie apparaît en général à des fréquences bien spécifiques. La figure 1.9 présente une carte des proportions des zones atypiques présentes dans notre base de données. Cette carte donne point par point sur le spectrogramme la proportion de moteurs de notre base de données dont le point étudié sur le spectrogramme appartient à une zone atypique. Les éléments de ce résultat sont à nuancer car notre algorithme d’extraction défini au-dessus inclut de nombreux points normaux dans les zones extraites. Cette carte nous apporte tout de même des informations concernant les différentes zones où les irrégularités sont présentes. Les zones atypiques sont localisées, la majorité des zones ne sont pas du tout (ou très peu) touchées par des signatures

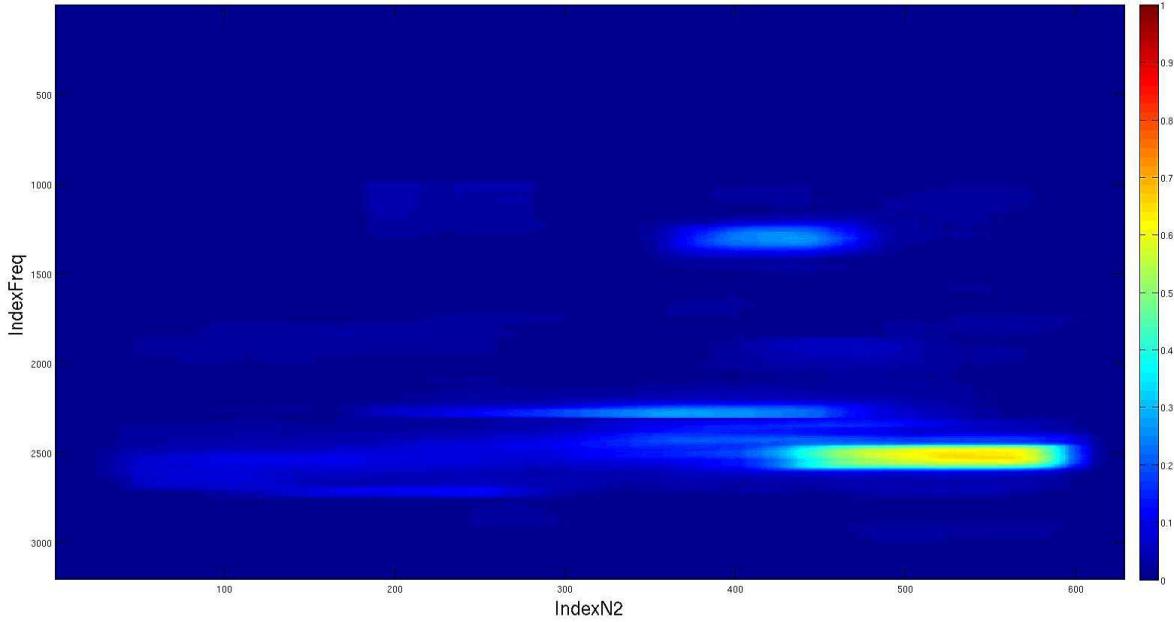


FIGURE 1.9 – Proportion (allant du bleu au rouge) pour chaque point du nombre de moteurs dans la base de données dont le point sur le spectrogramme appartient à une zone extraite. La plupart des points appartiennent rarement à des zones atypiques, une zone particulière attire notre attention avec plus de la moitié des moteurs de la base de données possédant une signature atypique sur cette zone dans leurs spectrogrammes.

inusuelles alors que d'autres possèdent une signature inusuelle dans plus de la moitié de notre base de données. Les zones atypiques présentes sur les spectrogrammes sont concentrées sur des positions spécifiques du spectrogramme, il est donc intéressant d'étudier chacune de ces zones séparément et de ne pas définir de modèle sur l'intégralité du spectrogramme. Nous présentons dans la partie suivante les bénéfices apportés par une approche de ce type.

1.5.2 Subdivision du spectrogramme en patchs

Les signatures inusuelles présentes sur les spectrogrammes sont de dimensions infimes comparées à la taille des spectrogrammes, la dimension correspondant au nombre de pixels. Il est donc fort probable que la signature inusuelle soit noyée par l'information normale présente sur le spectrogramme en effectuant une analyse statistique directement sur l'intégralité de ce dernier. Deux points d'attention empêchent l'étude du spectrogramme dans sa globalité comme une unique donnée :

- à l'échelle du spectrogramme, le rapport signal à bruit est très faible, si on considère le bruit comme l'information non pertinente constituée des raies normales et le bruit de mesure et le signal comme les raies atypiques ;
- bien que les moteurs dont sont issus les spectrogrammes sont considérés comme non endommagés, les spectrogrammes peuvent contenir des signatures inusuelles qu'il est important de détecter. En considérant le spectrogramme dans sa globalité, peu de données pourraient être considérées comme exemptes de signature atypique.

Une méthode pour pallier ces problèmes est de subdiviser les spectrogrammes en patchs sur une plage commune de régimes. Chaque patch correspond à une même plage de fréquences et de régimes sur l'ensemble de la base de données sur lequel une analyse est effectuée indépendamment des autres patchs. Nous définissons alors une subdivision \mathcal{K} comme un ensemble d'intervalles de régimes et de fréquences décomposant le spectrogramme en patchs Z correspondant à une extraction d'un rectangle sur le spectrogramme complet :

$$\mathcal{K} = \{\mathcal{K}_j = [f_{jini}, f_{jend}] \times [N_{2,jini}, N_{2,jend}], j \in \{1, \dots, \text{card}(\mathcal{K})\}\} \quad (1.2)$$

$$Z_{\mathcal{K}_j}^i = S^i(\mathcal{K}_j)$$

avec i le moteur considéré et S^i le spectrogramme issu de ce moteur, \mathcal{K}_j correspond au patch j de la subdivision \mathcal{K} .

Cette approche est similaire au processus des experts en mécanique de Safran Aircraft Engines. Le screening visuel consiste à regarder le spectrogramme sur des plages de fréquences prédéfinies afin d'avoir une meilleure observation des signatures inusuelles. La subdivision est indépendante du spectrogramme considéré et apporte divers avantages. Elle répond aux deux points d'attention énoncés ci-dessus. Le rapport signal à bruit de chaque patch est nettement supérieur par rapport au même rapport sur le spectrogramme complet, les signatures atypiques sont bien plus visibles au niveau des patchs. A l'inverse de la donnée complète, où nous disposons de peu de données sans aucune signature inusuelle pour mettre en place les modèles caractérisant la normalité, à l'échelle du patch ce problème ne se pose pas. A partir de la base de données construite (section 1.4), il est possible de sélectionner l'ensemble des spectrogrammes avec ou sans anomalie sur le patch considéré. Pour cela, il suffit de vérifier sur le spectrogramme étudié l'intersection entre les zones atypiques extraites dans la base données construite et le patch considéré. Si cette intersection est vide, le patch du moteur étudié est considéré comme normal. Nous disposons donc, à partir de la base de données et pour chaque patch de la subdivision, de la vérité terrain $Y_{Z_{\mathcal{K}_j}}^i$ caractérisant le caractère normal ou atypique pour le spectrogramme i du patch j de la subdivision \mathcal{K} . Rappelons que cette information à l'échelle ponctuelle (c'est-à-dire au niveau de chaque point du spectrogramme) Y_{f,N_2}^i n'est pas accessible car les annotations d'experts s'effectuent sur des zones du spectrogramme et non pas au niveau des points de ce dernier. Nous ne pouvons pas considérer chaque point des zones atypiques comme inusuels.

L'étude des spectrogrammes à partir d'une subdivision apporte d'autres avantages qu'une réduction du rapport signal sur bruit ou la classification des patchs comme normaux ou atypiques :

- la variabilité au niveau du patch est nettement inférieure à celle du spectrogramme complet ce qui permet de mieux caractériser les comportements normaux à cette échelle ;
- les patchs sont de dimension inférieure, ce qui permet une mise en place plus rapide des modèles ;
- l'anomalie est détectée uniquement sur le ou les patchs contenant les signatures inusuelles. Nous disposons donc d'une localisation approximative de ces signatures ;
- l'analyse des différents patchs est parallélisable, car ils sont étudiés de manière indépen-

dante.

Trois paramètres définissent la subdivision des spectrogrammes en patchs :

- la taille des patchs en longueur et largeur,
- le recouvrement des patchs.

Les signatures inusuelles correspondent à des raies. Afin de pouvoir les distinguer, il est nécessaire que les patchs soient suffisamment larges afin d'avoir un maximum d'information les concernant. Cependant si le patch est trop grand, la signature inusuelle risque d'être noyée par de l'information normale. La taille du patch doit apporter un équilibre entre la quantité relative d'information inusuelle présente dans le patch par rapport aux zones atypiques et la quantité d'information normale. De plus certaines méthodes de représentation par dictionnaire exigent que la donnée d'entrée soit sous la forme de carré dyadique. Nous avons donc choisi cette structure de patch. Avoir la totalité de la signature inusuelle dans le patch permettrait de maximiser le taux d'information inusuelle. Nous avons donc déterminé la taille moyenne du carré permettant d'englober les zones atypiques de la base de données.

$$\hat{L}_{\mathcal{K}} = \frac{1}{\text{card}(\text{zones}_{ano})} \sum_{k \in \text{zones}_{ano}} \max(L_{\text{zones}_{ano}^k}, l_{\text{zones}_{ano}^k})$$

$L_{\text{zones}_{ano}^k}, l_{\text{zones}_{ano}^k}$ correspondent à la longueur et la largeur des zones atypiques zones_{ano}^k de la base de données.

Nous obtenons $\hat{L}_{\mathcal{K}} \approx 147$. Cette valeur est supérieure à la réalité, les zones extraites par l'algorithme 3 sont surdimensionnées (prise du rectangle droit uniquement, fusion des zones) par rapport aux zones annotées par les experts. Nous avons donc opté pour une subdivision en carré dyadique de taille 128 pixels, cela signifie une plage de fréquences de $400Hz$ et une plage de régimes de 1280rpm. Une taille de 256 pixels serait trop importante et noierait les signatures inusuelles. Des patchs de dimension 64 ne permettraient pas de contenir toute la signature inusuelle. Le recouvrement des patchs n'est pas indispensable pour les approches étudiées dans cette thèse. Nous utilisons donc une subdivision \mathcal{K}^{128} du spectrogramme en patchs carrés de taille 128×128 sans recouvrement (Figure 1.10). Dans la suite, nous étudions également les spectrogrammes de manière ponctuelle comme un ensemble de points d'intensités vibratoires. Nous pouvons considérer cela comme une subdivision du spectrogramme en patchs de taille 1. Cette subdivision est caractérisée par les coordonnées en fréquence f et en régime N_2 de chaque point.

La subdivision est établie sur les plages de fréquences et de régimes communes à l'ensemble des spectrogrammes. Les vibrations sous et au-dessus d'un certain régime ne sont pas considérées car il s'agit de régimes non communs à l'ensemble de la base. Les vibrations à des fréquences supérieures à un certain seuil ne sont pas prises en compte non plus du fait de la non-annotation par les experts (repliement spectral à des fréquences très élevées). Nous considérons donc les spectrogrammes comme l'ensemble des patchs les composant.

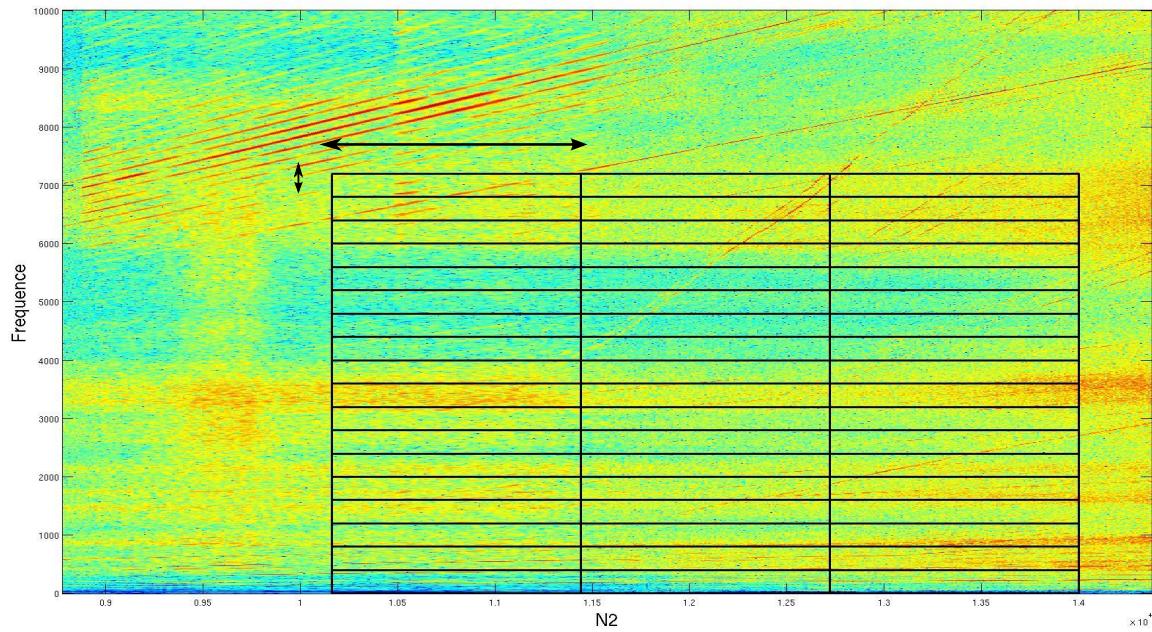


FIGURE 1.10 – Subdivision \mathcal{K}^{128} . Les flèches correspondent à la taille des patchs et chaque cadre à un des patchs. Les intensités vibratoires sous et au-dessus de certains régimes ne sont pas prises en compte, tout comme les intensités au-dessus d'une certaine fréquence.

1.5.3 Labélisation ponctuelle du patch - enrichissement de la base de données

Nous cherchons à donner un résultat de détection sur les patchs considérés. Il est également possible de mettre en place des algorithmes afin de détecter ponctuellement les signatures inusuelles, c'est-à-dire la détection des différents points composant cette signature et non pas du patch la contenant. Cependant, nous ne disposons pas (et nous n'avons pas la possibilité) d'obtenir une annotation de tous les points des différents spectrogrammes. Il s'agit d'une des raisons pour lesquelles nous avons opté pour une détection au niveau du patch. Afin de donner des résultats numériques de cette détection, combinés aux résultats visuels, nous avons annoté manuellement quelques points des spectrogrammes. Pour une soixantaine de spectrogrammes, une douzaine de points ont été récupérés et chaque point est affecté à une des 4 classes suivantes :

- classe "normal" : le point fait partie d'une signature normale liée à l'arbre HP,
- classe "inusual" : le point fait partie d'une signature atypique,
- classe "bruit" : bruit du spectrogramme, le point ne se trouve pas sur une raie et ne représente donc pas la vibration spécifique d'un arbre ou d'une irrégularité,
- classe "décalé" : le point fait partie d'une signature normale, mais cette dernière n'est pas exactement identique sur l'ensemble des spectrogrammes, il s'agit des signatures liées à l'arbre BP n'ayant pas la même position dans tous les spectrogrammes.

Seule la classe 2 doit être détectée comme atypique.

Trois points issus de chaque classe sont récupérés sur un patch spécifique d'un ensemble de 60 spectrogrammes. Le patch sélectionné correspond à celui contenant un nombre important de signatures inusuelles dans notre base de données (Figure 1.9). Cette extraction d'information

est possible uniquement manuellement et est coûteuse en temps. Il n'a donc pas été possible d'effectuer cette opération sur tous les points, patchs, ou spectrogrammes. Notons cette base de données \mathcal{B}_1 . Elle contient uniquement les données du patch des spectrogrammes desquels les informations ponctuelles ont été extraites. Cette extraction permet de donner des résultats de détection ponctuelle sur les spectrogrammes.

1.5.4 La grande variabilité des signatures inusuelles

Dans un cadre supervisé, une méthode pour classifier les patchs comme normaux ou atypiques serait de construire un classifieur pour chaque patch indépendamment. Considérons un patch Z_j issu d'une des subdivisions, l'approche serait de définir ou d'apprendre un modèle sur les patchs normaux Z_j^{normal} et sur les patchs inusuels Z_j^{ano} (Figure 3). Le classifieur correspondrait alors à l'appartenance la plus vraisemblable d'un nouveau patch Z_j^{test} à l'une des classes (les modèles sont définis pour un patch en particulier, les patchs tests correspondent exactement à la même zone sur les spectrogrammes tests). C'est de cette manière que des méthodes telles que la régression logistique ou les arbres de classification [49] sont construites. Cependant, pour effectuer une telle approche, il est indispensable que la base de données d'apprentissage contienne suffisamment d'échantillons des différentes classes. Il est également nécessaire que la variabilité au sein d'une même classe ne soit pas trop importante.

Notre base de données ne satisfait aucun de ces deux critères. Comme nous l'avons vu sur la figure 1.9, certaines zones contiennent très peu de données avec des signatures inusuelles. Mettre en place un modèle d'anomalie dans ce cadre n'est donc pas adapté. Certaines zones, à l'inverse, contiennent un nombre suffisant de données atypiques. Cependant ces derniers ne satisfont pas le second critère. Il existe une grande variabilité des signatures singulières au sein d'un même patch et pas suffisamment de données pour chacune d'entre elles (Figure 1.11).

Les différents types de signatures inusuelles du même patch (Figure 1.11) présentent de grandes variabilités en forme, position et intensité. Les signatures atypiques de même type possèdent également les mêmes variabilités. Une signature liée au palier #4 est dépendante du régime N_2 et N_1 . Ainsi du fait de la variabilité des relations N_1/N_2 (Figure 1.5), chacune de ces signatures est différente. De plus, il est possible que ce ne soit pas la fréquence fondamentale de la signature inusuelle qui soit observable sur le spectrogramme mais une de ses harmoniques. Nous ne disposons pas dans notre base de données de plusieurs échantillons de tous les types possibles de signatures inusuelles afin de calibrer un modèle pour chacun d'entre eux.

Néanmoins, nous disposons de suffisamment de données sans anomalie afin d'apprendre les caractéristiques normales des patchs des spectrogrammes. La détection d'anomalies sur les patchs s'effectue alors en mesurant l'écart entre la donnée test et ce modèle normal. Cette procédure est associée aux approches de type détection d'anomalies, d'outliers, de nouveautés qui permettent d'effectuer des détections de manière automatique sans (ou avec très peu) de données atypiques.

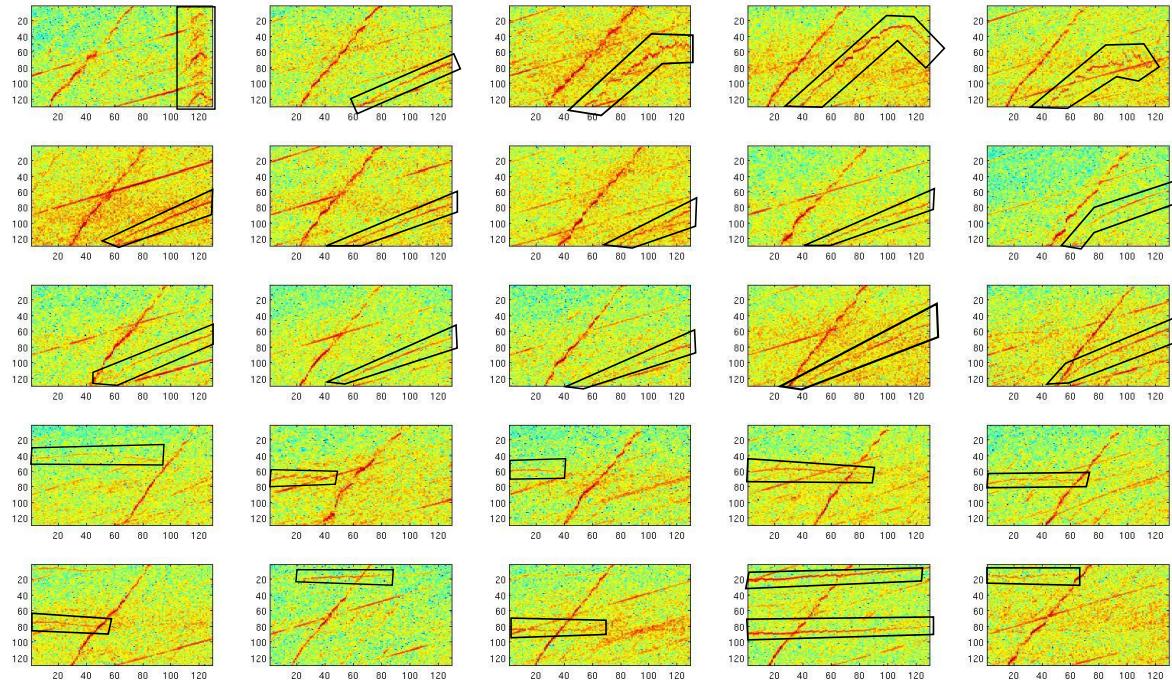


FIGURE 1.11 – Extraction du même patch des spectrogrammes de notre base de données avec encadrement des signatures inusuelles. Les types de signatures atypiques sur un même patch sont variés, certaines correspondent à des formes horizontales ou obliques, et d'autres ont des formes particulières. Les signatures inusuelles de même type (par exemple les 2 dernières lignes) sont également variables en intensité, en longueur et en position.

1.6 L'état de l'art de l'analyse vibratoire

1.6.1 L'état de l'art provenant de la littérature

Les vibrations sont étudiées depuis de nombreuses années, particulièrement dans le monde industriel, dans le but de détecter des anomalies ou de caractériser différentes pièces d'une machine [91]. Les différentes méthodes d'analyse vibratoire sont appliquées suivant la nature stationnaire ou non-stationnaire des signaux étudiés. Cette nature influe sur le domaine dans lequel les signaux sont représentés et étudiés [91, 117].

- Les signaux stationnaires
- Le domaine temporel
- Le domaine fréquentiel
- Les signaux non-stationnaires
- La cyclostationnarité
- le domaine temps-fréquence

Selon le domaine sélectionné, la résolution du signal dans ce dernier est définie à l'avance. D'après le principe d'incertitude d'Heisenberg, il est impossible d'obtenir de bonnes résolutions aussi bien dans le domaine fréquentiel que dans le domaine temporel. Il faut donc sélectionner le domaine de l'étude.

Le domaine temporel

Les vibrations correspondent à un signal échantillonné dans le temps, ce signal contient l'information vibratoire accessible depuis le capteur. Dans le cadre des vibrations des machines tournantes, ces signaux sont formés d'une composante périodique et d'une composante aléatoire. La moyenne synchrone est une technique couramment utilisée pour étudier ces signaux [65]. Elle permet d'extraire différentes sources du signal en considérant chaque cycle de la machine comme une réalisation. Dans [65], une moyenne synchrone angulaire est appliquée afin de soustraire du signal les sources déterministes liées au N_1 et au N_2 des moteurs d'avions. Ainsi seules les sources liées à aucun de ces régimes, telles les signatures atypiques, apparaissent dans le signal résiduel. Cependant cette approche ne peut être utilisée qu'en régime stationnaire.

Les modèles autorégressifs, tel que les modèles ARMA (autoregressive moving average), permettent également d'analyser les signaux temporels en détectant des fluctuations liées à un endommagement sur le signal. Ces méthodes peuvent être utilisées pour filtrer le signal vibratoire à partir d'un modèle calibré sur des signaux sans anomalie [115] ou pour donner une estimation sans anomalie de la suite du signal. Des filtres de Kalman ont également été utilisés dans [118] afin d'étudier des signaux vibratoires dans des conditions non stationnaires. Le RMS (Root Mean Square), le kurtosis, ainsi que les différents moments des signaux sont des indicateurs statistiques permettant de caractériser les signaux temporels.

L'Empirical Mode Decomposition (EMD) introduite dans [61] permet de séparer le signal en composantes presque orthogonales. Il s'agit d'une méthode itérative où chaque source correspond à la moyenne entre les enveloppes supérieure et inférieure du signal résiduel (les différentes sources découvertes retranchées du signal). Les sources constituent donc une base calibrée par le signal et non fixée à l'avance, ce qui est très avantageux pour un signal non-stationnaire [73]. Cette méthode possède cependant quelques défauts comme la superposition des modes et le manque de fondements théoriques.

Le domaine spectral

Le domaine spectral est fortement lié à la transformée de Fourier, qui permet de convertir un signal temporel en un signal fréquentiel. Cette transformée est applicable uniquement pour un signal stationnaire, ce qui n'est pas le cas de la majorité des signaux vibratoires issus du milieu industriel. D'autres outils ont donc été mis en place afin d'étudier ces signaux dans le domaine spectral. L'analyse cepstrale [45] permet également d'étudier les signaux vibratoires. Le cepstre consiste en la transformée de Fourier inverse du logarithme du spectre de puissance. Cependant, il est lui aussi applicable uniquement dans un cadre stationnaire.

Le kurtosis spectral [7] est un outil puissant permettant d'indiquer les composantes non-gaussiennes dans le signal et de les localiser dans le domaine fréquentiel. Le kurtosis est calculé pour chaque fréquence afin de déceler la présence de non-stationnarité cachée. Cette méthode

est assez similaire au spectre de puissance avec le moment d'ordre 2 remplacé par le moment d'ordre 4. Le kurtosis spectral est calculé à partir du STFT. Il est donc dépendant des mêmes paramètres que cette dernière. Le kurtogramme [9] permet de pallier ce problème en donnant une représentation du kurtosis spectrale en 2 dimensions de manière analogue au spectrogramme.

La cyclostationnarité

La cyclostationnarité est une méthode courante de caractérisation des signaux étudiée en particulier dans [8]. La cyclostationnarité concerne les signaux ayant une composante déterministe ainsi qu'une composante aléatoire qui est elle-même périodique comme les signaux vibratoires des machines tournantes. Les signaux cyclostationnaires ont donc leurs moments qui sont périodiques, un signal cyclostationnaire d'ordre k signifie que tous ses moments d'ordre 1 à k sont périodiques. La transformée de Fourier est alors appliquée sur les moments du signal afin de mettre en évidence des anomalies dans les systèmes étudiés.

L'enveloppe spectrale [92], qui correspond à une cyclostationnarité d'ordre 2, permet de suivre les réponses hautes fréquences des machines tournantes comme les engrenages et les roulements. Les chocs émis par ces pièces sont très brefs et l'énergie produite est également très faible et répartie sur une grande plage de fréquences. L'analyse spectrale traditionnelle ne permet pas de détecter les possibles défauts dans ces composants.

Le domaine temps-fréquence

La majorité des signaux vibratoires dans les systèmes mécaniques ne sont pas stationnaires par nature. Les représentations temps-fréquence sont donc destinées à étudier ces signaux et permettent une représentation des signaux en 3 dimensions : temps-fréquence-amplitude.

La STFT permet d'obtenir ce type de représentation ; l'hypothèse de stationnarité du signal est faite sur des temps très courts. La transformée de Fourier peut être appliquée sur ces fenêtres de signal. La concaténation des spectres ainsi obtenus produit un spectrogramme. Notre base de données est constituée de spectrogrammes sur lesquels nous cherchons à détecter tout type de signatures atypiques présentes. Cette représentation a déjà été utilisée afin de détecter des défauts à partir des vibrations des systèmes mécaniques comme les engrenages [113, 114, 52].

L'utilisation de la STFT implique une décomposition du signal dans la base de Fourier, donc dans une base sinusoïdale. Les bases d'ondelettes [80] peuvent apporter une représentation parcimonieuse d'un signal dans une base appropriée. Le signal est représenté en fonction du temps et d'un paramètre d'échelle. Les signaux vibratoires peuvent ainsi être représentés dans différentes bases d'ondelettes. Les ondelettes ont déjà été utilisées à de nombreuses reprises pour caractériser et mettre en évidence des anomalies sur les signaux vibratoires [116]. Il est également possible de représenter les signaux vibratoires dans des fonctions définies par des

ondelettes comme les bandelettes [81], curvelets [22], wedgelets [42]. Cela permet de caractériser des formes plus spécifiques et en plus grandes dimensions. La représentation du signal dans une base de Fourier ou d'ondelettes correspond à une représentation dans un dictionnaire dont les atomes sont fixés à l'avance et définis par des fonctions.

La transformation de Wigner-Ville [12] constituent un autre moyen de caractériser les signaux dans un domaine temps-fréquence. Il s'agit d'une opération bilinéaire où la représentation de la somme de signaux ne correspond pas à la somme des représentations mais fait intervenir des termes d'interférence entre le temps et les fréquences.

1.6.2 Les algorithmes d'analyse vibratoire de Safran Aircraft Engines

Algorithme de détection du palier#4

Safran Aircraft Engines a développé des algorithmes spécifiques pour la détection d'anomalies sur les spectrogrammes qui utilisent l'information physique des signatures vibratoires. Les signatures liées à des endommagements de roulements moteur sont les plus problématiques et les plus fréquentes. Ces signatures sont représentées dans les spectrogrammes par des raies dont les équations sont connues. Les raies inusuelles liées au palier#4 (roulement corrotatif) sont représentées par l'équation suivante dans le spectrogramme :

$$f = k_1 N_1 + k_2 N_2 \text{ avec } k_1 = -k_2 \quad (1.3)$$

L'algorithme 4 cherche à détecter spécifiquement les raies correspondant à ce type de signature. La méthode de détection consiste en la suppression des signatures prévisibles et de toutes les intensités faibles par un seuillage. Les coefficients de l'équation 1.3 sont calculés pour chaque paire de points restants. La détection est établie dans cet espace des coefficients en considérant les taux d'apparition des couples (k_1, k_2) . La raie inusuelle liée au palier#4 n'est pas supprimée par le filtrage, ainsi tous les points la composant restent présents et donnent les mêmes valeurs pour le couple (k_1, k_2) . Si les valeurs du couple correspondent à une signature de palier#4, que le taux d'apparition du couple et l'intensité maximale le long de la raie sont suffisamment grands, une alarme est déclenchée et le moteur est suspecté d'être anormal. Cet algorithme permet de bien détecter des anomalies de palier#4, mais aucun autre type d'anomalie. De plus si les anomalies sont d'intensités trop faibles, ces dernières sont supprimées lors de l'étape de prétraitement.

Algorithme 4 : DéTECTeur de signature palier#4

Données : Le spectrogramme S, le seuil s_1 d'apparition du couple, le seuil s_2 d'intensité maximale

Résultat : Indicateur de présence d'une signature atypique de type palier#4
Suppression des intensités faibles, des harmoniques liées aux arbres HP, BP et du RDS.

```

pour chaque paire de points non supprimés faire
    | Calcul du couple  $(k_1, k_2)$  de l'équation 1.3.
    | Incrémentation du compteur correspondant au couple  $(k_1, k_2)$  calculé
fin
si compteur  $\geq s_1$  et  $S(N_2, k_1(N_2 - N_1(N_2))) \geq s_2$  alors
    | Déclenchement d'une alarme
fin
```

Algorithme de détecteur de raies

Cet algorithme [52] estime un masque sur l'intégralité du spectrogramme qui est considéré comme l'ensemble de l'information normale présente sur le spectrogramme. Il est défini à partir d'un ensemble de spectrogrammes supposés normaux. Afin d'obtenir ce masque, les spectrogrammes sont dans un premier temps normalisés à partir de la méthode de Clifton et Tarassenko [33]. Deux masques sont déterminés et soustrait intégralement du spectrogramme. Le premier masque, paramétrique, correspond aux différentes harmoniques entières du N_1 et du N_2 présentes sur le spectrogramme test. Ces harmoniques sont calculées à partir de la transformée de Hough H [10]. Il s'agit d'un opérateur s'appliquant à des fonctions de $\mathbb{R}^2 \mapsto \mathbb{R}$ et permettant de détecter des formes en renseignant la famille des courbes paramétriques auxquelles elles appartiennent. Les harmoniques du N_1 et du N_2 appartiennent à la famille $\{\mathcal{C}_\alpha^j, j \in \{1, 2\}, \alpha \in \mathbb{N}\}$ des courbes linéaires en $N_j, j \in \{1, 2\}$ paramétrées par α

$$\mathcal{C}_\alpha^j = \{(x, \alpha N_j(x)), x \in [\min N_2, \max N_2]\}.$$

La transformée de Hough correspond à l'intégrale le long de la courbe. Dans le cas des spectrogrammes, la somme des intensités des points le long des courbes est prise en compte.

$$H : \mathcal{C}_\alpha^j \rightarrow \int_{\mathcal{C}_\alpha^j} S^i(x, \alpha N_j(x)) dx.$$

Pour toute valeur de α dont la transformée de Hough est supérieure à un seuil fixé arbitrairement, l'intégralité de la courbe correspondante est supprimée du spectrogramme.

Le second masque, statistique, correspond à l'apprentissage de la présence ou non d'information vibratoire sur des patchs du spectrogramme de petites tailles. Il s'agit d'imagettes de taille 5×3 à partir de méthodes d'analyse discriminante ou de SVM [49]. Le classifieur appris est appliqué sur l'ensemble des imagettes des spectrogrammes utilisés pour la calibration du masque. Ce dernier est binaire et alloue la valeur 1 à l'ensemble des points dont les imagettes possédant

ce point en leurs centres ont été classifiées plusieurs fois comme contenant de l'information vibratoire pertinente dans la base de données. Ce masque est également soustrait du spectrogramme. L'anomalie est déclarée par rapport au nombre de points restants après la suppression par les 2 masques.

Cette méthode présente les avantages de tenir compte du décalage des raies N_1 par le masque paramétrique, de pouvoir considérer toutes les raies présentes dans le spectrogramme et d'être établie comme une approche de détection de nouveautés ne nécessitant que des spectrogrammes normaux pour la calibration du modèle. Cependant, elle ne tient pas du tout compte de l'intensité vibratoire. Les raies vibratoires sont considérées comme des variables binaires de présence. De plus, cet algorithme est appliqué sur le spectrogramme complet. Or comme nous l'avons énoncé précédemment, plusieurs signatures inusuelles sont présentes sur les spectrogrammes normaux également. Ainsi, plus la base d'apprentissage est grande, plus le masque statistique risque d'apprendre de l'information inusuelle également. Si cette base est trop petite, une grande quantité d'information normale risque de ne pas être prise en compte.

L'application de la transformée de Hough pour détecter les raies paramétriques est intéressante. Cependant il serait plus pertinent d'apprendre le masque statistique sur de patchs sur lesquels nous pouvons donner la présence ou non de signatures inusuelles. Une autre amélioration serait de tenir compte de l'intensité et de la continuité des points vibratoires restants. Les différentes méthodes énoncées cherchent à détecter des signatures liées à des endommagements, donc des signatures d'intensités importantes et possédant plusieurs harmoniques dans le signal. Dans cette thèse, nous cherchons à détecter toute signature inusuelle présente sur les spectrogrammes, indépendamment du fait qu'elles correspondent à un endommagement. Les signatures à détecter correspondent donc à des signatures en faible dimension et souvent d'intensités faibles.

1.7 Une première approche de détection

Cette partie contient différentes approches afin de détecter les moteurs atypiques sur un patch particulier de la subdivision \mathcal{K}^{128} . Nous considérons donc notre jeu de données comme l'ensemble du même patch sur les différents spectrogrammes.

$$\{Z_{\mathcal{K}_j^{128}}^i\}_{i=1 \dots n}$$

Pour chacun des patchs, nous disposons du label du patch $Y_{Z_{\mathcal{K}_j}}^i$:

$$Y_{Z_{\mathcal{K}_j}}^i = \begin{cases} 1 & \text{si } \exists k \text{ tel que } \text{card}(\text{zones}_{ano}^i(k) \cap \mathcal{K}_j^{128}) \neq 0 \\ 0 & \text{sinon} \end{cases} \quad (1.4)$$

$\text{zones}_{ano}^i(k)$ correspond à la k^{ieme} zone atypique extraite dans la base de données sur le spectrogramme du moteur i . Nous cherchons, avec les méthodes présentées ci-dessous, à discriminer les patchs inusuels (labélisés 1) par rapport aux patchs normaux (labélisés 0).

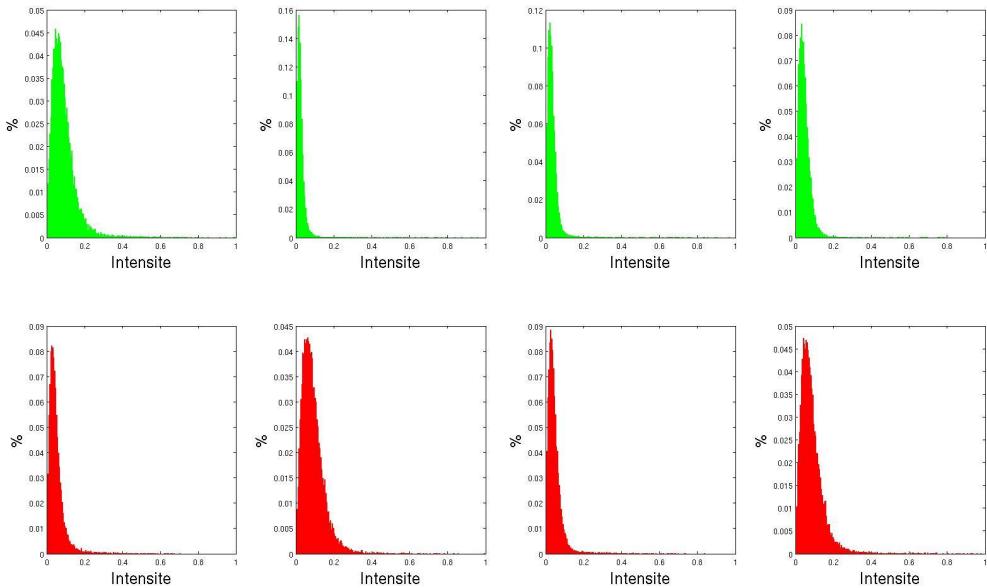


FIGURE 1.12 – Histogrammes des intensités vibratoires d'un patch spécifique pour différents moteurs ayant des spectrogrammes normaux (partie supérieure) et atypiques (partie inférieure) sur ce patch.

1.7.1 Représentation des patchs par leurs histogrammes d'intensités vibratoires

Les patchs $\{Z_{\mathcal{K}_j^{128}}^i\}_{i=1 \dots n}$ peuvent être considérés comme différentes réalisations d'une même donnée appartenant à $\mathbb{R}_+^{128^2}$. Les histogrammes des patchs normaux doivent donc être très proches les uns des autres. Sous la forme d'histogramme d'intensités vibratoires, la localisation des raies est perdue et ainsi seule la présence ou non d'une raie est déterminante. Les raies inusuelles entraînent un nombre de points à intensité élevé plus important que pour les spectrogrammes normaux, les histogrammes devraient donc avoir des queues de distribution différentes.

Afin de pallier les différences d'intensités vibratoires sur les mêmes patchs des spectrogrammes, les intensités vibratoires du patch considéré ont été normalisées par l'intensité maximale sur ce même patch. Ainsi, tous les points des patchs appartiennent à l'intervalle $[0, 1]$, nous notons $\tilde{Z}_{\mathcal{K}_j^{128}}^i$ les patchs normalisés.

$$\tilde{Z}_{\mathcal{K}_j^{128}}^i = \frac{Z_{\mathcal{K}_j^{128}}^i}{\max Z_{\mathcal{K}_j^{128}}^i} \quad (1.5)$$

Les histogrammes correspondent à une subdivision de l'intervalle $[0, 1]$ en sous-intervalles de taille 0.005, les histogrammes sont donc alors des représentations du patch en dimension 200. La figure 1.12 illustre les différents histogrammes obtenus sur des patchs normaux (ligne supérieure) et atypiques (ligne inférieure). Nous pouvons remarquer une variabilité aussi bien pour

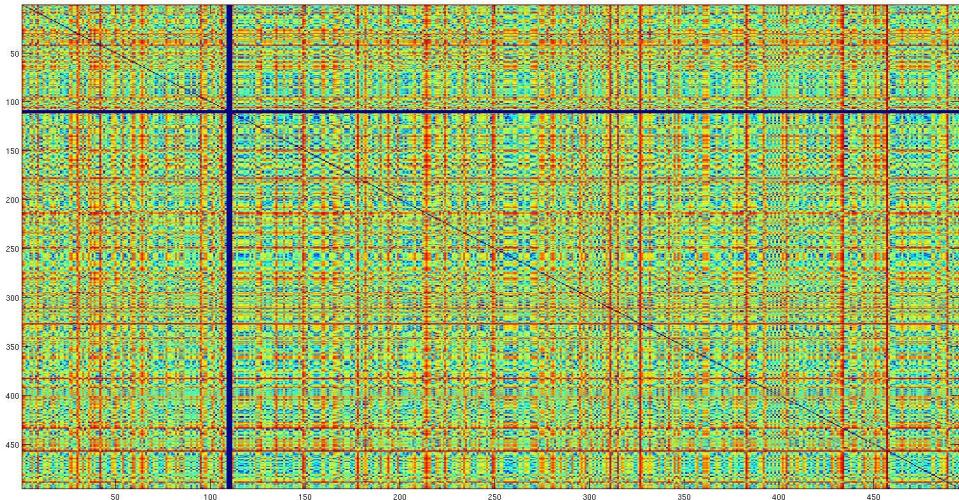


FIGURE 1.13 – Distance entre les histogrammes des mêmes patchs pour différents spectrogrammes. Le premier quadrant (partie supérieure gauche) correspond à la distance entre les patchs normaux, le dernier quadrant (partie inférieure droite) à la distance entre les patchs atypiques, les deux autres à la distance entre les patchs normaux et atypiques. La matrice obtenue n'est pas diagonale par bloc. Cela montre l'inefficacité de la méthode pour discriminer les patchs atypiques des patchs normaux.

les histogrammes des patchs normaux et inusuels, mais également une certaine proximité entre ces mêmes histogrammes. La détection d'anomalies s'effectue à partir de la distance L_2 de ces représentations par histogramme. La figure 1.13 représente la matrice des distances entre les histogrammes des même patchs des différents moteurs de la base de données. Les premiers éléments de la matrice (premier quadrant : premières lignes et colonnes) correspondent aux patchs normaux, les suivants (quatrième quadrant : les lignes et colonnes suivantes) aux patchs inusuels, chaque point de la matrice donne la distance entre les patchs des colonnes et lignes correspondantes. Nous n'observons pas de structure diagonale par bloc dans la matrice des distances permettant de discriminer les patchs normaux des patchs inusuels. La représentation des patchs par leurs histogrammes d'intensités vibrations n'est donc pas un indicateur pertinent pour la détection d'anomalies sur tout un patch.

Cette première étude illustre les problématiques rencontrées dans l'étude des spectrogrammes. Les signatures inusuelles se retrouvent noyées par l'information normale. Les points inusuels consistent en un faible nombre de points sur le patch n'influençant pas suffisamment la distance L_2 entre les histogrammes. Les points atypiques sur le patch ne sont pas les points de plus fortes intensités, les vibrations normales étant de plus forte amplitudes. Les points atypiques possèdent de fortes amplitudes vibratoires par rapport aux points de mêmes coordonnées en fréquence et régime sur les spectrogrammes normaux. Cependant cette représentation en histogramme ne tient pas compte de l'information de position noyant les points inusuels. De plus, les signatures normales des spectrogrammes possèdent également une grande variabilité en présence des raies, position et intensité.

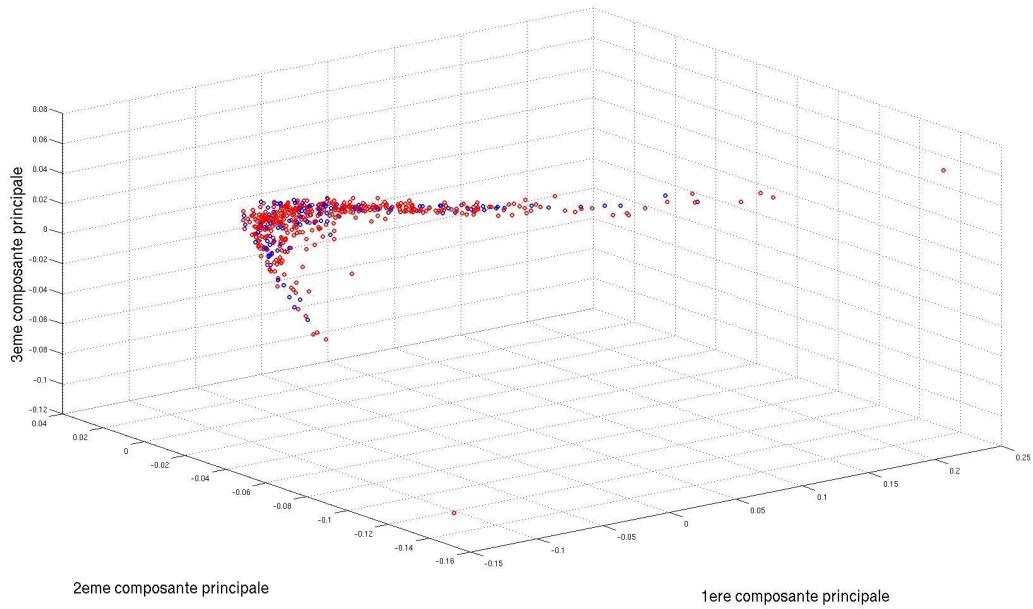


FIGURE 1.14 – Projection des histogrammes de représentation sur les 3 premières composantes principales de la ACP. Les points bleus et rouges correspondent respectivement aux patchs normaux et inusuels.

1.7.2 Représentation des histogrammes dans un espace réduit

La distance L_2 peut être assimilée à une moyenne sur les éléments de l'histogramme noyant les signatures inusuelles. Il est donc plus pertinent de considérer les différents éléments de l'histogramme comme une variable. Chaque patch est donc caractérisé par un vecteur de taille 200. Nous projetons ce vecteur dans un espace réduit maximisant la variance entre ces indicateurs à partir de l'Analyse en Composantes Principales (ACP). Les différentes données sont projetées dans l'espace engendré par les 3 premières composantes principales (Figure 1.14). Les patchs normaux sont représentés en bleu et les patchs atypiques en rouge. La figure 1.14 montre que les indicateurs issus de l'histogramme ne sont pas gaussiens. Les 3 premiers composantes principales ne permettent pas la discrimination des patchs normaux des patchs inusuels. Cela signifie que la variabilité de l'information normale des patchs est plus importante que la variabilité apporté par les signatures inusuelles. Cela montre une nouvelle fois que les signatures inusuelles en très faible dimension sont noyées par de l'information normale. Il est donc nécessaire de caractériser cette information normale afin de faire apparaître les signatures inusuelles.

1.8 Conclusions

Nous disposons d'une base de données de spectrogrammes vibratoires de moteurs d'avions échantillonnés en régime N_2 pour les études réalisées dans cette thèse. Cette base de données est fortement déséquilibrée avec un unique moteur déclaré comme contenant un endommagement.

Il est important de souligner qu'un moteur déclaré sans anomalie peut contenir des signatures inusuelles dans les données. Les spectrogrammes dont nous disposons contiennent des signatures inusuelles cataloguées comme sans gravité par les experts de Safran Aircraft Engines. Il s'agit de ces signatures, parfois d'intensités très faibles, que nous cherchons à détecter dans nos études. Les signatures inusuelles correspondent à des intensités vibratoires plus importantes sur des fréquences f et régimes N_2 non normales.

Dans un premier temps, nous avons récupéré les annotations d'experts afin de construire une base de données numérique de spectrogrammes contenant des zones labélisées comme normales ou atypiques. Nous disposons ainsi d'une base de données de 493 spectrogrammes annotés. Une analyse globale des spectrogrammes n'étant pas pertinente, nous avons donc décidé de subdiviser le spectrogramme en patchs carrés de taille 128 sans recouvrement et de les étudier indépendamment les uns des autres. Un modèle est donc défini pour chacun des patchs. Cette démarche permet d'avoir une meilleure mise en évidence des signatures inusuelles et une labélisation de chaque patch à partir de la base de données construite.

Les signatures inusuelles sont très variées en forme, en intensité et en position et le nombre de spectrogrammes ayant des signatures inusuelles est très faible au niveau de certains patchs. Ces deux effets entraînent l'impossibilité de mettre en place des modèles de données atypiques et donc d'utiliser des méthodes supervisées de classification. Il est donc indispensable que les algorithmes mis en place ainsi que les représentations tiennent compte de ce déséquilibre et de la structure normale des patchs. Les méthodes développées dans cette thèse sont donc principalement portées sur des approches de type one-class de détection de nouveautés.

Chapitre 2

La détection de nouveautés

2.1 Définition

La détection de nouveautés [90] (ou novelty detection) constitue une branche du machine learning se situant dans un cadre non supervisé. Elle est appliquée lorsque la base de données contient un label fortement majoritaire (souvent considéré comme normal) et un label minoritaire ou absent (pouvant être atypique). Ce type d'approche est défini comme la reconnaissance des données différant du comportement normal issu des données d'apprentissage [90]. La détection de nouveautés possède l'avantage de ne pas dépendre de la connaissance apriori ou de la présence de données atypiques.

La détection de nouveautés est pertinente lorsque l'apprentissage d'un modèle lié au label minoritaire n'est pas envisageable et s'apparente au problème de type one-class. Le principe consiste à construire un modèle de normalité à partir des données normales majoritairement présentes. Il s'agit de l'étape de caractérisation de la normalité. Des données de validation, non utilisées pour définir le modèle, sont comparées au modèle de normalité afin de définir un score et un seuil de nouveauté. Le score de nouveauté est appliqué à chaque donnée test. Plus ce score est élevé, plus la donnée peut être considérée comme n'étant pas issue de la même distribution que les données normales. Ce score est comparé à un seuil afin de classifier la donnée comme nouvelle ou non. Une description du processus est donnée en figure 2.1. Nos algorithmes correspondent à ce type d'approche. Les modèles mis en place doivent permettre la généralisation des caractéristiques normales des données tout en évitant un surapprentissage de celles-ci.

La détection de nouveautés s'apparente à la détection d'anomalies [26] et la détection d'outliers [25, 60]. La détection de nouveautés consiste à reconnaître ce qui n'est pas observé dans la base de données normales. Les méthodes de détection d'outliers consistent à trouver les données ayant un comportement différent de celui attendu [25]. La détection d'anomalies cherche à mettre en évidence dans les données un fonctionnement anormal du système résultant ou pouvant entraîner des endommagements. Sa définition dans [26] est la même que celle donnée pour la

détection d'outliers dans [25]. La base de données normales est considérée comme caractérisant entièrement le comportement nominal du système et toute donnée s'en écartant provient d'une irrégularité ou d'un nouveau comportement du système. Ces approches ont pour but de détecter des patterns rares dans les données sans a priori sur ces dernières étant donné leur absence ou faible nombre dans la base de données.

2.2 État de l'art de la détection de nouveautés

Il existe différents états de l'art assez complets sur ces différentes approches [90, 26, 25, 60, 83, 84]. Nous donnons une brève description et intuition des différentes approches utilisées pour la détection de nouveautés. Nous renvoyons à ces articles et aux différentes références associées pour plus de précisions sur les différentes méthodes.

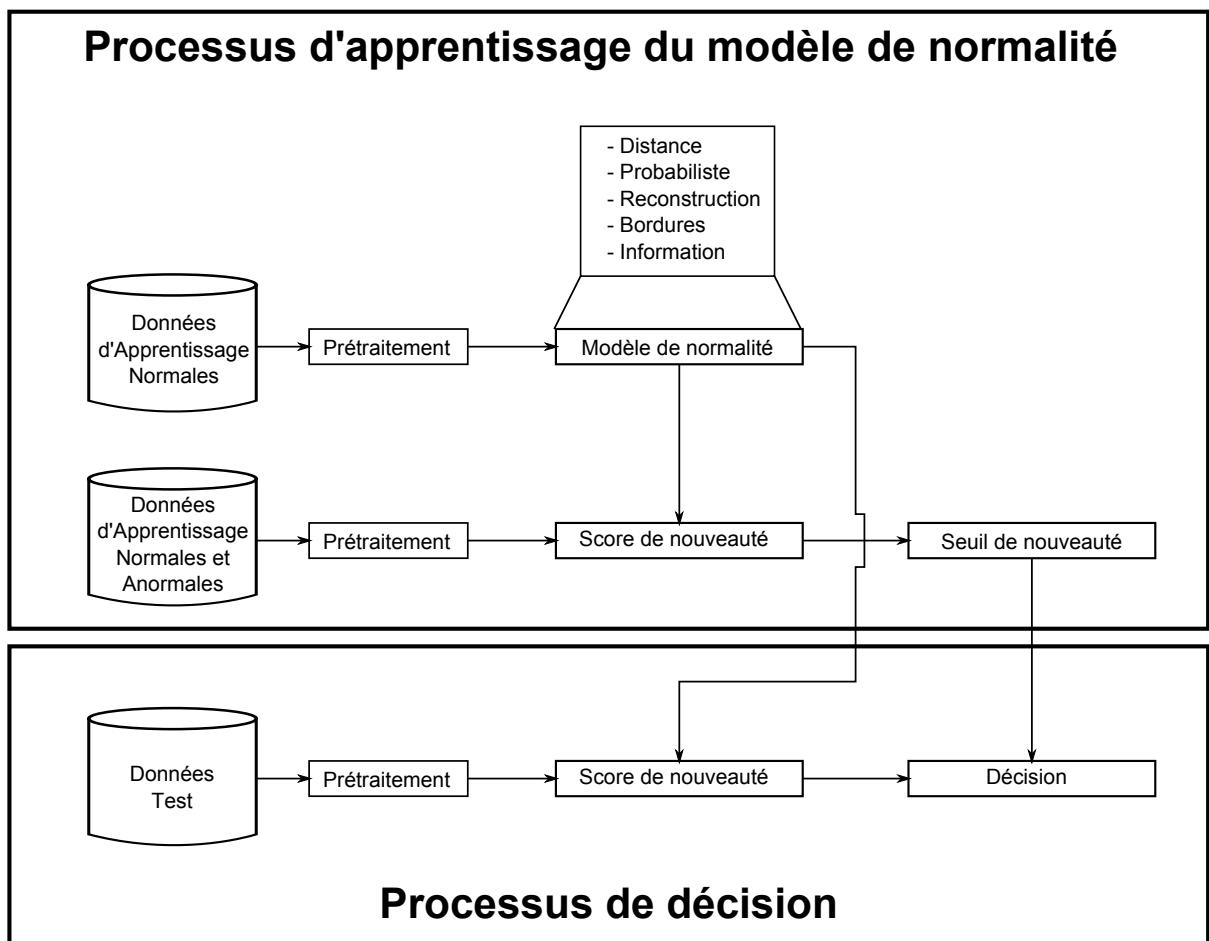


FIGURE 2.1 – Processus de détection de nouveautés/anomalies. La partie supérieure concerne l'apprentissage du modèle de normalité et la définition du seuil de détection à partir d'ensembles disjoints de données normales uniquement pour l'apprentissage du modèle, et de données normales et atypiques pour la définition du seuil de nouveauté. La partie inférieure porte sur la détection des données inconnues du système.

Différentes méthodes de détection de nouveautés/anomalies/outliers permettent d'étudier et de classifier des ensembles de données dont le label atypique est très faiblement représenté. Ces méthodes passent toutes par la caractérisation des données normales, le calcul d'une mesure de nouveauté et la comparaison à un seuil. Ces techniques peuvent être répertoriées en 5 classes distinctes [90] :

- les approches probabilistes,
- les approches basées sur les distances,
- les approches basées sur la reconstruction de la donnée,
- les approches basées sur la caractérisation des limites des données normales,
- les approches basées sur la théorie de l'information.

Le choix d'une méthode par rapport à une autre est effectué selon les caractéristiques des données comme la dimension ou la structure du domaine des données normales.

2.2.1 Les approches probabilistes

Ces approches estiment la distribution sous-jacente des données normales, définissant ainsi un modèle de normalité. La distribution des données nominales n'est généralement pas connue. Elle peut alors être estimée à partir de mélanges de gaussiennes [15]. Il s'agit là d'une méthode paramétrique dont les paramètres principaux sont le nombre de gaussiennes du mélange et leurs caractéristiques (moyenne et covariance). Chaque gaussienne correspond à un comportement normal. Les paramètres du modèle sont estimés à partir du maximum de vraisemblance via l'algorithme Expectation-Maximisation (EM). Une seconde approche pour estimer la distribution sous-jacente est l'estimation de la densité par noyau [49]. Cette méthode non-paramétrique consiste en l'application d'un noyau probabiliste au niveau de chaque donnée d'apprentissage normale. Une explication plus détaillée de cette approche est donnée dans la section 5.3. Le principal paramètre de cette approche est l'échelle du noyau considérée. Si elle est trop importante, la distribution est fortement lissée. Si elle est trop faible, la distribution est trop fortement liée aux données d'apprentissage (surapprentissage) et ne généralise pas le modèle de normalité.

La nouveauté est détectée par la comparaison de la donnée test à la distribution du modèle de normalité. Dans un cas unimodal, c'est-à-dire lorsque la distribution possède un unique mode, les nouveautés se trouvent au niveau des queues de distribution et sont donc détectées en fixant un seuil sur cette distribution. La théorie des valeurs extrêmes [37] est une des méthodes permettant de fixer un seuil de détection, elle permet de modéliser la distribution du maximum d'un échantillon de taille fixe. D'après le théorème de Fisher-Tippett [48], dépendant de la loi des données, la distribution des valeurs extrêmes correspond à une loi de Gumbel, Fréchet ou Weibull. La caractérisation de ce maximum permet alors de définir le seuil de détection. Dans un cadre multi-modal, les nouveautés ne sont plus caractérisées uniquement par les extrêmes de la distribution, mais aussi par les points de faibles densités entre les différents modes. Le seuil de détection peut alors être défini par une valeur de densité en dessous de laquelle les points sont considérés comme improbables donc nouveaux [32].

Ces approches permettent de définir la normalité à travers la distribution des données et de détecter la nouveauté à partir d'un seuil sur la densité des données. Ces approches sont dépendantes du nombre de données utilisées pour estimer la distribution. Cependant, en grande dimension l'apprentissage de la densité demande un nombre très important de données pour caractériser la distribution au niveau de toutes les régions de l'espace. Ainsi plus la dimension est grande, plus le nombre de données nécessaires pour caractériser tout l'espace est important. Il s'agit du "fléau de la dimension". Ces approches ne sont donc pas adaptées aux problématiques en grande dimension.

2.2.2 Les approches basées sur les distances

Elles consistent en la mesure de la distance entre une donnée et ses homologues normales. Plus la distance est grande, plus cette donnée peut être considérée comme nouvelle. Il existe deux grandes catégories d'approches utilisant les distances. La première considère les plus proches voisins des données tests comme les k plus proches voisins (k -NN) [49]. Elle permet de classifier les données comme nouvelles si elles se trouvent éloignées des données normales. Cette méthode est paramétrée par le nombre k de voisins à prendre en compte et la distance considérée. Le temps de calcul est généralement long pour de grosses bases de données. Une seconde méthode basée sur les voisins est le Local Outlier Factor (LOF) [17]. Elle compare la densité de voisins autour des données étudiées dans un certain rayon de voisinage (constituant le principal paramètre de l'approche) avec cette même densité calculée pour leurs voisins. Une densité de voisins plus faible signifie une isolation de la donnée et donc son caractère nouveau. La seconde catégorie d'approches basées sur les distances correspond au clustering des données dont la méthode la plus répandue est le k -means [49], k correspondant cette fois-ci au nombre de clusters. La détection de nouveautés s'effectue dans ce cadre par rapport à la distance au plus proche cluster estimé sur les données normales. Il existe plusieurs choix de distances possibles avec des propriétés différentes constituant un paramètre supplémentaire de ces approches.

En grande dimension, la notion de distance est mal établie, ces approches ne sont donc pas efficaces. De plus, la mise en place de ces approches nécessitent un très grand nombre de données pour caractériser correctement l'espace des données normales et pour éviter les fausses détections.

2.2.3 Les approches basées sur la reconstruction des données

Ces approches définissent un modèle caractérisant la normalité au sein des données à partir duquel il est possible de donner une estimation normale de la donnée test. La détection s'effectue alors sur le résidu de la reconstruction. Dans le cas d'une donnée normale, la reconstruction de cette dernière est proche de celle-ci et donc entraîne des résidus de reconstruction faibles. Pour une donnée contenant des nouveautés ou des anomalies, les résidus de la reconstruction sont plus importants. Pour ce type d'approche, l'élément déterminant est le nouvel espace de représentation, caractérisant la normalité des données et dans lequel les données sont représen-

tées [13]. Cet espace correspond à des dictionnaires pouvant être appris sur les données ou à des réseaux de neurones [68]. Les méthodes de représentation par dictionnaires décomposent la donnée dans un système linéaire avec des contraintes. Dans la suite nous donnons une explication plus détaillée de la représentation par dictionnaire. L'ACP [49] est la méthode la plus classique de représentation des données dans un dictionnaire permettant de maximiser la variance des données normales. La reconstruction est effectuée à partir des premières composantes principales modélisant la variabilité normale des données. Dans le cadre de la détection de nouveautés, il est également possible de projeter les données sur les dernières composantes principales n'ayant que peu d'information normale et détectant ainsi des outliers. Le principal paramètre de ce type d'approche est la nouvelle dimension dans laquelle les données sont représentées. Dépendant de la nouvelle dimension, ce type d'approche ne nécessite pas nécessairement un très grand nombre de données.

Les réseaux de neurones [68] ont été particulièrement utilisés pour des tâches de classification supervisée mais également de détection de nouveautés. Les Replicator Neural Network (RNN) [53] et les autoencodeurs [109] sont des réseaux de neurones apprenant des sous-espaces permettant la reconstruction de la donnée d'entrée. Les réseaux sont donc appris sur des données normales afin de caractériser cet espace de normalité, la détection de nouveautés s'effectue également sur les résidus de la reconstruction. Les principaux paramètres de ces approches sont le pas du gradient mais également la structure et la composition des couches du réseau de neurones. La construction de ces réseaux nécessitent un très grand nombre de données pour éviter le surapprentissage.

Ces approches fonctionnent sur des données en grande dimension telles que des images. Les espaces dans lesquelles les données sont projetées permettent d'apprendre la structure et le comportement normal des données. Les paramètres de ces différentes approches correspondent aux paramètres des espaces dans lesquels les données sont projetées comme la nouvelle dimension ou la structure du réseau.

2.2.4 Les approches basées sur la caractérisation des limites des données normales

Ces approches caractérisent les bordures de la normalité dans l'espace des données. Dans ce sens, elles ne tiennent pas compte de l'ensemble des données mais uniquement de celles se trouvant proches de ces bordures. La détection de nouveautés correspond alors à la comparaison de la donnée aux limites du domaine normal. Ces méthodes sont apparentées aux support vector machines (SVM) [49]. Un one-class SVM [99] permet de trouver un hyperplan dans un espace transformé des données d'apprentissage normales définissant de vastes marges par rapport à l'origine. Les principaux paramètres de ces approches sont le nombre de points définissant les bordures et un pourcentage de points pouvant être mal classifiés pour éviter le surapprentissage.

Le support vector data description (SVDD) [107] définit un domaine caractérisé par un centre et un rayon autour des données normales minimisant le volume de cette hypersphère. Cette

caractérisation s'effectue également dans un espace transformé. La nouveauté est détectée par l'appartenance ou la non-appartenance de la donnée à l'hypersphère. Les principaux paramètres sont similaires à ceux du one-class SVM.

Il existe d'autres approches caractérisant les bordures de l'espace de normalité non liées au SVM comme les one-class random forests [38]. Ces approches sont également intéressantes sur des données en grande dimension car seuls les points aux bordures sont étudiés. Elles requièrent tout de même un grand nombre de points pour la calibration du modèle.

2.2.5 Les approches basées sur la théorie de l'information

Ces approches proviennent de l'intuition que la présence d'une donnée nouvelle ou atypique au sein d'un ensemble de données normales entraîne un changement de la quantité d'information estimée sur toutes les données. La mesure de l'information [15] permet alors de détecter des nouveautés en calculant l'entropie (possible mesure de l'information) pour des sous-ensembles des données. Lorsque l'entropie diminue, cela signifie que la donnée retirée est différente du reste [56].

Ces approches de théorie de l'information ne nécessitent aucun a priori sur les données, seule la mesure de l'information des données est considérée. Cependant il est indispensable de définir la mesure considérée pour l'information. De plus la détection s'effectue uniquement lorsque plusieurs observations sont atypiques dans le jeu de données. Dans le cas contraire, le retrait d'une seule observation peut ne pas être suffisant pour entraîner une modification significative de la mesure d'information. De plus, ces mesures passent souvent par la définition d'une densité de probabilité. Ce type d'approche n'est donc pas adapté en grande dimension.

2.3 La détection de nouveautés appliquée aux données vibratoires

2.3.1 Application aux données temporelles et fréquentielles

Les idées de détection de nouveautés et d'anomalies sont courantes en traitement du signal. Les signaux récupérés sur des systèmes industriels complexes sont en grande majorité des données considérées comme normales. La complexité des systèmes rend impossible de considérer toutes les signatures atypiques possibles. Une pratique standard du traitement du signal consiste à calculer le spectre à partir des données vibratoires temporelles (lorsque ces dernières sont stationnaires) et de comparer le pics fréquentiels obtenus avec ceux issus de comportements normaux. Il s'agit bien d'une approche de détection de nouveautés où les irrégularités sont caractérisées par l'apparition de pics inconnus. La mesure de nouveauté peut alors être obtenue par un calcul résiduel ou par une matrice de correspondance des fréquences d'apparition des différents pics. Les signaux temporels ou fréquentiels sur lesquels les méthodes de détection de nouveautés sont appliquées

sont généralement stationnaires.

Dans [55], une approche de type peak-over-threshold¹(POT) (approche liée aux valeurs extrêmes) est étudiée pour la détection de défauts de roulements à partir de mesures vibratoires sur des périodogrammes. Il s'agit de la transformée de Fourier discrète appliquée à des signaux temporels en régime stationnaire. Les maximums des périodogrammes sans signature atypique sont calculés pour chaque fréquence, ces derniers sont comparés à d'autres périodogrammes de la base d'apprentissage. Les points supérieurs aux maximums calculés sur les périodogrammes sont modélisés par une loi de Pareto sur laquelle le seuil de détection est déterminé.

Une approche de type one-class SVM est utilisée dans [23] pour la détection d'anomalies sur des données vibratoires temporelles. Différents indicateurs du signal temporel sont calculés et projetés dans un espace de dimension réduite sur lequel le one-class SVM est appris.

Une comparaison de différentes approches de détection de nouveautés a été réalisée dans [111] à partir de différents indicateurs classiques des signaux temporels et en ordre. Les différentes approches comparées sont l'ACP, l'estimation de densité par noyau gaussien, les k-means, les k plus proches voisins, les one-class SVM et les autoencodeurs. Les résultats montrent un comportement varié des différentes méthodes suivant le type d'anomalie présent dans les données.

Ces méthodes sont établies dans le domaine temporel ou angulaire du signal en supposant la stationnarité de ce dernier. Notre problématique consiste à étudier des représentations temps-fréquence de ces signaux permettant de tenir compte du caractère non-stationnaire.

2.3.2 Application sur les harmoniques du signal

Les études citées ci-dessus sont effectuées sur des signaux en régime stationnaire sur lesquels la transformée de Fourier peut être appliquée. Cependant dans les signaux non-issus de banc d'essai, la stationnarité est rarement vérifiée. Des méthodes classiques comme la transformée de Fourier ou des indicateurs sur les signaux temporels ne sont plus pertinents. Il est tout de même possible de construire des représentations temps-fréquence afin d'étudier ces signaux à partir de la STFT, des transformées en ondelettes,... Cela permet de prendre en compte l'aspect fréquentiel du signal (donc les éléments périodiques), mais aussi la non-stationnarité à travers l'aspect temporel. Il est également possible d'étudier juste quelques ordres ou harmoniques spécifiques du signal, c'est sur les premières harmoniques qu'apparaissent certains défauts comme les problèmes d'équilibrage.

Dans [31, 34], des méthodes de détection de nouveautés basées sur une estimation de la distribution des valeurs extrêmes, à partir d'un mélange de gaussiennes, ont été étudiées pour la détection d'anomalies de moteurs d'avions dans un cadre multivarié et multimodal. Les valeurs extrêmes dans ce cadre sont définies comme les valeurs les moins probables, c'est-à-dire celles dont les densités de probabilité sont les plus faibles. Les valeurs extrêmes sont calculées sur banc

1. méthode des excès

d'essai [31] pour les premiers ordres des spectrogrammes vibratoires normaux de chaque arbre du moteur, et en vol [34] à partir des points de plus fortes intensités.

Une approche de détection de nouveautés à partir du one-class SVM a été développée dans [54]. Les intensités vibratoires d'ordres prédéfinis des spectrogrammes normaux sont récupérées afin d'apprendre le domaine des données saines.

Notre étude consiste à détecter toute trace des signatures vibratoires inusuelles sur les spectrogrammes. Il est donc indispensable de définir des modèles sur les spectrogrammes et non pas sur quelques ordres de ce dernier.

2.3.3 Application aux spectrogrammes

Un masque normal des spectrogrammes [52] a été présenté dans le chapitre 1 permettant la suppression de l'information normale des spectrogrammes et de comptabiliser les éléments restants. Cette approche s'apparente à des méthodes de détection d'anomalies basées sur une distance correspondant à la concordance de l'information vibratoire présente entre les spectrogrammes normaux et le spectrogramme étudié.

Une approche similaire a été développée dans [33]. Les spectrogrammes ont été subdivisées en sous-zones sur lesquelles une normalisation est effectuée en modélisant le bruit par une loi Gamma afin de l'homogénéiser. Cette normalisation est effectuée intra-zone et entraîne des artefacts sur les bords des sous-zones définies. La distribution des valeurs extrêmes est estimée pour chaque sous-zone. Le nombre de points dépassant le seuil de détection défini à partir de la distribution estimée est comptabilisé pour chaque sous-zone des spectrogrammes normaux. L'approche est réitérée pour chaque spectrogramme et le nombre de points dépassant les seuils de détections sont comparés. Une anomalie est déclarée lorsqu'une des zones du spectrogramme étudié possède significativement plus de points détectés que ses homologues des spectrogrammes normaux.

Dans [63], une référence (définie par la moyenne et la variance) est apprise pour tous les points des spectrogrammes en ordre à partir de données normales. Les spectrogrammes tests sont alors comparés à cette référence pour déterminer les points anormaux. Afin que les points soient considérés comme anormaux, il est nécessaire qu'ils définissent une région continue avec un nombre de points et une surface suffisante. Pour que le spectrogramme soit déclaré comme anormal, la surface totale doit être supérieure à un seuil. Il est également possible de récupérer les raies le long de certains ordres particuliers en collectant les voisinages des maxima locaux au niveau des points détectés [64].

Notre travail est complémentaire à ces différentes approches. Nous cherchons à détecter finement toutes signatures atypiques sur les spectrogrammes à partir de notre base de données construite, c'est-à-dire déterminer l'ensemble des points composant les signatures inusuelles.

2.4 Caractérisation de la base de données de spectrogrammes construite

2.4.1 Répartition des données en sous-ensembles

La figure 2.1 présentait le besoin de plusieurs bases de données disjointes pour mettre en place et tester nos modèles :

- une base d'**apprentissage** comportant uniquement des données normales sans signature inusuelle pour mettre en place le modèle de normalité (Ω_{App}) ;
- une base de **validation** contenant des données avec et sans signatures inusuelles pour calibrer le seuil de détection et les paramètres optimaux du modèle par cross-validation (Ω_{Val}) ;
- une base de **test** pour présenter les résultats et évaluer les performances de nos approches, (Ω_{Test}).

Les données de la base d'apprentissage et des données normales de validation forment un même ensemble dans lequel nous sélectionnons aléatoirement la base d'apprentissage pour définir le modèle et les données normales de la base de validation. Les données atypiques de la base de validation restent identiques, nous pouvons en sélectionner un sous-ensemble pour nos études. La base de test reste la même pour toutes les différentes approches afin de pouvoir les comparer.

Nous avons présenté (section 1.4) la base de données (\mathcal{B}_0) construite et indexée à partir de l'extraction automatique des zones atypiques sur les données textuelles d'annotations manuelles des experts. Nous avons également présenté nos propres annotations de quelques points en différentes classes (\mathcal{B}_1) sur quelques spectrogrammes (section 1.5.3) afin d'obtenir une vérité terrain plus fine que sur l'échelle d'un patch. Toutes les données se trouvant dans Ω_{Test} correspondent à des spectrogrammes annotés sur quelques points (donc $\Omega_{Test} \subsetneq \mathcal{B}_1$). Nous souhaitons nous servir d'eux pour donner des résultats numériques. Les spectrogrammes annotés ponctuellement mais ne faisant pas partie de Ω_{Test} font partie de la base de validation Ω_{Val} afin de calibrer les métaparamètres des différentes approches comme les seuils de détection. Les moteurs de Ω_{Test} restent les mêmes tout au long de l'étude.

La répartition des données au niveau de chaque patch commence par une classification de ces derniers suivant qu'ils sont normaux ou atypiques. Chaque patch $\{Z_{\mathcal{K}_j}\}_{j=1, \dots, \text{card}(\mathcal{K})}$ est comparé à la base de données en vérifiant l'intersection entre le patch du spectrogramme étudié et les zones atypiques extraites de ce même spectrogramme. Les patchs dont la surface d'intersection est supérieure à un seuil sont considérés comme atypiques et sont envoyés dans la base de validation Ω_{Val}^j du patch j correspondant. Les patchs dont la surface d'intersection est inférieure à un seuil sont envoyés aléatoirement dans la base d'apprentissage Ω_{App}^j ou dans la base de validation Ω_{Val}^j du patch j correspondant. Le choix d'un seuil non nul de la surface d'intersection est dû à la récupération d'information normale lors de l'extraction des zones atypiques. Les données d'apprentissage et de validation sont donc différentes selon le patch étudié tandis que les données

de test restent les mêmes sur tous les patchs. Ce processus de répartition des données est détaillé dans l'algorithme 5. Pour les études ponctuelles (point à point) des spectrogrammes, nous utilisons la base \mathcal{B}_1 des annotations ponctuelles. La base de test reste la même (contenant déjà les annotations ponctuelles) et la base de validation correspond aux spectrogrammes de \mathcal{B}_1 non utilisés dans la base de test. La base d'apprentissage reste sélectionnée de la même manière.

Algorithme 5 : Répartition des données en base d'apprentissage et base de validation

Données : Base de données Ω , base de données \mathcal{B}_1 des spectrogrammes annotés ponctuellement, la subdivision \mathcal{K}^{128} , la surface minimale d'intersection S_{min} , le pourcentage de patchs normaux sélectionnés pour la base d'apprentissage τ_{App} , les données test Ω_{Test}

Résultat : Les données réparties $\Omega_{normal}^j, \Omega_{ano}^j, \Omega_{App}^j, \Omega_{Val}^j$

Initialisation : $\forall j \quad \Omega_{normal}^j = \emptyset, \quad \Omega_{ano}^j = \emptyset, \quad \Omega_{App}^j = \emptyset, \quad \Omega_{Val}^j = \mathcal{B}_1 \setminus \Omega_{Test}$;

pour j in $1, \dots, \text{card}(\mathcal{K}^{128})$ **faire**

pour chaque moteur i de Ω **faire**

si $\exists k \text{ zone}_{ano}^i(k) : Surface(Z_j, \text{zone}_{ano}^i(k)) > S_{min}$ **alors**

| Ajout de i à Ω_{ano}^j

sinon

| Ajout de i à Ω_{normal}^j

fin

fin

Sélection aléatoire parmi $\Omega_{normal}^j \setminus \Omega_{Test}$ de τ_{App} moteurs pour Ω_{App}^j

$\Omega_{Val}^j = \Omega_{normal}^j \setminus \{\Omega_{Test} \cup \Omega_{App}^j\} \cup \Omega_{ano}^j \setminus \Omega_{Test}$

fin

retourner $\Omega_{normal}^j, \Omega_{ano}^j, \Omega_{App}^j, \Omega_{Val}^j, j \in \{1, \dots, \text{card}(\mathcal{K}^{128})\}$

$\text{zone}_{ano}^i(k)$ correspond aux zones atypiques présentes dans la base de données annoté (Figure 1.8).

La figure 2.2 présente la répartition entre spectrogrammes normaux et atypiques pour chaque patch parmi les $n = 493$ moteurs. Chaque sous-rectangle (encadré en noir) correspond à un des patchs, sa position correspond à la position dans le spectrogramme. L'axe des N_2 a donc été divisé en 3 intervalles et l'axe des fréquences en 18 intervalles à partir de la décomposition en patchs carrés de taille 128 pixels. Le coin inférieur droit du sous-rectangle contient le taux de patchs normaux dans la base de données, et le coin supérieur gauche le taux de patchs atypiques. Comme nous l'avions énoncé dans le chapitre précédent (Figure 1.9), les données ne sont pas équilibrées. La grande majorité des patchs possèdent très peu de données atypiques. Les approches de type one-class/détection d'anomalies, permettant de caractériser le comportement normal des patchs, sont donc adaptées à notre problématique. Deux patchs présentent un nombre de données atypiques supérieur à celui des données normales. Il s'agit des patchs les plus complexes où de nombreux types de signatures inusuelles apparaissent. Utiliser des approches supervisées pour caractériser les données atypiques pourrait paraître plus efficace sur ces patchs. Cependant la parcimonie des signatures inusuelles au sein des patchs et la grande variabilité de

ces dernières rendent cette analyse délicate. Caractériser la normalité reste donc plus pertinent. Nous cherchons également à mettre en place des méthodes non dépendantes de la subdivision en patchs établie. Il est donc indispensable que les approches étudiées fonctionnent sur l'intégralité des patchs sans tenir compte de la répartition des moteurs dans ces derniers.

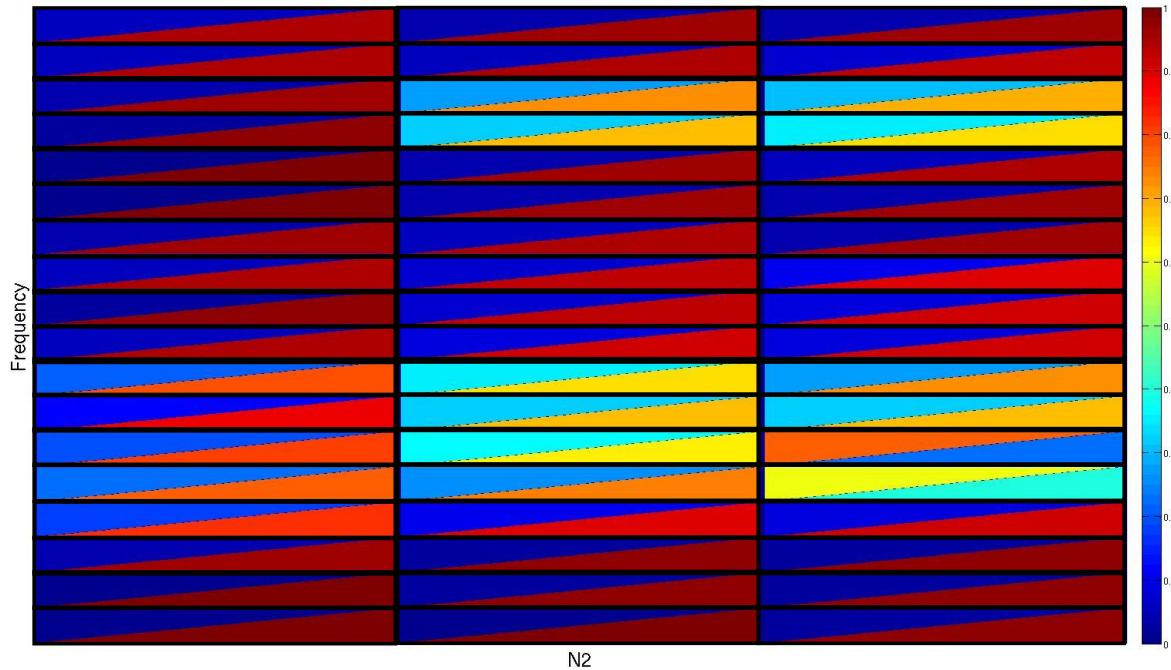


FIGURE 2.2 – Ratio de données normales et atypiques sur les différents patchs allant du bleu (faible proportion) au rouge (forte proportion). Chaque sous-rectangle correspond à un patch avec la partie inférieure droite correspondant au taux de données normales sur ce patch et la partie supérieure gauche aux données atypiques. La grande majorité des patchs possède peu de données atypiques, quelques patchs se distinguent avec une forte proportion de données possédant des signatures inusuelles.

2.4.2 Visualisation des résultats

Dans la thèse, nous présentons des résultats visuels de détection des signatures inusuelles sur un patch spécifique contenant différents types de signatures atypiques. Il s'agit du patch sur lequel quelques points de certains spectrogrammes ont été annotés. Nous avons sélectionné 5 données de ce patch spécifique dans la base de test pour présenter visuellement les résultats, une donnée ne contenant pas de signatures inusuelles et les 4 autres possédant différents formes de signatures atypiques (Figure 2.3). Les approches développées ne sont pas spécifiques à un type de signatures mais caractérisent la normalité présente sur les patchs afin de détecter tout type de signatures inusuelles. Nous représentons sur la figure 2.3 les différents patchs utilisés pour la représentation visuelle des résultats dans ce manuscrit avec un encadrement des signatures inusuelles présentes. Le patch sans encadrement correspond au patch normal.

A partir de nos différentes approches, nous cherchons à détecter les points composant ces

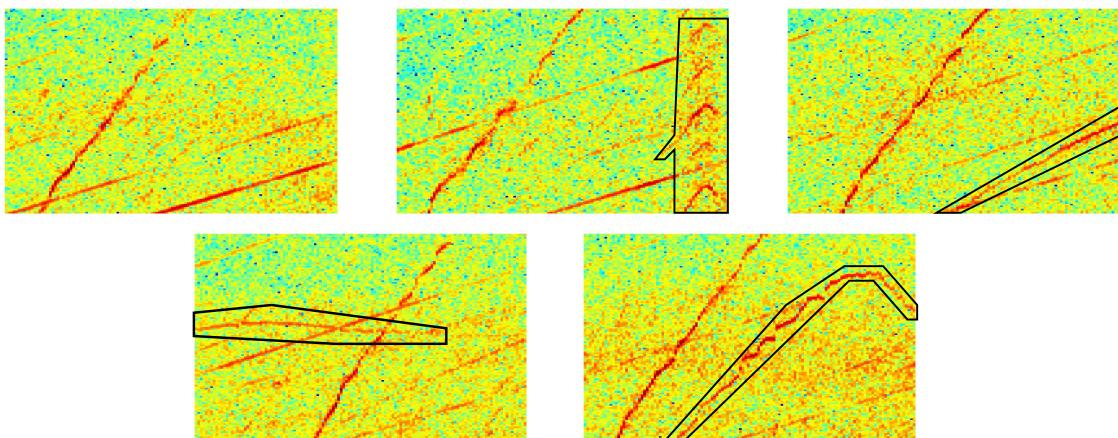


FIGURE 2.3 – Patches de la base de test utilisés pour présenter les résultats visuels des différentes approches. Le premier patch ne contient pas de signature inusuelle, les suivants possèdent tous différentes signatures inusuelles encadrées.

signatures atypiques et ainsi les mettre en évidence pour des détections visuelles. Pour cela, nous modélisons les comportements normaux de chaque patch dans leur globalité et ponctuellement.

Deuxième partie

Les approches de représentation globale par dictionnaire

Introduction

Les approches par dictionnaires permettent de représenter les données en grande dimension dans un nouvel espace. Dans le cadre de la détection de nouveautés, ce dictionnaire doit permettre de caractériser le comportement normal de nos données, c'est-à-dire l'ensemble des raies présentes sur la très grande majorité des spectrogrammes. Cette approche est appliquée patch par patch de manière indépendante. Les dictionnaires sont définis sur chaque patch et n'ont aucune relation avec les dictionnaires définis sur d'autres patchs. Les patchs sont définis à partir de la subdivision \mathcal{K}^{128} dont chaque patch est de dimension 128×128 . Afin de caractériser la normalité, ces dictionnaires sont calibrés sur les patchs normaux sans signature inusuelle. Nous nous servons donc des zones atypiques extraites de la base de données et de la classification des patchs établis afin de sélectionner les patchs d'apprentissage.

Nous cherchons à définir un espace, défini par les atomes du dictionnaire, caractérisant les éléments normaux sur les patchs afin d'y projeter nos données. Nous obtenons ainsi une représentation normale des données à partir de laquelle nous reconstruisons les patchs. Dans ces reconstructions issus du dictionnaire de normalité, les signatures atypiques présentes dans les données se retrouvent absentes ou réduites. Les reconstructions correspondent alors à des estimations normales des patchs. Nous utilisons des dictionnaires dont la reconstruction s'écrit comme une combinaison linéaire des atomes de ces derniers. Ce choix est volontaire et vient de notre interprétation des spectrogrammes comme une superposition de différentes raies pouvant être interprétées comme des sources. Les atomes du dictionnaire sont appris sur les données ou sélectionnés dans un dictionnaire plus large à partir d'un seuillage des coefficients de la décomposition. Nous avons étudié deux de ces dictionnaires :

- les curvelets [22] forment un dictionnaire non-adaptatif (du fait de la non modification des atomes en fonction des données) défini à partir de fonctions. Les atomes de ce dictionnaire s'apparentent à des raies sur de petites échelles et dans différentes orientations. Ce dictionnaire permet donc la caractérisation des signatures vibratoires en combinant différents atomes pour reconstruire la raie.
- La Non-Negative Matrix Factorization (NMF) [70], un dictionnaire adaptatif dont les atomes sont appris à partir des données. Les atomes de ce dictionnaire prennent en compte la structure globale du patch par la procédure d'apprentissage. Ce dictionnaire impose des combinaisons additives de ces atomes uniquement. Les signatures atypiques non présentes dans les données d'apprentissage ne sont pas bien caractérisées par le dictionnaire et ne peuvent pas être reconstruites.

Ces dictionnaires ne sont généralement pas utilisés dans le cadre de la détection d'anomalies. Nous les avons donc adaptés pour qu'ils permettent de répondre à notre problématique. Dans cette partie, nous montrons que ces dictionnaires sont pertinents et complémentaires pour finement détecter les points atypiques sur les patchs.

Chapitre 3

Représentation par dictionnaire fixe - les curvelets

3.1 Introduction

3.1.1 La représentation par dictionnaire

La représentation des données a un rôle primordial dans les performances des méthodes de machine learning [13]. Cette représentation doit avoir un sens aussi bien mathématique qu'explicatif vis-à-vis du problème étudié. Elle doit permettre de réaliser l'étude et de mettre en valeur les éléments pertinents sur les données au niveau de la représentation. Pour la détection dans un cadre supervisé, il est important que la représentation des données soit discriminante, tandis que pour la détection de nouveautés, il est important que la représentation généralise la normalité.

Dans cette partie, nous avons opté pour des dictionnaires reconstruisant les données de manière linéaire. Ce choix a été réalisé car nous considérons les spectrogrammes comme une superposition linéaire de différentes raies pouvant être considérées comme des sources. Les dictionnaires correspondent à un ensemble d'éléments sur lesquels les données sont représentées ; chaque élément du dictionnaire est un atome. Les dictionnaires étudiés permettent de représenter les données comme une combinaison linéaire des atomes de ce dictionnaire. Dans ce cadre, il existe deux moyens de représenter une donnée $x \in \mathbb{R}^p$ à partir d'un dictionnaire $\mathcal{D} = [d_1, \dots, d_r] \in \mathbb{R}^{p \times r}$ [98, 93] :

- la méthode d'analyse où la donnée x est représentée par sa décomposition $C_{\mathcal{D}}^A$ dans le dictionnaire \mathcal{D} , c'est à dire par le produit scalaire de \mathcal{D} avec x ,

$$C_{\mathcal{D}}^A = \mathcal{D}^T x,$$

- la méthode de synthèse où la donnée x est considérée comme une combinaison linéaire des atomes de \mathcal{D} pondérés par la représentation $C_{\mathcal{D}}^S$, la décomposition est obtenue par des

méthodes d'optimisation.

$$x = \mathcal{D}C_{\mathcal{D}}^S$$

Ces deux approches sont identiques dans le cas où le dictionnaire \mathcal{D} est orthogonal. Lorsque $r < p$, la donnée est représentée dans un espace de plus petite dimension, on parle alors de réduction de dimension [35]. Lorsque $r > p$ la représentation est effectuée dans un espace de plus grande dimension, il s'agit alors d'un dictionnaire sur-complet [4]. Ce second cas de figure est utilisé plus particulièrement pour obtenir des représentations parcimonieuses des données.

Les atomes des dictionnaires peuvent être définis de manière analytique par des fonctions, ou sont appris à partir des données. Un état de l'art de ces différentes approches est réalisé dans [97]. Les dictionnaires analytiques possèdent leurs atomes définis par des fonctions prédéfinies. Ce type de dictionnaire est non-adaptatif, car les atomes ne sont pas modifiés en fonction des données, mais possède des propriétés mathématiques intéressantes. Ces dictionnaires donnent une décomposition en général unique et rapide à calculer. Ils sont basés sur la représentation d'un signal complexe à partir de classes de fonctions mathématiques plus simples. Ils sont généralement sélectionnés car leurs atomes correspondent à la structure des données étudiées et sont susceptibles de donner une représentation parcimonieuse de ces dernières. Les dictionnaires *data-driven* apprennent directement leurs atomes sur les données. Les représentations acquises à partir de ces dictionnaires ne sont généralement pas uniques. Afin de rendre ces dictionnaires et les décompositions dans ces derniers plus robustes et d'éviter le surapprentissage, des contraintes sont ajoutées lors de l'apprentissage telles que la parcimonie, la positivité, l'invariance par translation ou par rotation... Ce type de dictionnaire s'est rapidement développé dans la fin du 20ème siècle et le début du 21ème grâce à son adaptabilité aux données et aux méthodes d'optimisation comme les « basis pursuit » [28].

Nous nous intéressons à ces approches de dictionnaire dans un cadre de la détection de nouveautés sur nos spectrogrammes. Nous définissons le modèle de normalité de nos données à partir de ces dictionnaires. Nous ne cherchons pas à extraire des caractéristiques sur les données pour la détection d'anomalies, mais à représenter les éléments normaux des données afin de pouvoir donner une reconstruction normale (sans signature atypique) de ces dernières. Nous définissons la représentation des données par la combinaison du dictionnaire et la décomposition des données dans ce dernier. Dans le cadre de la détection de nouveautés, nous définissons la représentation normale par la reconstruction des données à partir du dictionnaire caractérisant la normalité, il s'agit donc d'une estimation normale des données. Dans ce chapitre, nous étudions les dictionnaires non-adaptatifs à travers les curvelets [22], les dictionnaires adaptatifs sont étudiés dans le chapitre suivant.

3.1.2 Les dictionnaires non-adaptatifs

Ces dictionnaires permettent de représenter les données à partir d'ensemble de fonctions simples. L'exemple le plus connu de ce type de dictionnaire est la transformée de Fourier caractérisant les signaux à partir de fonctions sinusoïdales. Cependant, ne bénéficiant pas de fonction de localisation, cette transformée ne permet pas de caractériser efficacement des signaux discontinus. Des approches multi-échelles tenant compte de la localisation ont permis d'obtenir de meilleurs résultats de caractérisation pour certains types de données. Il s'agit de la transformée en ondelettes [80], fondée sur une famille de fonctions paramétrées par un facteur d'échelle et de position. Cette transformée est inversible et permet de décomposer efficacement des signaux discontinus sans aucun apriori avec peu de coefficients. Autrement dit, la représentation dans ce dictionnaire est généralement parcimonieuse. Dans le cas de la transformée de Fourier, les signaux discontinus influent sur toutes les fréquences et donc sont représentés par un grand nombre de coefficients. Il y a un choix à effectuer par rapport à la nature des fonctions utilisées pour les atomes du dictionnaire. Il existe différentes catégories d'ondelettes comme les ondelettes de Haar, de Daubechies, de Morlet,...[80]. Ces dictionnaires constituent généralement une base de L^2 . La décomposition dans ces dictionnaires se calcule donc généralement à partir d'un produit scalaire entre les données et les atomes, donc par analyse.

La décomposition en ondelettes est pertinente pour caractériser des singularités ponctuelles sur des signaux unidimensionnels ou multidimensionnels. Cependant, dans les dimensions supérieures, les singularités peuvent également correspondre à des hyperplans qui sont alors caractérisés par un grand nombre de coefficients. La transformée en ondelettes ne permet plus une représentation parcimonieuse en grande dimension. Bien qu'elle tienne compte de la position, la transformation en ondelettes classique ne prend pas en compte les orientations et donc la géométrie des singularités. Ceci entraîne la nécessité d'un grand nombre de coefficients afin de caractériser une discontinuité linéaire en 2 dimensions. De nouvelles approches basées sur les ondelettes et la représentation multi-échelle ont vu le jour pour pallier ce problème et principalement caractériser des singularités courbes dans des images, donc en dimension 2. Dans [42], un dictionnaire appelé les wedgelets est mis en place, il consiste en la division de l'image en 4 carrés dyadiques et la définition d'une droite séparatrice pour chacun de ces carrés. Cette droite permet de représenter la partie supérieure du carré par une valeur et la partie inférieure par une autre. Si la droite séparatrice ne permet pas une assez bonne caractérisation du carré dyadique, c'est-à-dire que ce carré est traversé par une forme non linéaire, ce dernier est à nouveau décomposer en 4 sous-carrés dyadiques et chacun d'entre eux est une nouvelle fois divisé par une droite séparatrice. Le processus est itéré jusqu'à avoir une bonne caractérisation des données. Le dictionnaire correspond alors à l'ensemble des carrés dyadiques et des droites séparatrices correspondantes. Il permet de caractériser efficacement des formes courbes en les décomposant en sous-formes linéaires à travers des carrés dyadiques d'échelle de plus en plus fine. Les ridgelets [21] permettent de caractériser des discontinuités linéaires, elles sont basées sur une application des ondelettes le long de droites, les curvelets [22] caractérisent les discontinuités courbes. Plusieurs autres approches permettent de caractériser des discontinuités sur des images comme les

contourlets [39], les bandelets [67]... Le scattering network [18] permet de représenter les données dans un réseau convolutionnel où chaque noeud correspond au module des convolutions successives de transformées d'ondelettes de Morlet. Cette représentation a l'avantage d'être invariante par translation et rotation. Une étape non-linéaire de seuillage est généralement ajoutée à ces représentations non-adaptatives afin de donner une représentation parcimonieuse car un nombre limité de coefficients est généralement suffisant pour caractériser et/ou reconstruire la donnée d'entrée.

Le dictionnaire des curvelets permet de caractériser les formes courbes, nous utilisons donc ce dictionnaire afin de caractériser les raies normales présentes sur les patchs sans signature atypique. La caractérisation des raies normales permet de définir un dictionnaire de normalité dans lequel nous pouvons projeter les patchs pour obtenir une reconstruction normale de ces derniers et étudier les résidus associés afin de vérifier la présence potentielle de signatures inusuelles sur le patch.

3.2 La transformée en curvelet

La transformée en curvelet [22] permet la caractérisation de singularités courbes. Elle est basée sur la transformée en ridgelet [21] et la caractérisation d'une forme courbe à partir d'une succession de formes linéaires à petite échelle (Figure 3.1).

3.2.1 La transformée en ridgelet

Les ridgelets ont été introduites dans [19] et sont définies sous la forme d'une composition de fonctions *ridges* avec une ondelette ψ (3.1). Elles sont caractérisées par un paramètre d'échelle $a > 0$, un paramètre de position $b \in \mathbb{R}$ et un paramètre d'orientation $\theta \in [0, 2\pi[$. Ce nouveau paramètre diffère des ondelettes et permet la caractérisation de toutes formes linéaires sous différentes directions. On note $\psi_{a,b,\theta}$ la ridgelet de paramètre (a, b, θ) .

$$\psi_{a,b,\theta}(t = (t_1, t_2)) = a^{-\frac{1}{2}}\psi\left(\frac{t_1 \cos \theta + t_2 \sin \theta - b}{a}\right) \quad (3.1)$$

Cette fonction est constante le long des droites $t_1 \cos \theta + t_2 \sin \theta = \text{constante}$ et se comporte comme une ondelette perpendiculairement. Dans le domaine des fonctions ridges, une singularité linéaire est définie par un point (la constante à laquelle est associée la droite la caractérisant). Dans cet espace, la singularité linéaire devient donc une singularité ponctuelle pouvant être caractérisée efficacement par les ondelettes avec peu de coefficients. Les ridgelets permettent donc une représentation efficace des formes linéaires.

La transformée en ridgelet \mathcal{R}_x d'un signal x correspond alors au produit scalaire entre la

fonction de ridgelet $\psi_{a,b,\theta}$ et x .

$$\mathcal{R}_x(a, b, \theta) = \int \bar{\psi}_{a,b,\theta}(t)x(t)dt$$

$\bar{\psi}$ et $\hat{\psi}$ sont respectivement le complexe conjugué et la transformée de Fourier de ψ satisfaisant la condition d'admissibilité :

$$\int \frac{|\hat{\psi}(\lambda)|^2}{\lambda} d\lambda < \infty$$

Cette transformée est inversible pour un signal x intégrable et de carré intégrable, respecte la relation de Parseval et se généralise dans toutes les dimensions.

La transformée, ainsi définie, permet d'obtenir une représentation des signaux continus. La version discrète de la transformée en ridgelets [21] correspond à une discréétisation spécifique (a_j, b_k, θ_l) de ses paramètres afin que l'ensemble des fonctions de ridgelets $\{\psi_{j,k,l}\}$ forme une frame. Inspirés par la transformée en ondelette, les paramètres d'échelle a et de position b sont échantillonnés de manière dyadique avec une dépendance de la discréétisation du paramètre de position par rapport à celle de l'échelle. La résolution du paramètre d'orientation θ augmente mécaniquement avec le paramètre d'échelle et est donc dépendante de ce paramètre.

$$a_j = a_0 2^{-j} \quad b_{j,k} = 2\pi k 2^{-j} \quad \theta_{j,l} = 2\pi l 2^{-j}$$

L'ensemble des fonctions

$$\{\psi_{j,k,l}(t) = 2^{\frac{j}{2}} \psi(2^j(t_1 \cos(2\pi l 2^{-j}) + t_2 \sin(2\pi l 2^{-j}) - 2\pi k 2^{-j}))\}_{j,k,l} \quad (3.2)$$

forme une frame permettant la décomposition des signaux. La transformée en ridgelet [21] discrète s'effectue par produit scalaire entre le signal et l'ensemble des fonctions de ridgelets définies dans (3.2).

La transformée en curvelet se calcule à partir des ridgelets orthonormales ρ_λ définies dans [40] et paramétrées par $\lambda = (j, k, i, l, \epsilon) \in \Lambda$. j et k correspondent respectivement aux paramètres d'échelle et de position de la fonction ridge, i et l définissent les paramètres d'échelle et de position angulaire, ϵ est un paramètre de genre lié aux paramètres d'échelle. Nous renvoyons à [40] pour plus de détails sur la construction de ces ridgelets particulières. Le dictionnaire défini à partir des ridgelets orthonormales constitue une "tight" frame permettant la conservation de l'énergie entre les signaux et leurs représentations à partir de ces ridgelets particulières.

3.2.2 Les ridgelets multi-échelles

Les ridgelets définies au dessus permettent d'analyser les données en 2 dimensions dans leur globalité. Les ridgelets multi-échelles [22] ont pour but de pouvoir analyser une donnée sous différentes échelles de cette donnée. Il est possible de considérer les ridgelets orthonormales comme

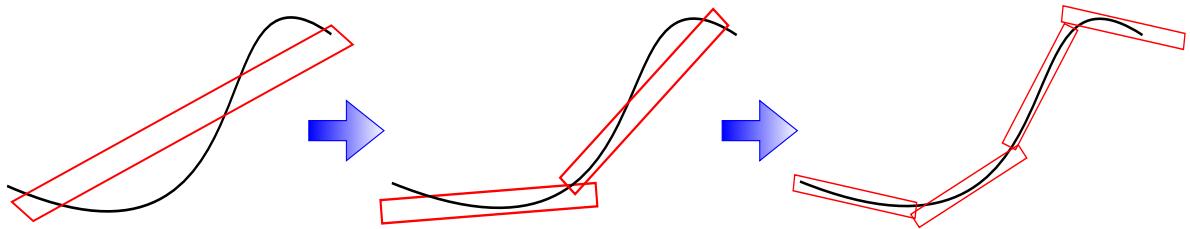


FIGURE 3.1 – Caractérisation d'une forme courbe à différentes échelles. La taille des éléments caractérisant la forme diminue avec l'échelle. La représentation de la forme courbe est améliorée en augmentant le nombre de formes linéaires à plus petites échelles.

des éléments linéaires de taille fixe et de largeur plus ou moins fine. Cependant, dépendant de la forme considérée, une certaine taille de ridgelets peut être plus pertinente qu'une autre (Figure 3.1). Il faut donc qu'elles puissent s'adapter aux différentes dimensions des formes étudiées. Pour cela, les ridgelets multi-échelles sont définies à partir d'un opérateur d'échelle T_Q qui transpose la ridgelet orthonormale de son espace de départ $[0, 1]^2$ vers un carré dyadique $Q = (s, k_1, k_2)$ définit sur $[\frac{k_1}{2^s}, \frac{k_1+1}{2^s}] \times [\frac{k_2}{2^s}, \frac{k_2+1}{2^s}]$, s définit l'échelle de subdivision des données en carrés dyadiques et (k_1, k_2) la position du carré étudié. L'énergie de la ridgelet est également répartie de manière lisse sur les points voisins du carré dyadique par une fonction de fenêtrage ω ayant comme propriété $\sum_{k_1, k_2} \omega(x_1 - k_1, x_2 - k_2) \equiv 1$.

Les ridgelets multi-échelles $\{\psi_\mu, \mu = (\lambda, Q) \in (\Lambda, \mathcal{Q}_s)\}$ (3.3) correspondent à une application des ridgelets orthonormales paramétrées par λ sur des extractions de carrés dyadiques à différentes échelles s paramétrés par $Q \in \mathcal{Q}_s$ avec \mathcal{Q}_s l'ensemble des carrés dyadiques de taille 2^{-s} . L'application des ridgelets orthogonales sur différentes tailles d'images permet de considérer différentes tailles pour les ridgelets (correspondant à la taille de l'image) tout en étudiant différentes échelles et orientations des ridgelets.

$$\psi_{\mu_s} = 2^s T_Q(\omega \cdot \rho_\lambda), \quad \mu_s = (\lambda, Q) \in (\Lambda, \mathcal{Q}_s) = \mathcal{M}_s \quad (3.3)$$

Il faut distinguer l'échelle j des ridgelets et l'échelle s des multi-ridgelets qui correspond à la subdivision en carrés dyadiques sur lesquels les ridgelets définies à plusieurs échelles a_j sont appliquées.

3.2.3 La construction de la transformée en curvelet

Les curvelets sont utilisées pour caractériser des formes courbes sur les données. Elles sont issues de la transformée en ridgelet appliquée à différentes échelles s de la donnée. Les différentes échelles caractérisent l'idée que chaque courbe peut être approximée par une série de formes linéaires sur de petites échelles (Figure 3.1). En diminuant l'échelle, les formes linéaires caractérisent bien mieux les courbures en prenant de plus petites tailles, mais nécessairement leur nombre augmente. Le meilleur moyen de caractériser les données x est donc d'appliquer les ridgelets orthonormales sur des échelles s de plus en plus fines. Il s'agit de caractériser x à partir

de $\{\psi_\mu, \mu \in \mathcal{M} = \bigcup_{s>0} \mathcal{M}_s\}$. Cependant, à une échelle donnée s , $\{\psi_\mu, \mu \in \mathcal{M}_s\}$ constitue un tight frame permettant d'avoir

$$\sum_{\mu \in \mathcal{M}_s} \langle x, \psi_\mu \rangle^2 = \|x\|_{L_2}^2, \quad \forall x$$

ainsi si nous considérons la représentation dans $\{\psi_\mu, \mu \in \mathcal{M}\}$, nous avons

$$\sum_{\mu \in \mathcal{M}} \langle x, \psi_\mu \rangle^2 = \sum_{s>0} \sum_{\mu \in \mathcal{M}_s} \langle x, \psi_\mu \rangle^2 = \sum_{s>0} \|x\|_{L_2}^2 = \infty.$$

$\{\psi_\mu, \mu \in \mathcal{M}\}$ ne constitue pas une frame et n'est donc pas adéquat pour représenter les données.

Pour éviter la divergence de l'énergie de représentation, les données x sont décomposées dans un premier temps selon un filtrage passe-bande dont la plage de fréquences implique l'application d'une unique échelle des ridgelets multi-échelles. La décomposition fréquentielle est effectuée en intervalles dyadiques de la forme $|\xi| \in [2^{2s}, 2^{2s+2}]$ par le filtre passe-bande Δ_s auquel est associée la ridgelet multi-échelle s , donc $\{\psi_\mu, \mu \in \mathcal{M}_s\}$. Les basses fréquences, $|\xi| \leq 1$ sont récupérées par un filtre passe-bas P_0 , ce filtre est associé à une ondelette ϕ plutôt qu'à une ridgelet. La décomposition fréquentielle permet une conservation de l'énergie, tout comme l'application d'une seule échelle des ridgelets multi-échelles (ridgelets orthonormales), le dictionnaire ainsi défini correspond alors à une "tight" frame.

$$\|x\|_2^2 = \|P_0 x\|_2^2 + \sum_s \|\Delta_s x\|_2^2 = \langle P_0 x, \phi \rangle^2 + \sum_s \langle \Delta_s x, \psi_{\mu_s} \rangle^2 \quad \mu_s = (\lambda, Q) \in (\Delta, \mathcal{Q}_s)$$

La transformée en curvelet des données $x \in \mathbb{R}^2$, et leurs décompositions dans le dictionnaire, se calculent par les étapes suivantes dont une illustration est donnée dans [47] :

1. filtrage passe-bande sur la plage de fréquence $|\xi| \in [2^{2s}, 2^{2s+2}]$ des données x ,
2. subdivision lisse des données filtrées en carrés dyadiques de taille 2^{-s} dépendant du filtre utilisé,
3. remise à l'échelle du carré dyadique de façon à ce qu'il appartienne à $[0, 1]^2$,
4. application de la transformée en ridgelet orthonormale.

La décomposition des données x dans ce dictionnaire s'écrit sous la forme d'un produit scalaire avec les atomes du dictionnaire $\gamma_{\mu_s} = \Delta_s \psi_\mu, \mu_s \in \mathcal{M}_s$. Nous notons \mathcal{C}_x la représentation de x dans le dictionnaire des curvelets.

$$\mathcal{C}_x = \{\langle \gamma_{\mu_s}, x \rangle\}_s \tag{3.4}$$

Cette transformée permet d'avoir une représentation parcimonieuse à partir d'un seuillage des formes courbes sur les données. Le taux d'approximation des formes courbes à partir des m plus grands coefficients de la décomposition dans le dictionnaire est asymptotiquement quadratique [22]. Ce taux d'approximation est meilleur que ceux définis à partir de la transformée de Fourier ou des ondelettes. Une transformée en curvelets rapide a été définie et implémentée dans [20].

3.2.4 Le dictionnaire des curvelets

Le dictionnaire des curvelets \mathcal{D}^C est surcomplet, ce qui peut entraîner une représentation par-cimonieuse des données (après seuillage des coefficients). La structure des atomes du dictionnaire est indépendante des données. De plus, chaque étape de la transformée est inversible. Il existe donc une transformée inverse \mathcal{C}_x^{-1} permettant de reconstruire la donnée d'origine à partir de sa décomposition dans le dictionnaire des curvelets, cette reconstruction est parfaite.

La reconstruction des données à partir du dictionnaire (la transformée inverse) correspond à la combinaison des atomes du dictionnaires pondérée par les coefficients de représentation des données. Nous représentons (Figure 3.2) les atomes du dictionnaire des curvelets \mathcal{D}^C dans le domaine des données (le domaine image). Chaque élément de la base correspond à la reconstruction lorsqu'un unique atome est activé avec pour coefficient 1 (3.5). Un atome est activé lorsque son coefficient associé est non nul.

$$\mathcal{D}^C = \{\mathcal{C}_{\mathbf{1}_{s,k,\theta}}^{-1}\}_{s,k,\theta} \quad (3.5)$$

avec $\mathbf{1}_{s,k,\theta}$ la fonction indicatrice dans l'espace des coefficients de curvelets des coordonnées (s, k, θ) correspondant respectivement à l'échelle, la position et l'orientation.

Différents atomes à différentes échelles sont représentés en figure 3.2. Les atomes de l'échelle la plus grossière n'ont pas de direction puisqu'il s'agit d'ondelettes. Les atomes d'échelles plus fines correspondent à de petites formes de raies linéaires permettant de caractériser des formes courbes par la concaténation de ces petites raies. Les raies des atomes à une même échelle ont toutes la même taille définie par celle de la subdivision en carrés dyadiques. Nous pouvons remarquer que plus l'échelle devient fine, plus la taille de l'atome diminue, permettant la caractérisation de formes courbes à petites échelles. Les atomes sur les bords de l'image répercutent leurs effets sur le bord opposé. L'intensité de l'atome est maximale sur le point étudié et décroît dans les différentes directions. Les atomes du dictionnaire des curvelets ont une action locale sur les données étudiées.

Le dictionnaire des curvelets a été utilisé dans le traitement d'images pour du débruitage dans [105] en seuillant les coefficients des curvelets pour caractériser l'information courbe sur l'image et pour l'analyse des séismes [27]. Un état l'art des différentes applications mises en place à partir des curvelets a été réalisé dans [77]. Le choix du dictionnaire est effectué par rapport à la nature de l'information pertinente présente dans les données (forme de raie).

3.3 Application des curvelets aux spectrogrammes vibratoires

3.3.1 Caractérisation des raies vibratoires à partir des curvelets

Les atomes du dictionnaire des curvelets ne s'adaptent pas aux données mais sont les mêmes indépendamment des données considérées. Ce dictionnaire reste néanmoins pertinent aux données

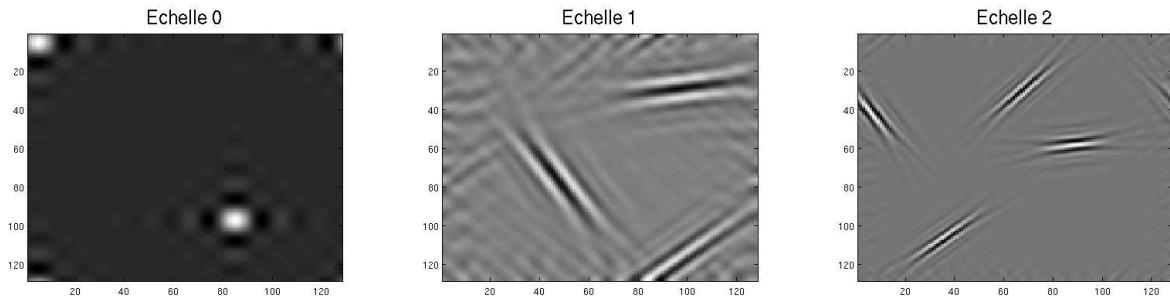


FIGURE 3.2 – Atomes du dictionnaire des curvelets à différentes échelles. La première image correspond aux atomes de l'échelle grossière correspondant à des ondelettes. Les deux images suivantes correspondent aux atomes de curvelets à des échelles plus fines. Les atomes caractérisent des formes de plus en plus petites.

de spectrogrammes de part la structure en raies de ces derniers. Nous considérons les spectrogrammes comme la superposition de raies qui peuvent être considérées comme la superposition de singularités courbes. Les curvelets permettent de caractériser naturellement des singularités courbes avec peu de coefficients. Cette représentation peut donc permettre de caractériser les différentes signatures vibratoires de manière parcimonieuse. La transformée en curvelet entière n'est pas indispensable, seuls les atomes dont l'orientation est colinéaire avec l'orientation des raies sont significatifs. Les autres, particulièrement ceux dont l'orientation est orthogonale par rapport aux raies, sont négligeables. La représentation parcimonieuse des spectrogrammes dans le domaine des curvelets est obtenue en seuillant les coefficients de la transformation. Seuls les atomes dont les coefficients correspondants sont supérieurs à un seuil défini sont nécessaires pour caractériser les raies vibratoires présentes sur le spectrogramme et permettre une bonne reconstruction de ces dernières. Les reconstructions de patchs à partir de différents seuillages des coefficients sont présentés en figure 3.3 pour un patch normal et en figure 3.4 pour un patch contenant des signatures atypiques. Les reconstructions sont établies à partir de 100%, 50%, 10%, 5% et 1% des coefficients représentant les patchs de taille 128×128 dans le dictionnaire des curvelets à partir de 4 niveaux d'échelles. Dans cette configuration chaque patch est représenté par 46080 coefficients, soit une dimension de représentation dans le dictionnaire surcomplet 2.8 fois plus grande que la dimension des données.

En prenant en compte tous les coefficients, nous pouvons observer une reconstruction parfaite des patchs. En seuillant les coefficients de manière à récupérer uniquement les 50% et 10% des coefficients les plus importants, nous obtenons une bonne reconstruction des patchs avec des résidus contenant principalement du bruit. L'utilisation de 4608 coefficients (soit environ 28% de la dimension de l'image) est suffisante pour caractériser correctement les informations vibratoires normales et inusuelles présentes sur les patchs (les raies) et permettre un débruitage du patch. Le seuillage à 5%, donc en considérant 2304 coefficients (14% de la dimension de l'image), permet une bonne reconstruction des raies visuellement. Cependant une petite partie de l'information vibratoire se retrouve également dans les résidus. En considérant 1% des coefficients, la reconstruction n'est pas intéressante visuellement avec un flou sur toutes les raies ainsi que sur le bruit vibratoire. L'effet du seuillage sur la reconstruction est le même pour un patch normal

(Figure 3.3) que pour un patch atypique (Figure 3.4). Le dictionnaire des curvelets permet donc une bonne caractérisation des différentes raies du spectrogrammes en conservant un faible pourcentage des coefficients de représentation.

3.3.2 Comparaison des représentations en curvelet

Afin de détecter les patchs atypiques, nous comparons les distances entre les représentations seuillées des curvelets des différentes données. La figure 3.5a présente la matrice des distances L^2 entre les différentes données. Les premiers points (couleur verte) dans la matrice correspondent aux patchs normaux, les suivants (couleur rouge) aux patchs inusuels. La matrice obtenue ne possède pas une structure diagonale par bloc, la distance des coefficients ne permet donc pas de discriminer les patchs atypiques des patchs normaux. La variabilité de l'information normale des patchs entraîne une modification des coefficients noyant les altérations des coefficients apportées par les raies inusuelles.

Les atomes du dictionnaire caractérisent une raie à une certaine position et orientation. Ainsi si deux mêmes atomes sont activés, c'est-à-dire si leurs coefficients associés sont tous deux supérieurs au seuil d'activation s_a , cela signifie que la même raie est présente à des intensités différentes sur les deux spectrogrammes. Un atome activé pour une donnée et pas une autre correspond à l'absence d'une raie sur cette dernière. Les signatures inusuelles devraient donc être caractérisées par un nombre plus important d'atomes activés par rapport aux données normales. Le nombre d'atomes différents activés entre deux données est une pseudo-distance intéressante pour étudier les spectrogrammes à partir de ce dictionnaire, il ne s'agit pas d'une distance car elle n'est pas symétrique. Nous calculons le nombre d'atomes activés par une donnée et non activés par une autre.

$$d(Z_{\mathcal{K}_j}^{i_1}, Z_{\mathcal{K}_j}^{i_2}) = \text{card}((j_1, k, \theta) \mid \mathcal{C}_{Z_{\mathcal{K}_j}^{i_1}}(j_1, k, \theta) \geq s_a \quad \& \quad \mathcal{C}_{Z_{\mathcal{K}_j}^{i_2}}(j_1, k, \theta) < s_a)$$

avec $\mathcal{C}_{Z_{\mathcal{K}_j}}(j_1, k, \theta)$ le coefficient d'échelle j_1 , de position k et d'orientation θ de la transformée en curvelet des patchs $Z_{\mathcal{K}_j}$ et s_a le seuil d'activation du coefficient. La figure 3.5b présente la matrice de cette distance d dans la base de données avec les premiers moteurs correspondant aux patchs normaux et les suivants aux patchs inusuels. Une structure diagonale par bloc ne se dégage pas de la matrice des distances. La différence d'atomes activés parmi les représentations des données ne permet pas de discriminer les patchs normaux des patchs atypiques. La variabilité des patchs est trop importante, l'absence de certaines raies normales sur les patchs, la non-complétude et le décalage de ces dernières entraînent une variabilité des atomes activés pour les patchs normaux et ne permet donc pas la détection des patchs inusuels en comparant les atomes activés.

Le dictionnaire des curvelets permet une bonne caractérisation des signatures présentes sur le spectrogramme. Cependant l'ensemble des coefficients de représentation ainsi que la différence des atomes activés ne permettent pas la détection des patchs inusuels. Les signatures atypiques correspondent à quelques points du patch qui ne sont pas suffisants pour impacter significativement la matrice des distances.

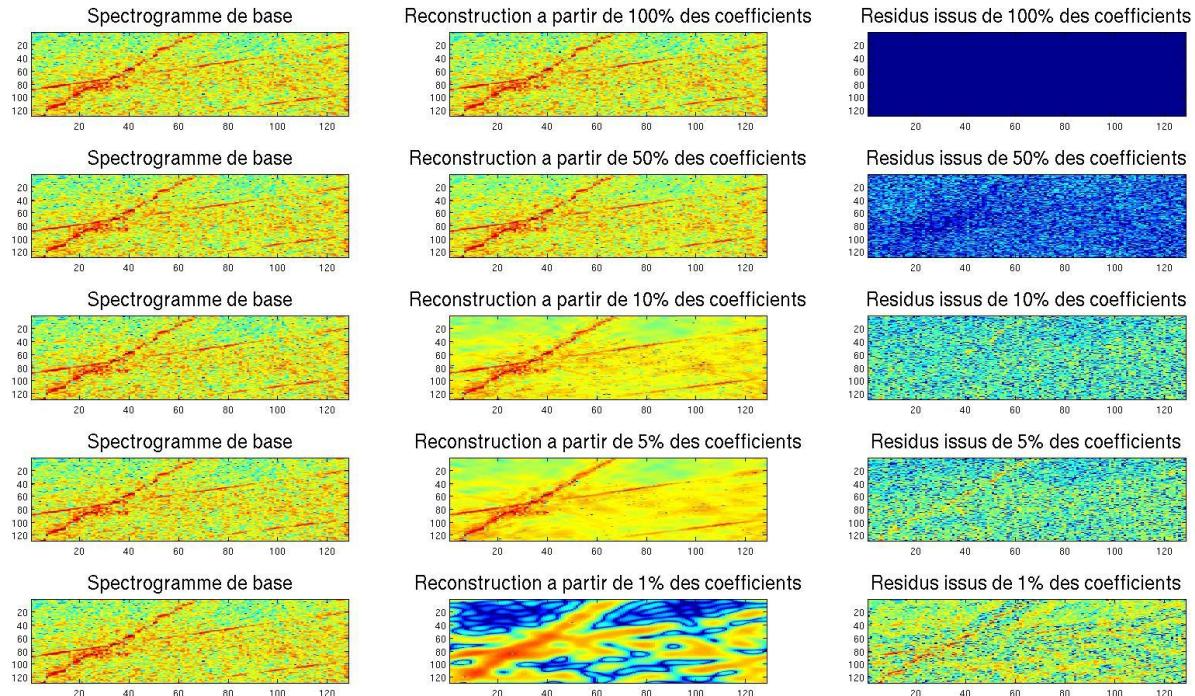


FIGURE 3.3 – Reconstruction d'un patch normal et résidus associés à partir de 100%, 50%, 10% et 5% des coefficients dans le dictionnaire des curvelets. La reconstruction à partir de 100% des coefficients permet une reconstruction parfaite, les signatures restent visibles sur les reconstructions à partir de 50%, 10% et 5% mais cette dernière entraîne entraîne une perte d'information visible dans les résidus. La reconstruction à partir de 1% des coefficients ne permet pas une reconnaissance du patch.

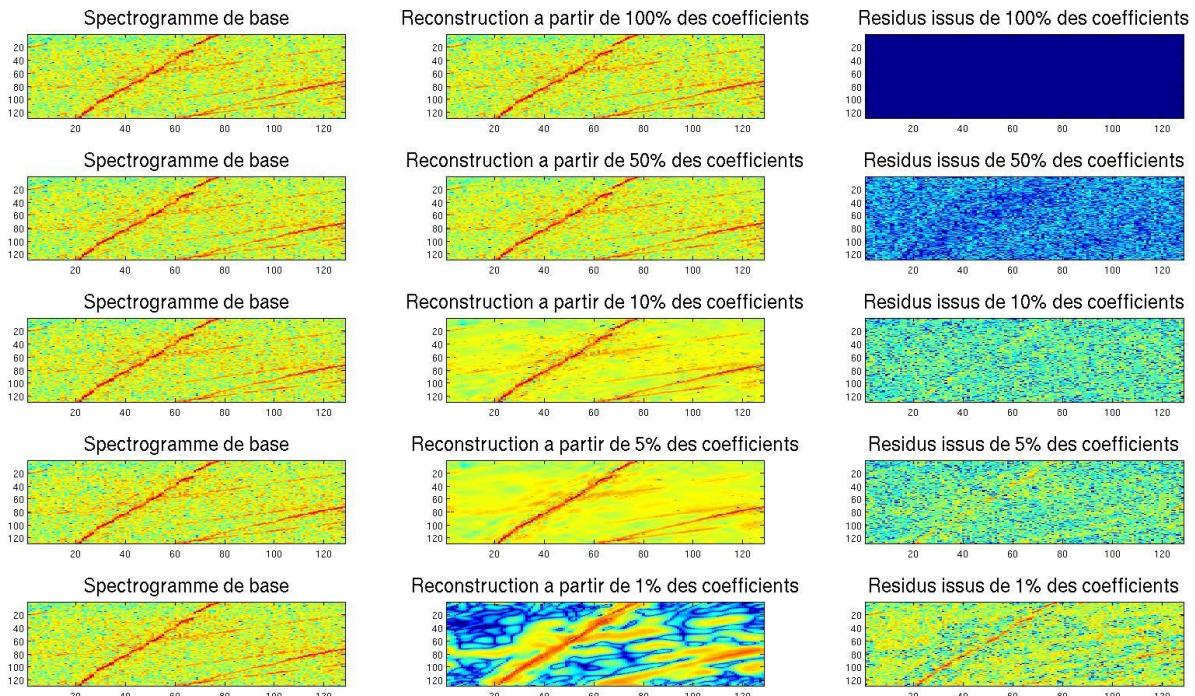


FIGURE 3.4 – Reconstruction d'un patch contenant une signature atypique et résidus associés à partir de 100%, 50%, 10%, 5% et 1% des coefficients dans le dictionnaire des curvelets. La signature atypique reste reconstruite en considérant les coefficients de plus fortes intensités.

ment la distance des coefficients ou les atomes activés par rapport à la variabilité de l'information normale. Mettre en place des modèles basés sur la modélisation des signatures inusuelles n'est pas efficace étant donnés leur faible nombre et leur grande variabilité. Il est plus pertinent de caractériser la normalité de ces patchs afin de les projeter dans ce domaine de normalité et d'obtenir une représentation normale de ces derniers.

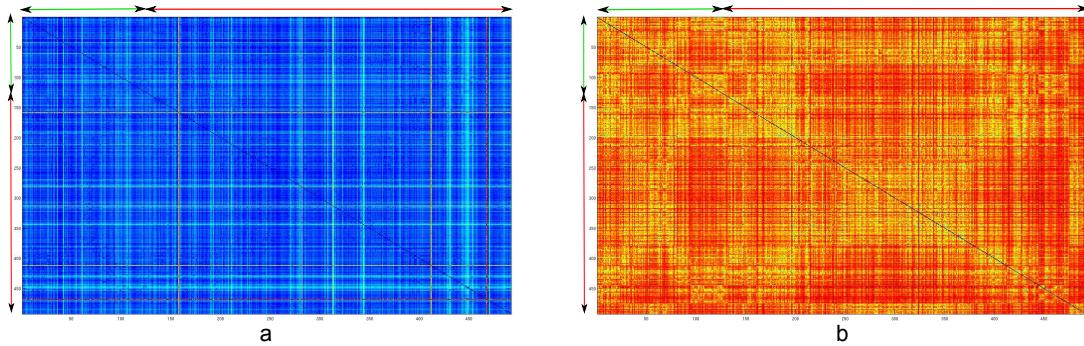


FIGURE 3.5 – Matrices des distances des coefficients des curvelets (a) et matrice de la différence d'atomes activés entre deux représentations des patchs (b). La flèche verte correspond aux patchs normaux et la flèche rouge aux patchs inusuels. Ces matrices ne possèdent pas de structure diagonale par bloc, ces distances ne permettent donc pas la détection des patchs atypiques.

3.4 Normalité définie dans le dictionnaire des curvelets

3.4.1 Le modèle de normalité

L'inconvénient en considérant l'ensemble des coefficients de la représentation parcimonieuse par curvelets provient de la caractérisation des signatures inusuelles. Ces dernières correspondent à une infime partie du patch entraînant des modifications des coefficients non suffisantes pour les détecter (Figure 3.5). L'inefficacité de l'approche provient de la variabilité de l'information normale due au décalage, à l'absence et à la non-complétude des raies normales noyant les altérations des coefficients apportées par les raies atypiques. Bien que des atomes représentant les données normales soient différents, plusieurs d'entre eux sont communs sur plusieurs patchs et caractérisent la même information sur ces derniers. Ces atomes du dictionnaire définissent le comportement normal des patchs et donc la normalité que nous cherchons à caractériser. La reconstruction à partir des atomes de normalité sélectionnés permet ainsi de définir un estimation normale du patch considéré. La caractérisation d'un modèle de normalité permet de retirer ces informations normales des données et de réduire leur variabilité afin de mettre en évidence les signatures inusuelles présentes sur les patchs au niveau des résidus de la reconstruction.

Le support d'un patch

Nous avons défini l'activation d'un atome lors de la représentation dans le dictionnaire d'un patch $Z_{\mathcal{K}_j}$ par la valeur du coefficient associé à cet atome supérieure au seuil d'activation s_a . L'activation d'un atome signifie la présence d'une forme courbe colinéaire à cet atome. La plupart des atomes ne sont pas utiles pour caractériser l'intégralité du patch (Figure 3.3 et 3.4) car caractérisent des orientations de raies inexistantes dans les spectrogrammes normaux. Nous définissons donc le support d'un patch $Z_{\mathcal{K}_j}^i$ comme étant l'ensemble des atomes du dictionnaire activés dans la représentation en curvelets (3.6). Ce support correspond donc à l'ensemble des indices des coefficients qui sont considérés comme significatifs.

$$Supp(Z_{\mathcal{K}_j}^i) = \bigcup_{j_1, k, \theta} \left\{ (j_1, k, \theta) \mid \mathcal{C}_{Z_{\mathcal{K}_j}^i}(j_1, k, \theta) \geq s_a \right\} \quad (3.6)$$

Le seuil d'activation peut être défini de 2 manières :

1. en définissant un seuil comme étant la valeur minimale qu'un coefficient doit avoir pour être considéré comme significatif, ce seuil est donc identique pour tous les patchs,
2. en définissant un certain pourcentage p_a de conservation des coefficients ; il s'agit de définir le seuil comme étant la valeur de coefficient permettant d'obtenir ce pourcentage

$$s_a = \tilde{\mathcal{C}}_{\mathcal{K}_j}^i(p_a \times \text{card}(\mathcal{C}_{\mathcal{K}_j}^i))$$

avec $\tilde{\mathcal{C}}$ les coefficients ordonnées dans l'ordre décroissant. Ce seuil est différent selon le patch étudié.

Nous avons sélectionné la seconde approche permettant de considérer chaque patch séparément et de comparer les valeurs intrinsèques des coefficients de la représentation. Cette valeur de p_a correspond donc au taux minimal de coefficients permettant une bonne reconstruction. Les figures 3.3 et 3.4 détaillaient la reconstruction des patchs suivant un pourcentage de conservation des coefficients. La reconstruction à partir de 10% des coefficients permettaient de ne visuellement pas perdre d'information dans les résidus. Cette même reconstruction à 5% semble "flouter" les raies d'intensités faibles et retirer de l'information dans les résidus. De plus, le support contient l'intégralité des coefficients de l'échelle la plus grossière qui consistent en 1024 coefficients, en considérant une sélection de 5% (soit 2304 coefficients), la moitié des coefficients correspondraient alors à l'échelle grossière. La prise en compte d'un plus grand nombre de coefficients rend la reconstruction plus fine et plus pertinente pour la suite de l'étude. Nous avons donc fait le choix de considérer :

$$p_a = 0.1$$

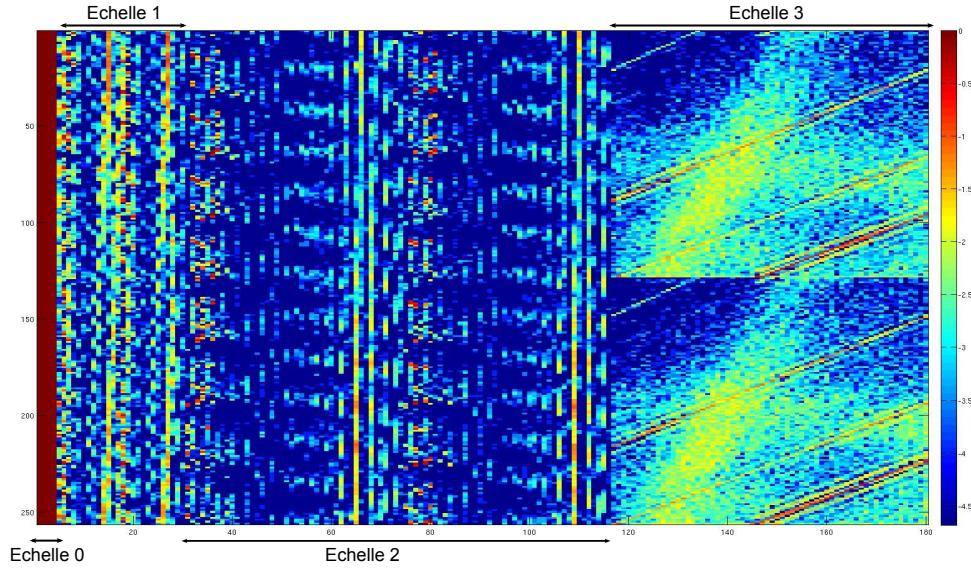


FIGURE 3.6 – Proportion (du bleu au rouge) des atomes de curvelets activés sur l’ensemble de la base de données. Les flèches renseignent sur l’échelle de ces atomes.

Le support de normalité

La transformée en curvelet inverse à partir des atomes du support permet une reconstruction satisfaisante du patch et donc des raies normales et inusuelles (Figure 3.4). Afin de détecter ces dernières, nous sommes plus intéressés par une reconstruction des signatures normales en supprimant les anomalies présentes sur les patchs afin de récupérer une représentation normale des patchs. Les signatures atypiques se retrouvent alors au niveau des résidus de la reconstruction. Nous cherchons à caractériser à partir des atomes du dictionnaire la normalité des patchs, cette normalité est caractérisée par la redondance des signatures normales sur les patchs. Au niveau des atomes du dictionnaire, cette redondance correspond aux mêmes atomes activés sur les différentes données. Nous cherchons donc le support commun des atomes du dictionnaire sur les patchs sans signatures inusuelles définissant le comportement normal du patch. Ce support commun de normalité correspond à l’union/intersection des différents supports (3.6) des patchs normaux de notre base d’apprentissage normale Ω_{App} . La figure 3.6 présente pour chaque atome du dictionnaire des curvelets, la proportion de données pour lesquelles l’atome considéré est activé, c’est-à-dire faisant partie du support du patch. Nous pouvons remarquer que les atomes basses fréquences (échelle 0) sont fortement activés ainsi que plusieurs atomes du dictionnaire d’échelle plus fine.

L’intersection des supports reviendrait à sélectionner les atomes activés sur tous les patchs normaux, ainsi seuls les atomes correspondant à l’échelle la plus grossière (échelle 0) seraient retenues. Ce support de normalité correspond uniquement aux basses fréquences et n’est pas suffisant pour caractériser les comportements normaux. L’union des supports permettraient de récupérer tous les atomes activés au moins une fois dans la base d’apprentissage normale. Cependant, cela revient à sélectionner des atomes activés pour une unique donnée, cet atome ne généralise pas le

comportement normal des patchs et ne devrait pas être retenu de notre point de vue. De plus, en considérant l'union de tous les supports, la dimension du support de normalité est la même que celle de l'intégralité des coefficients de curvelets due à la récupération de nombreux supports isolés.

L'approche que nous préconisons se trouve entre les deux, nous récupérons comme support de normalité $Supp^*$ (3.7) l'union des atomes des supports sous la contrainte d'appartenance à une certaine proportion Q des supports de la base d'apprentissage normale, c'est-à-dire qu'il doit exister un sous-ensemble de taille Q de la base d'apprentissage normale dans lequel l'atome considéré appartient à l'intersection des supports.

$$Supp^* = \bigcup_{i \in \Omega_{App}} \left\{ (j_1, k, \theta) \in Supp(Z_{\mathcal{K}_j}^i) \& \text{card}((j_1, k, \theta) \in Supp(\Omega_{App})) \geq Q \text{ card}(\Omega_{App}) \right\} \quad (3.7)$$

avec $Supp(\Omega_{App})$ les supports des coefficients des patchs de la base d'apprentissage.

Cette approche permet de trouver un support d'atomes de normalité commun aux patchs normaux tout en supprimant les atomes ne généralisant pas le comportement normal. La dimension de $Supp^*$ diminue rapidement en fonction de Q (figure 3.7a). L'union entraînait donc bien la récupération d'atomes isolés, cette forte décroissance suggère de prendre une valeur de Q plus proche de 0 que de 100 pour éviter de récupérer uniquement les basses fréquences. Sur la figure 3.7b, nous avons tracé la reconstruction de 2 patchs inusuels par rapport à différentes valeurs de Q allant de 0% à 100% par pas de 10%. Des artefacts liés aux signatures inusuelles sont présents dans la reconstruction malgré la sélection du support normal. Cela est dû à la sélection des atomes basses fréquences reconstruisant grossièrement ces signatures atypiques. Nous cherchons à obtenir de bonnes reconstructions des raies normales tout en supprimant le plus possible les informations inusuelles. Les sélections des supports à $Q = 10\%$ et $Q = 20\%$ permettent une bonne reconstruction des raies normales. Nous avons donc opté pour une valeur de Q comprise entre ces 2 valeurs.

$$Q = 15\%$$

La reconstruction normale $\hat{Z}_{\mathcal{K}_j}^*$ (3.8) à partir de ce support de normalité est alors définie par la transformée en curvelet inverse \mathcal{C}^{-1} restreinte au support $Supp^*$ de la transformée en curvelet \mathcal{C} du patch $Z_{\mathcal{K}_j}$.

$$\hat{Z}_{\mathcal{K}_j}^{i*} = \mathcal{C}_{Z_{\mathcal{K}_j}^i | Supp^*}^{-1} \quad (3.8)$$

Nous avons mis en place une procédure permettant de sélectionner automatiquement un support des atomes du dictionnaire des curvelets caractérisant le comportement normal du patch. Ce support est défini sur la base d'apprentissage Ω_{App} comme l'union des atomes appartenant à $Q\%$ des supports de la base d'apprentissage. Les supports de chaque patch sont définis par un seuil sur les coefficients. Ce dictionnaire est par la suite vérifié visuellement à partir de la reconstruction des données où nous pouvons voir apparaître des artefacts autour des signatures

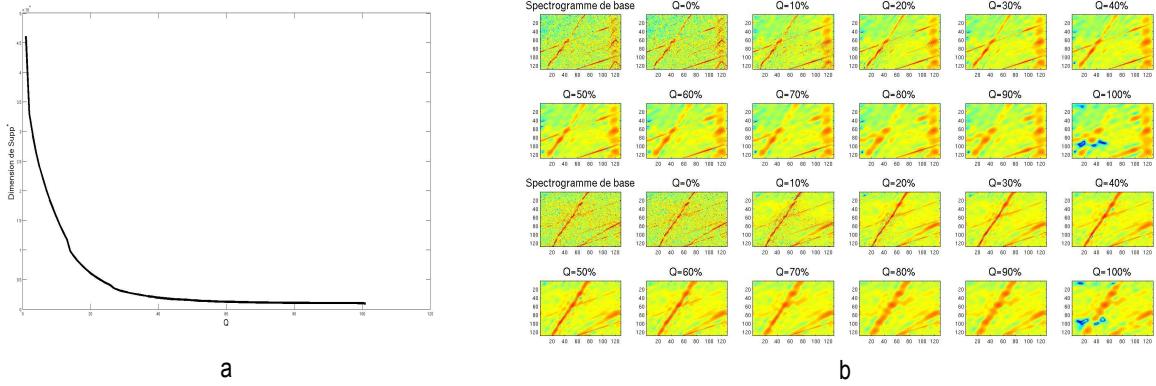


FIGURE 3.7 – Dimension de Supp^* en fonction de Q (a) et reconstruction de 2 patchs inusuels à partir des atomes de Supp^* définis pour différentes valeurs de Q (b). La dimension du support de normalité diminue rapidement en fonction de la proportion Q de supports communs. Les signatures atypiques sont reconstruites grossièrement dus aux atomes basses fréquences.

inusuelles (Figure 3.7b). Il est alors possible de projeter les patchs dans ce dictionnaire par le système de transformée en curvelet inverse restreinte au support, afin d'obtenir une estimation normale de ces mêmes patchs (figure 3.10).

3.4.2 Normalité définie par optimisation avec contraintes de parcimonie

Nous avons défini le dictionnaire \mathcal{D}^C des curvelets (3.5). Nous cherchons alors à partir de ce dictionnaire surcomplet à trouver la meilleure représentation parcimonieuse (en sélectionnant les atomes) des patchs normaux de la base d'apprentissage en optimisant la fonctionnelle :

$$C^* = \underset{C}{\operatorname{argmin}} \left\{ \|Z_{\mathcal{K}_j}^{\Omega_{App}} - \mathcal{D}^C C\|_2^2 + \lambda \|C\|_1 \right\}. \quad (3.9)$$

Nous considérons alors le support commun des atomes à coefficients non nuls pour caractériser le comportement normal des patchs. Afin de résoudre la fonctionnelle (3.9), nous utilisons la méthode d'optimisation Alternating direction method of multipliers (ADMM) [16]. Il s'agit d'une méthode d'optimisation robuste qui s'applique sur des fonctionnelles séparées, elle permet d'optimiser des fonctionnelles de la forme suivante :

$$f(x) + g(z) \text{ sous la contrainte } Ax + Bz = c$$

On voit bien sous cette forme que les fonctions f et g sont séparées. L'équation (3.9) n'est pas encore sous cette forme, nous donnons une forme équivalente respectant les critères pour pouvoir utiliser la méthode ADMM. (3.10).

$$(c_1^*, c_2^*, c^*) = \underset{c_1, c_2, c}{\operatorname{argmin}} \left\{ \|c_1\|_1 + \alpha \|Z_{\mathcal{K}_j}^{\Omega_{App}} - c_2\|_2^2 \right\} \text{ sous la contrainte } \begin{pmatrix} I_d \\ \mathcal{D}^C \end{pmatrix} c = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} \quad (3.10)$$

Cette formulation est équivalente à la précédente car $c_1 = c$ et $c_2 = \mathcal{D}^C$, ainsi en remplaçant

ces termes dans (3.10) nous retrouvons (3.9). Nous avons donc bien deux fonctionnelles séparées avec $f(c_1) = \|c_1\|_1$ et $g(c_2) = \alpha\|Z_{\mathcal{K}_j}^{\Omega_{App}} - c_2\|_2^2$ avec des contraintes d'égalité. Pour résoudre cette fonctionnelle, nous calculons le lagrangien augmenté en fonction de $\lambda = \begin{pmatrix} \lambda_1 \\ \lambda_2 \end{pmatrix}$.

$$\mathcal{L}_a(c, c_1, c_2, \lambda) = \|c_1\|_1 + \alpha\|Z_{\mathcal{K}_j}^{\Omega_{App}} - c_2\|_2^2 + \left\langle \lambda, \begin{pmatrix} I_d \\ \mathcal{D}^c \end{pmatrix} c - \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} \right\rangle + \frac{\rho}{2} \left\| \begin{pmatrix} I_d \\ \mathcal{D}^c \end{pmatrix} c - \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} \right\|_2^2$$

$$\mathcal{L}_a(c, c_1, c_2, \lambda) = \|c_1\|_1 + \alpha\|Z_{\mathcal{K}_j}^{\Omega_{App}} - c_2\|_2^2 + \frac{\rho}{2} \left\| \frac{\lambda}{\rho} + \begin{pmatrix} I_d \\ \mathcal{D}^c \end{pmatrix} c - \begin{pmatrix} c_1 \\ c_2 \end{pmatrix} \right\|_2^2 + cste(\lambda)$$

Il s'agit d'optimiser ce lagrangien augmenté en fonction de chacune des variables. La méthode d'optimisation est itérative avec :

$$c_1^{k+1} = \operatorname{argmin}_{c_1} \left\{ \mathcal{L}_a \left(c^k, c_1, c_2^k, \lambda^k \right) \right\} = \operatorname{prox} \left(\frac{1}{\rho} \|\cdot\|_1; \tilde{c}_1 \right) = \operatorname{sign}(\tilde{c}_1) \cdot \max \left(\tilde{c}_1 - \frac{1}{\rho}, 0 \right)$$

avec $\tilde{c}_1 = \frac{\lambda_1^k}{\rho} + c^k$. Les opérateurs proximaux sont définis dans [88].

$$\begin{aligned} c_2^{k+1} &= \operatorname{argmin}_{c_2} \left\{ \mathcal{L}_a \left(c^k, c_1^{k+1}, c_2, \lambda^k \right) \right\} = \frac{2\alpha Z_{\mathcal{K}_j}^{\Omega_{App}} + \rho \tilde{c}_2}{2\alpha + \rho} \quad \text{avec } \tilde{c}_2 = \frac{\lambda_2^k}{\rho} + \mathcal{D}^c c^k \\ c^k &= \operatorname{argmin}_c \left\{ \mathcal{L}_a \left(c, c_1^k, c_2^k, \lambda^k \right) \right\} = (I_d - \mathcal{C}) \left[\begin{pmatrix} c_1^{k+1} \\ c_2^{k+1} \end{pmatrix} - \frac{\lambda^k}{\rho} \right] \\ \lambda^{k+1} &= \lambda^k + \rho \left[\begin{pmatrix} I_d \\ \mathcal{D}^c \end{pmatrix} c^{k+1} - \frac{c_1^{k+1}}{c_2^{k+1}} \right] \end{aligned}$$

Cette approche va permettre de converger vers la solution (c^*, c_1^*, c_2^*) , et donc vers une décomposition parcimonieuse (ou avec des coefficients très faibles) dans le dictionnaire des curvelets. Il s'agit d'une seconde méthode pour calculer les coefficients de curvelets en imposant de la parcimonie. Il reste alors à sélectionner les atomes caractérisant le comportement normal.

Ces atomes du support des patchs sont sélectionnés par un seuillage des coefficients calculés sur les patchs normaux (3.6). La grande majorité des coefficients calculés à partir de cette méthode sont d'intensité très faibles, proches de 0, nous définissons alors le seuil à partir d'une proportion de coefficients à conserver de 10%. Le support de normalité est alors défini de manière analogue à (3.7) avec les mêmes métaparamètres.

3.4.3 Comparaison des supports normaux

Nous comparons les supports définis directement sur la représentation en curvelets et à partir de la méthode ADMM, ainsi que le pourcentage d'atomes actifs communs et visualisons la

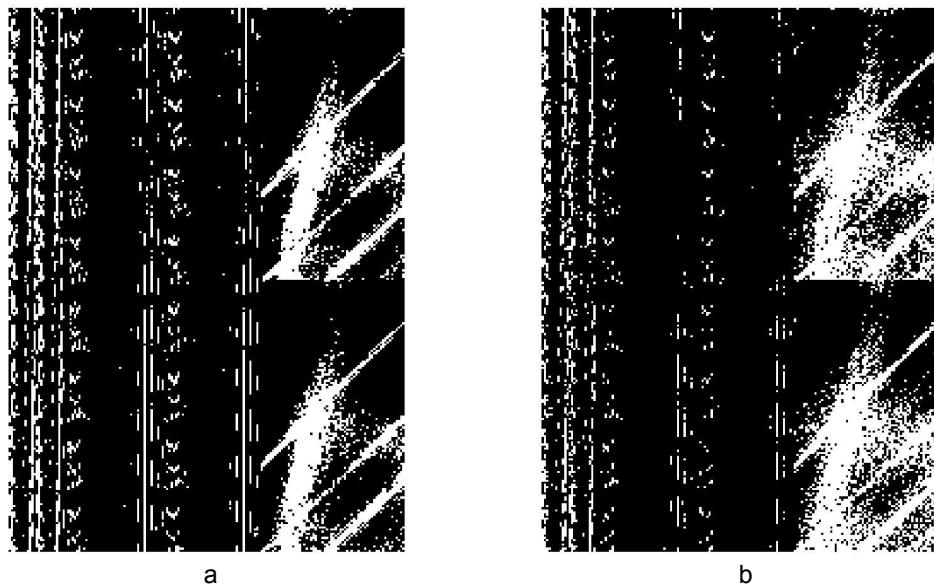


FIGURE 3.8 – Supports définis directement sur la transformée en curvelet (a) et à partir d’ADMM (b). Les points blancs correspondent aux atomes activés. Plusieurs atomes sont communs aux 2 approches, l’approche à partir d’ADMM récupère plus d’atomes dans les échelles les plus fines.

reconstruction des patchs normaux et inusuels à partir de ces différents supports. Cette étude a été effectuée sur un patch uniquement et non sur l’ensemble.

La dimension des deux supports ainsi définis n’est pas la même ; le support défini directement à partir de la transformée en curvelets possède 8288 atomes tandis que celui défini à partir d’ADMM considère 9548 atomes. Ces supports ont été définis avec le même métaparamètre Q qu’est la proportion de données pour laquelle l’atome doit être activé afin d’appartenir au modèle de normalité. Ces deux supports possèdent 6381 atomes en commun (soit environ 77% des atomes définis directement à partir de la transformée en curvelets). La majorité des atomes sélectionnés sur les patchs normaux étant identiques, nous pouvons supposer que nos méthodes ont bien capturé les comportements normaux de ces patchs. La figure 3.8 contient un tracé des supports pour les deux approches, nous pouvons y avoir clairement les nombreux supports communs et une dimension plus importante du support avec l’approche ADMM.

Les supports restent différents, la reconstruction définie par (3.8) à partir de la restriction au support l’est également. La figure 3.9 présente la reconstruction de patchs normaux et atypiques à partir de ces différents supports définis directement dans la transformée en curvelet (centre) et à partir d’ADMM (droite). Les deux premières lignes correspondent à des patchs normaux, les trois suivantes à des patchs contenant des signatures inusuelles. Les reconstructions à partir des deux supports sont assez similaires et proches de la donnée d’entrée, les modèles ont réussi à caractériser les informations normales des patchs. Les signatures inusuelles ne sont pas totalement supprimées lors de la reconstruction. Cette reconstruction correspond à la représentation basses fréquences des raies atypiques qui se retrouvent représentées de manière plus grossière.

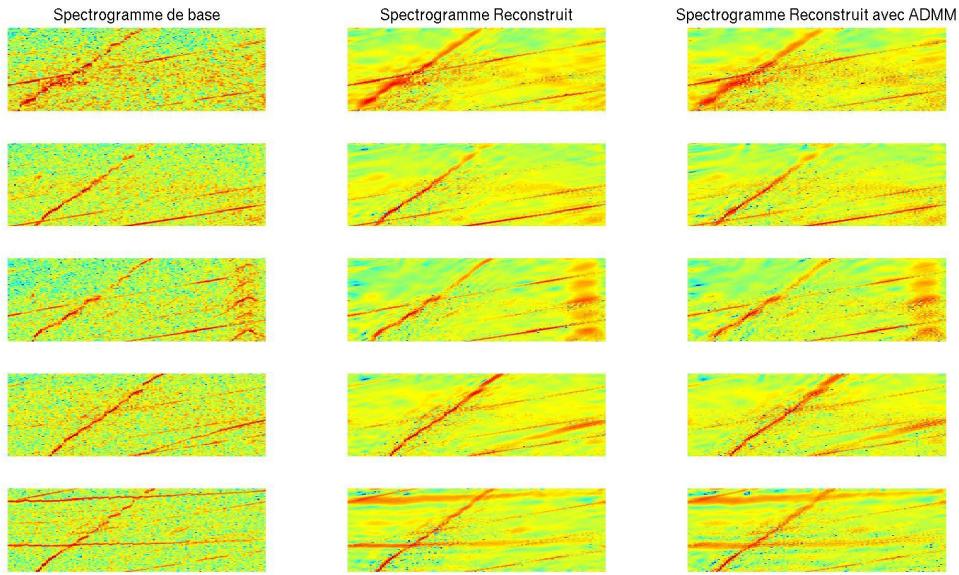


FIGURE 3.9 – Reconstruction à partir des supports de normalité pour 2 patchs normaux (premières lignes) et des patchs contenant des signatures inusuelles. La première colonne correspond au patch étudié, la seconde à la reconstruction à partir du support de normalité défini sur la transformée, et la dernière à la reconstruction à partir du support défini par ADMM.

Nous pouvons remarquer qu'une des raies normales possède une reconstruction floutée. Il s'agit de la raie N_1 translatée sur les différents spectrogrammes. Ce flou semble plus important sur les reconstructions définies avec ADMM. De plus la définition du support est plus couteuse à partir d'ADMM comme il s'agit d'une méthode itérative. La différence entre les deux supports n'étant pas significative, nous avons opté pour l'approche définissant le support directement sur la transformée en curvelet pour la suite. Nous notons $\mathcal{D}_{Supp^*}^C$ le dictionnaire défini par les atomes des curvelets de $Supp^*$, il s'agit du dictionnaire de normalité défini à partir de celui des curvelets.

3.5 Le score de détection d'anomalies sur le patch

3.5.1 Les scores de détection

Differentes mesures de détection d'anomalies sont possibles à partir de la représentation en curvelets. L'une d'entre elles est les k plus proches voisins (k-nn) [49] dans le domaine des curvelets afin de déterminer de quelle classe une nouvelle donnée est la plus proche. Une seconde approche de même nature concerne la distance à la plus proche donnée normale. Ces deux approches correspondent à des méthodes de détection de nouveautés basées sur les distances mais n'utilisent pas le modèle de normalité défini au-dessus. Elles sont calculées uniquement à partir de la représentation en curvelets seuillée. Cependant, nous avons vu sur la figure 3.5 que la distance entre les coefficients des curvelets ne permet pas de discriminer les patchs normaux

des patchs atypiques.

Une approche plus pertinente consiste à projeter les données dans le modèle de normalité afin d'obtenir une reconstruction normale $\hat{Z}_{\mathcal{K}_j}^{i*}$ avec une réduction des signatures inusuelles. Cette estimation normale est alors comparée à la donnée d'origine (3.11) pour obtenir une erreur de reconstruction. Ce type d'approche est semblable aux approches de détection de nouveautés basées sur la reconstruction des données.

$$d_{ER}^c(Z_{\mathcal{K}_j}^i) = \left\| Z_{\mathcal{K}_j}^i - \hat{Z}_{\mathcal{K}_j}^{i*} \right\|_2^2 \quad (3.11)$$

$\hat{Z}_{\mathcal{K}_j}^{i*}$ correspond à l'estimation normale du patch $Z_{\mathcal{K}_j}^i$ définie en (3.8). Cette erreur de reconstruction modélise les résidus entre le patch et son estimation normale définie à partir du modèle de normalité. Un patch normal est bien représenté par le modèle de normalité et possède des résidus faibles tandis qu'un patch contenant des signatures atypiques a ces dernières mal caractérisées par le modèle de normalité augmentant les résidus de la reconstruction. La figure 3.10 présente les reconstructions avec les résidus associés de trois patchs, le premier considéré comme normal et les deux autres contenant des signatures atypiques. Nous pouvons observer que le modèle permet de reconstruire correctement les raies normales sur tous les patchs étudiés, les raies liées au N_1 ne sont pas totalement modélisées du fait de leurs décalages. La reconstruction du patch normal est très proche visuellement du patch réel. Les résidus font apparaître uniquement la structure liée au N_1 . Les signatures inusuelles sur les patchs atypiques sont reconstruites grossièrement avec des intensités plus faibles. Ces signatures sont donc mises en évidence au niveau des résidus de la reconstruction normale. Le modèle défini permet donc bien d'avoir une estimation normale des patchs étudiés avec des artefacts au niveau des raies inusuelles correspondant à une reconstruction plus large et plus grossière de ces dernières. Ces artefacts entraînent donc une augmentation de l'erreur de reconstruction (3.11).

3.5.2 Le score de normalité

Le score de normalité est défini comme un test d'hypothèses statistiques [72] \mathcal{H}_0 contre \mathcal{H}_1 . Ce test est effectué sur chaque patch indépendamment, $\text{card}(\mathcal{K}^{128})$ tests sont à effectuer sur chaque spectrogramme, nous notons $\mathcal{H}_{0,j}^i$ le test associé au patch j du spectrogramme i . Nous définissons alors un ensemble de tests.

$$\{\mathcal{H}_{0,j} : \text{le patch } j \text{ est normal vs } \mathcal{H}_{1,j} : \text{le patch } j \text{ est atypique}\}$$

Pour répondre à ce test, nous modélisons la distribution du score de détection d'erreur de reconstruction défini dans la section 3.5.1 par une loi gamma. Les données utilisées pour modéliser cette distribution correspondent aux scores d'erreur de reconstruction des patchs normaux de la base de validation Ω_{Val} . L'estimation des paramètres de la loi gamma $\hat{\Gamma}$ se fait par maximum de vraisemblance. L'utilisation d'une distribution pour caractériser les erreurs de reconstruction permet de définir un seuil de détection valable sur tous les patchs. Cette distribution complète

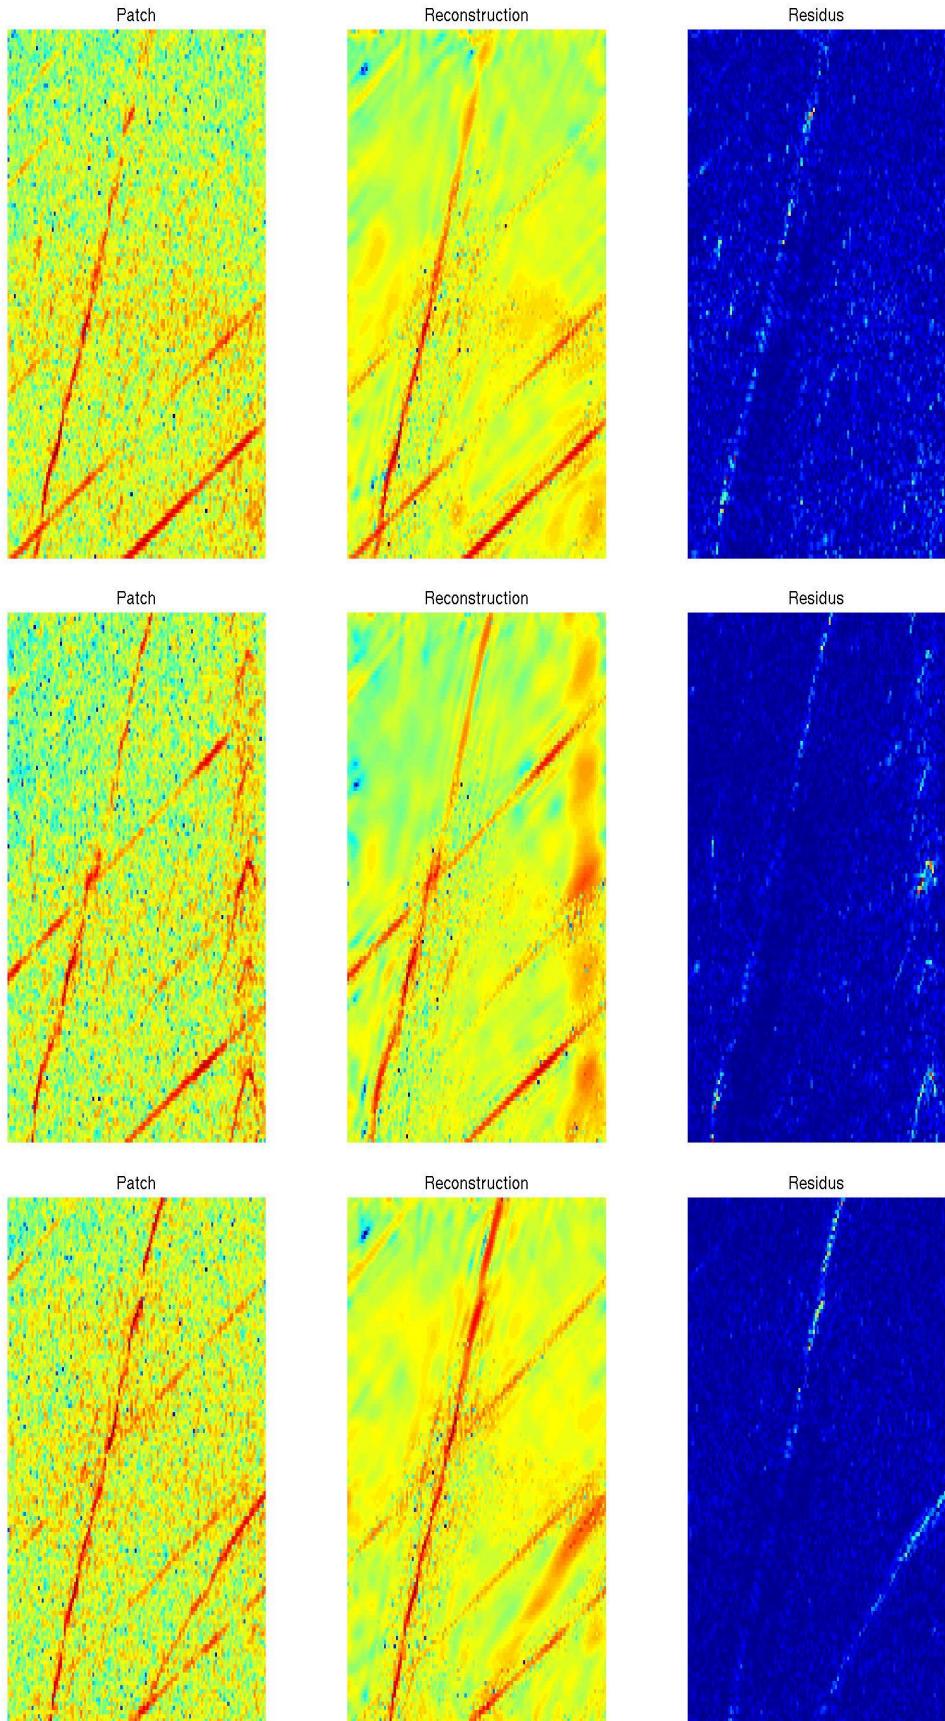


FIGURE 3.10 – Reconstruction de 3 patchs à partir du dictionnaire $\mathcal{D}_{Supp^*}^C$ avec les résidus de reconstruction. La première ligne correspond à un patch normal et les deux suivantes à des patchs contenant des signatures inusuelles

le modèle de normalité. Ce dernier est donc caractérisé par un dictionnaire de normalité dans lequel les données sont projetées pour obtenir une estimation normale des patchs dont l'erreur de reconstruction est calculée par rapport aux données réelles afin d'être comparée à la distribution de normalité $\hat{\Gamma}$ estimée sur les scores des données normales.

Le score de normalité correspond à la p-valeur (3.12) du test statistique défini ci-dessus, sachant que la loi sous $\mathcal{H}_{0,j}$ est approximée par la loi gamma $\hat{\Gamma}$.

$$pval_j^i = \mathbb{P}_{\mathcal{H}_{0,j}}(X > d_{ER}^C(Z_{K_j}^i)) \approx \mathbb{P}_{\hat{\Gamma}}(X > d_{ER}^C(Z_{K_j}^i)) = 1 - F_{\hat{\Gamma}}(d_{ER}^C(Z_{K_j}^i)) \quad (3.12)$$

La variable aléatoire X suit la loi définie par la probabilité et $F_{\hat{\Gamma}}$ est la fonction de répartition de $\hat{\Gamma}$. Plus cette p-valeur est faible, plus cela signifie que l'erreur de reconstruction est importante car elle se trouve dans les valeurs extrêmes du modèle et donc plus le patch peut être considéré comme atypique. Nous nous intéressons principalement à la queue de distribution permettant la détection des patchs inusuels. La détection de ces patchs est alors effectuée par la comparaison de la p-valeur du patch à un seuil s .

$$\hat{Y}_{Z_{K_j}}^i = \begin{cases} 1 & \text{si } pval_j^i \leq s \\ 0 & \text{sinon} \end{cases}$$

3.5.3 Résultats sur la base de test

Dans la section 2.4, nous avons défini la base de test sur laquelle nous présentons les résultats. Nous disposons dans notre base de données d'un unique moteur déclaré comme endommagé. Les autres disposent de signatures inusuelles faibles dans leurs spectrogrammes insuffisantes pour correspondre à des endommagements des moteurs mais suffisantes pour considérer les patch étudiés comme atypiques. Dans un premier temps nous allons présenter des résultats comparatifs entre le moteur endommagé et des moteurs normaux. Nous présenterons ensuite les résultats sur l'ensemble des patchs de la base de test.

Afin de donner les résultats sur le moteur endommagé nous considérons 2 différents patchs, le premier contenant les signatures anormales qui ont permis de déclarer ce moteur comme endommagé, et le second ne présentant pas d'anomalie pour toute la base de test, y compris pour le moteur endommagé. Dans le chapitre 1, nous avons défendu la décomposition en patchs comme une procédure afin de donner une localisation de l'anomalie. Il est donc important que le moteur endommagé soit détecté uniquement sur le patch caractérisant son état. Pour vérifier cela, nous donnons les p-valeurs des tests statistiques (Tableau 3.1) calculés sur le moteur endommagé à partir du modèle de normalité défini par $\mathcal{D}_{Supp^*}^C$ et les comparons aux moteurs considérés comme normaux sur les mêmes patchs. Les résultats des moteurs normaux correspondent à la moyenne des p-valeurs des spectrogrammes normaux sur le patch considéré.

Le moteur endommagé se distingue très bien sur le patch contenant les signatures anormales

TABLE 3.1 – P-valeurs des tests statistiques issus de l'erreur de reconstruction basée sur $\mathcal{D}_{Supp^*}^C$ du moteur endommagé et des moteurs normaux sur le patch contenant les signatures anormales qui ont permis la détection de l'endommagement et sur un patch ne présentant aucune signature atypique sur l'ensemble de la base de test.

	Patch avec signature inusuelle	Patch sans signature inusuelle
Moteur avec endommagement	$< 10^{-16}$	0.27 ± 0.04
Moteur sans endommagement	0.57 ± 0.03	0.44 ± 0.03

avec des p-valeurs très faibles. Les moteurs normaux ont des p-valeurs classiques sur ce patch et le patch normal permettant de ne pas les détecter, de même pour le moteur endommagé sur le patch normal. Ces résultats montrent de bonnes performances de détection du moteur endommagé uniquement sur le patch présentant des évidences du dégât et de non-détection au niveau des autres patchs.

Étude sur tous les patchs des moteurs contenant des signatures inusuelles

Ces résultats sont établis sur le moteur endommagé présentant des signatures inusuelles en grand nombre et en intensités plus importantes. La détection de ce moteur spécifique est ainsi assez aisée sur ce patch. Nous ne cherchons pas à détecter uniquement les signatures liées au moteur endommagé mais toutes signatures atypiques présentes dans les différents patchs. La figure 3.11 illustre la détection des signatures inusuelles pour l'ensemble des patchs de la base de test Ω_{Test} à partir d'un seuil sur les p-valeurs. La figure supérieure correspond à la vérité terrain, chaque ligne caractérise un moteur et chaque colonne un patch, la couleur blanche au niveau d'un case (i, j) indique la présence de signatures inusuelles sur le patch j du moteur i . La figure inférieure, définie de manière identique, illustre les détections de l'algorithme basées sur les erreurs de reconstruction avec un seuil sur les p-valeurs fixé à 0.1. Ces résultats montrent de mauvaises performances de cette méthode sur des patchs contenant des signatures inusuelles faibles, plusieurs patchs ne sont pas détectés ou détectés à tort. Le seuil utilisé n'a pas d'influence sur les résultats, la courbe ROC associé à cette procédure de détection est proche de la première bissectrice.

Cette méthode permet donc la détection des signatures anormales sur le spectrogramme du moteur endommagé. Il s'agit de signatures vibratoires suffisamment conséquentes pour impacter l'erreur de reconstruction. Cependant, pour les spectrogrammes contenant des signatures atypiques faibles, elle ne permet pas leur détection. Ces signatures inusuelles, correspondant en quelques points sur des patchs de taille 128×128 , ne sont pas suffisantes pour influencer la distance en grande dimension. De plus certaines raies normales d'intensités plus importantes sont mal représentées par le dictionnaire entraînant des résidus importants et faussant la détection. Etablir un score de détection sur le patch global noie les signatures inusuelles qui ne correspondent qu'à quelques points. La détection doit donc s'effectuer à cette échelle ponctuelle.

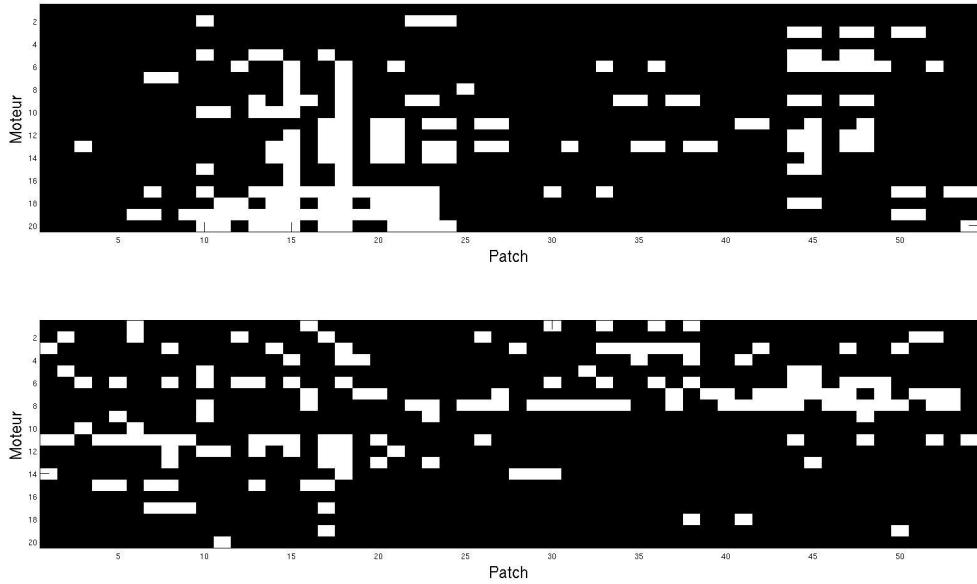


FIGURE 3.11 – Matrice de la vérité terrain (partie supérieure) des patchs des spectrogrammes de la base de test Ω_{Test} et classification (partie inférieure) à partir d'un seuil sur les p-valeurs calculées à partir du modèle de normalité défini par le dictionnaire des curvelets. Chaque ligne correspond à un moteur de la base de test et chaque colonne à un des patchs de la subdivision. La couleur blanche correspond à la présence d'une signature atypique sur le patch du spectrogramme défini respectivement par la colonne et la ligne. De nombreuses différences sont présentes entre le la matrice supérieure (vérité terrain) et la classification obtenue à partir de l'algorithme (partie inférieure) illustrant de mauvaises performances de détection des patchs contenant des signatures atypiques faibles.

3.6 L'étude des résidus ponctuels

3.6.1 Les résidus du modèle de normalité $\mathcal{D}_{Supp^*}^C$

Les résidus de reconstruction des patchs à partir des curvelets R_C (3.13) peuvent être modélisés par une gaussienne centrée en 0 (Figure 3.12). A la différence d'une erreur l_2 globale sur ces résidus, la signification des différents résidus n'est pas la même en les considérant ponctuellement.

$$R_C(Z_{\mathcal{K}_j}^i) = Z_{\mathcal{K}_j}^i - \hat{Z}_{\mathcal{K}_j}^{i*} \quad (3.13)$$

Nous distinguons 3 classes de résidus apportant différentes informations sur le modèle de normalité :

- les résidus positifs de fortes amplitudes (Figure 3.12 rouge) correspondant aux signatures mal caractérisées par le modèle de normalité, les signatures inusuelles font partie de cette classe de signatures, les points atypiques appartiennent à cette catégorie de résidus,
- les résidus d'amplitudes proches de 0 (Figure 3.12 noir) correspondent aux points très bien caractérisés par le dictionnaire de normalité, il s'agit de points dont la reconstruction normale est proche de leurs vérités terrain, les points composant les raies N_2 appartiennent

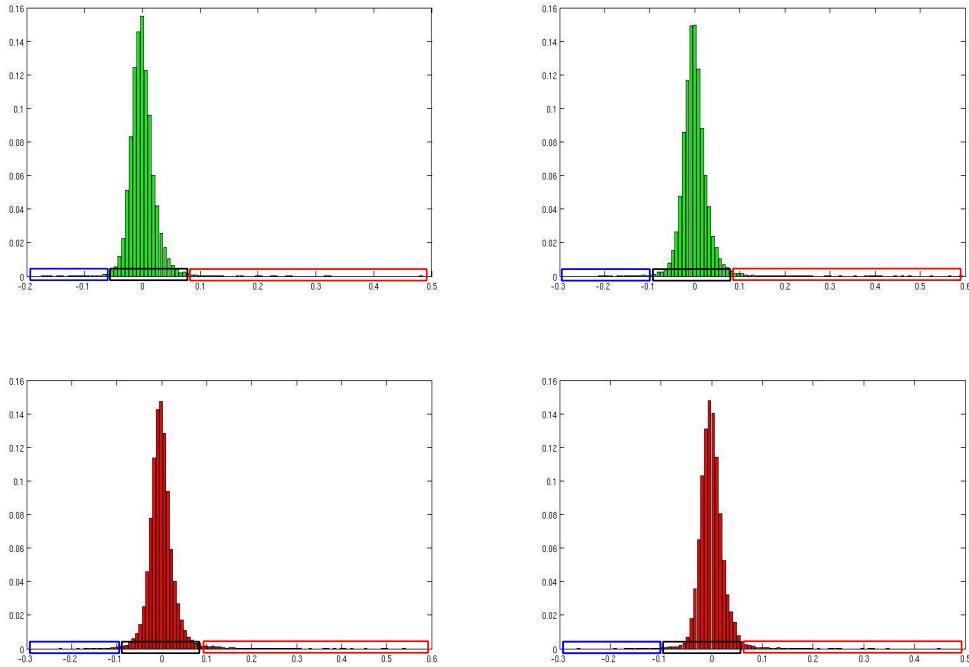


FIGURE 3.12 – Histogrammes des résidus définis à partir du modèle de normalité des curvelets pour différentes données. La première ligne correspond à des patchs normaux (vert), la seconde à des patchs inusuels (rouge). Les cadres correspondent aux différentes catégories de résidus avec dans le cadre noir les points bien représentés par le dictionnaire, dans le cadre rouge les points mal représentés et dans le cadre bleu les artefacts créés par le dictionnaire. Les résidus possèdent une allure de gaussienne.

- à cette catégorie de résidus,
- les résidus négatifs de fortes amplitudes (Figure 3.12 bleu) correspondent aux artefacts créés par le dictionnaire, il s'agit de points dont les intensités sur la reconstruction normale sont plus importantes que celles des points réels, pour le dictionnaire des curvelets, ces artefacts se trouvent autour des signatures atypiques.

Nous nous intéressons aux résidus de chaque point du patch. Cette approche est radicalement différente de la précédente où nous comparions les erreurs de reconstruction globales entre les patchs similaires de la base de données. Cette méthode compare les résidus intra-patch d'une même donnée car nous considérons que les points inusuels correspondent aux extrêmes des résidus de la reconstruction définie à partir du modèle de normalité $\mathcal{D}_{Supp^*}^C$.

3.6.2 La détection d'anomalies

Les résidus caractérisant les signatures atypiques se trouvent donc dans la première catégorie, les résidus positifs. De plus, la reconstruction des signatures inusuelles engendre des artefacts autour de ces dernières. Ces artefacts sont caractérisés par des résidus négatifs (3ème catégorie)

permettant également de détecter les points atypiques. Nous utilisons ces deux types de résidus pour détecter les signatures inusuelles.

$$\begin{aligned} R_{\mathcal{C}}^+(Z_{\mathcal{K}_j}^i) &= \max(R_{\mathcal{C}}(Z_{\mathcal{K}_j}^i), 0) \\ R_{\mathcal{C}}^-(Z_{\mathcal{K}_j}^i) &= \max(-R_{\mathcal{C}}(Z_{\mathcal{K}_j}^i), 0) \end{aligned}$$

Nous nous intéressons aux extrêmes de ces deux résidus, les points inusuels sont caractérisés par de forts résidus positifs et les artéfacts autour de ces signatures par de forts résidus négatifs. Les artéfacts créés par le modèle de normalité se situent autour des raies inusuelles et des raies N_1 . Nous utilisons les résidus négatifs $R_{\mathcal{C}}^-$ pour améliorer la détection des points atypiques effectuée sur les résidus positifs $R_{\mathcal{C}}^+$.

Les points inusuels correspondent aux valeurs extrêmes des résidus positifs et sont détectés à partir d'un seuil sur ces derniers. Ce seuil est défini pour tous les patchs de toutes les données. Il ne doit donc pas être déterminé directement sur les valeurs des résidus car en fonction des données ou des patchs, ces valeurs peuvent correspondre à différents ordres de grandeur. Il faut donc que ce seuil soit défini sur une transformation des valeurs des résidus à partir de laquelle les différents résidus sont comparables ou qui tient compte de l'ordre de grandeur.

Un première méthode pour définir ce seuil consiste à considérer les résidus comme suivant une distribution gaussienne et de fixer un seuil les p-valeurs des tests statistiques d'adéquation à cette loi estimée. Un seuil peu être fixé pour les résidus positifs et les résidus négatifs. Nous définissons donc des p-valeurs pour les résidus postitifs et des p-valeurs pour les résidus négatifs.

$$pval^+(Z_{\mathcal{K}_j(f,N_2)}^i) \approx \mathbb{P}_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)}(X > R_{\mathcal{C}}^+(Z_{\mathcal{K}_j(f,N_2)}^i)) = 1 - F_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)}(R_{\mathcal{C}}^+(Z_{\mathcal{K}_j(f,N_2)}^i))$$

$$pval^-(Z_{\mathcal{K}_j(f,N_2)}^i) \approx \mathbb{P}_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)}(X < -R_{\mathcal{C}}^-(Z_{\mathcal{K}_j(f,N_2)}^i)) = F_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)}(-R_{\mathcal{C}}^-(Z_{\mathcal{K}_j(f,N_2)}^i))$$

$\hat{\mu}_j^i$ et $\hat{\sigma}_j^i$ sont la moyenne et la variance de la distribution gaussienne estimée sur les résidus $R_{\mathcal{C}}(Z_{\mathcal{K}_j}^i)$, X suit cette loi et $F_{\mathcal{N}(\hat{\mu}_j^i, \hat{\sigma}_j^i)}$ est la fonction de répartition associée à cette loi. $Z_{\mathcal{K}_j(f,N_2)}^i$ correspond à l'intensité vibratoire sur le spectrogramme i aux coordonnées (f, N_2) dans le patch j . Définir un seuil sur les p-valeurs revient donc à définir un seuil sur la fonction de répartition. Il est alors possible de reporter ce seuil sur chaque patch car le seuil de probabilité prend en compte l'ordre de grandeur des résidus. Le seuil est donc identique pour tous les patchs étudiés. La détection des points inusuels au sein des résidus positifs \tilde{Y}^{i+} et au sein des résidus négatifs \tilde{Y}^{i-} s'effectuent alors par comparaison des p-valeurs de chaque point au seuil de détection s_+ pour les résidus positifs et s_- pour les résidus négatifs.

$$\tilde{Y}_{f,N_2}^{i+} = \mathbb{1} \left\{ pval^+(Z_{\mathcal{K}_j(f,N_2)}^i) \leq s_+ \right\} \quad \tilde{Y}_{f,N_2}^{i-} = \mathbb{1} \left\{ pval^-(Z_{\mathcal{K}_j(f,N_2)}^i) \leq s_- \right\}$$

La théorie des valeurs extrêmes [37] est une deuxième méthode pour estimer un seuil sur les résidus. La distribution des valeurs extrêmes modélisée par une loi de Weibull, Gumbel ou Fréchet

caractérise la loi du maximum d'un jeu de données et est estimée à partir d'un sous-échantillon de taille n_{max} contenant les points maximaux. Le nombre de points de ce sous-échantillon impacte la distribution des valeurs extrêmes. Nous définissons le seuil de détection dans l'espace des résidus positifs et négatifs comme le mode de la distribution des valeurs extrêmes. Ce mode peut être considéré comme le maximum le plus probable.

$$s_{max}^+ = \operatorname{argmax} \left(f_{R_{C,n_{max}}^+}^e \right) \quad s_{max}^- = \operatorname{argmax} \left(f_{R_{C,n_{max}}^-}^e \right)$$

$f_{R_{C,n_{max}}^+}^e$ correspond à la distribution des valeurs extrêmes estimée à partir des n_{max} résidus positifs maximaux. Le seuil estimé est dépendant des résidus du patch et ne peut être reporté sur les autres. La distribution des valeurs extrêmes est donc estimée pour tous les patchs. La détection des points atypiques au sein des résidus positifs \hat{Y}^{i+} et au sein des résidus négatifs \hat{Y}^{i-} s'effectue respectivement par comparaison des résidus positifs et négatifs aux seuils s_{max}^+ et s_{max}^- .

$$\tilde{Y}_{f,N_2}^{i+} = \mathbb{1} \left\{ R_{\mathcal{C}}^+(Z_{\mathcal{K}_j(f,N_2)}^i) \geq s_{max}^+ \right\} \quad \tilde{Y}_{f,N_2}^{i-} = \mathbb{1} \left\{ R_{\mathcal{C}}^-(Z_{\mathcal{K}_j(f,N_2)}^i) \geq s_{max}^- \right\}$$

Ces 2 méthodes permettent la définition d'un seuil de détection automatique des points atypiques pour chaque patch étudié. Nous utilisons les points extrêmes des résidus positifs $R_{\mathcal{C}}^+$ pour trouver les points considérés comme inusuels. Pour chacun de ces points détectés nous vérifions qu'un certain nombre $n_{voisins}$ de points de leur voisinage \mathcal{V}_{f,N_2} sont détectés dans les résidus négatifs $R_{\mathcal{C}}^-$, ces points correspondent aux artefacts créés par le dictionnaire de normalité autour des signatures atypiques. Nous définissons donc un point inusuel comme un point extrême de $R_{\mathcal{C}}^+$ et ayant des points rejetés dans son voisinage \mathcal{V}_{f,N_2} dans $R_{\mathcal{C}}^-$ (3.14).

$$\hat{Y}_{f,N_2}^{i,\mathcal{C}} = \begin{cases} 0 & \text{si } \hat{Y}_{f,N_2}^{i+} = 0 \\ 0 & \text{si } \hat{Y}_{f,N_2}^{i+} = 1 \text{ \& } \sum_{k \in \mathcal{V}_{f,N_2}} \hat{Y}_k^{i-} < n_{voisins} \\ 1 & \text{si } \hat{Y}_{f,N_2}^{i+} = 1 \text{ \& } \sum_{k \in \mathcal{V}_{f,N_2}} \hat{Y}_k^{i-} \geq n_{voisins} \end{cases} \quad (3.14)$$

3.6.3 Calibration des paramètres des modèles sur Ω_{Val}

La base de données annotées ponctuellement

La méthode développée dans cette section permet la détection ponctuelle des vibrations inusuelles présentes sur le spectrogramme. Afin de calibrer les différents paramètres des méthodes, il est indispensable de posséder une annotation ponctuelle des patchs. La base \mathcal{B}_1 présentée dans le chapitre 1 contient les données d'un patch spécifique j^* dont certains points ont été annotés et classifiés dans l'une des 4 classes :

- classe "normal" : le point fait partie d'une signature normale liée au N_2
- classe "inusuel" : le point fait partie d'une signature inusuelle

- classe "bruit" : bruit du spectrogramme, le point ne fait partie d'aucune raie
- classe "décalé" : le point fait partie d'une signature normale liée au N_1 , cette dernière est décalée sur les différents spectrogrammes.

Seuls les points de la classe "inusuel" sont à détecter.

La base \mathcal{B}_1 a été subdivisée en 2 groupes, le premier de validation Ω_{Val} afin de calibrer les paramètres du modèle et le second de test Ω_{Test} pour la présentation des résultats. Nous possédons donc des annotations de quelques points pour chacun de ces sous-ensembles de données. Etant donné que les points annotés ne concernent qu'un seul patch du spectrogramme, et par manque d'annotations ponctuelles sur les autres patchs, les paramètres calibrés à partir de la base Ω_{Val} sont reportés sur les autres patchs.

Les paramètres à définir sont le nombre de points maximaux n_{max} à prendre en compte pour estimer la distribution des valeurs extrêmes dans un cas et les niveaux s_+ et s_- des tests statistiques d'adéquation dans un second cas. Le nombre de voisins $n_{voisins}$ à prendre en considération pour le filtrage à partir des résidus négatifs est à déterminer dans les 2 cas.

Calibration des paramètres des tests d'adéquation

Afin de paramétriser le seuil de détection sur les p-valeurs des tests statistiques, nous calculons, pour chaque classe de points annotés, le taux de détection dans la base de validation Ω_{Val} pour différentes valeurs de seuil s comprises entre de 0 à 1 (Figure 3.13). Le taux de détection des points inusuels est élevé pour de petites valeurs de seuils tandis que les taux des points normaux et du bruit sont faibles pour ces mêmes valeurs. Cependant, les points décalés sont aussi fortement détectés. Cela provient de la mauvaise caractérisation par le modèle de normalité des raies se décalant dans l'espace et de forte intensité. La figure 3.13 permet de voir qu'il est beaucoup plus pertinent de prendre un seuil de p-valeurs faible car les fausses détections augmentent rapidement avec la valeur du seuil. Cependant un seuil trop faible réduit le taux de bonne détection. Etant donné que nous ne disposons pas de points annotés au niveau des résidus négatifs, nous appliquons la même valeur de seuil pour ces derniers. Nous avons donc opté pour

$$s_+ = 0.1 \quad s_- = 0.1$$

qui permet un taux de bonnes détections d'environ 86% et 74% de fausses détections des points décalés dans la base de validation Ω_{Val} .

Pour déterminer le nombre de voisins $n_{voisins}$ dans les résidus négatifs devant être détectés dans (3.14), nous effectuons une approche similaire à la précédente en calculant le taux de détection des différentes classes en supposant cette fois-ci le seuil fixé et en faisant varier le nombre de voisins (Figure 3.14). Les détections visuelles sur différents patchs en fonction du nombre de voisins complètent la calibration (Figure 3.15) et apportent une vérification visuelle des résultats. Nous considérons un voisinage \mathcal{V}_{f,N_2} de rayon 3 au niveau des résidus négatifs. Le

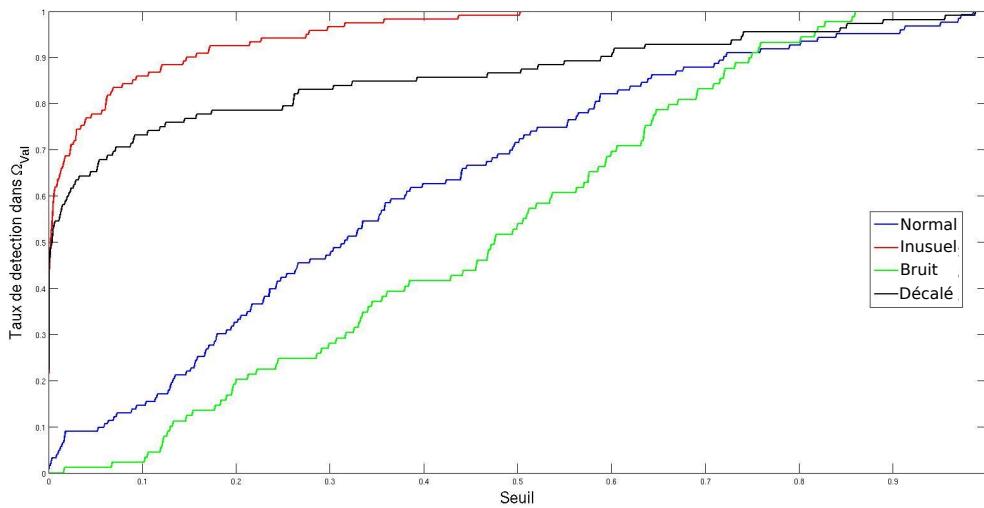


FIGURE 3.13 – Taux de détection des différentes classes de points dans Ω_{Val} en fonction du seuil sur les p-valeurs des tests d'adéquation. Les points inusuels (rouge) sont fortement détectés pour de petites valeurs de seuils, c'est également le cas pour les points normaux décalés (rouge). Pour ces mêmes valeurs, les points normaux (bleu) et le bruit (vert) sont faiblement détectés.

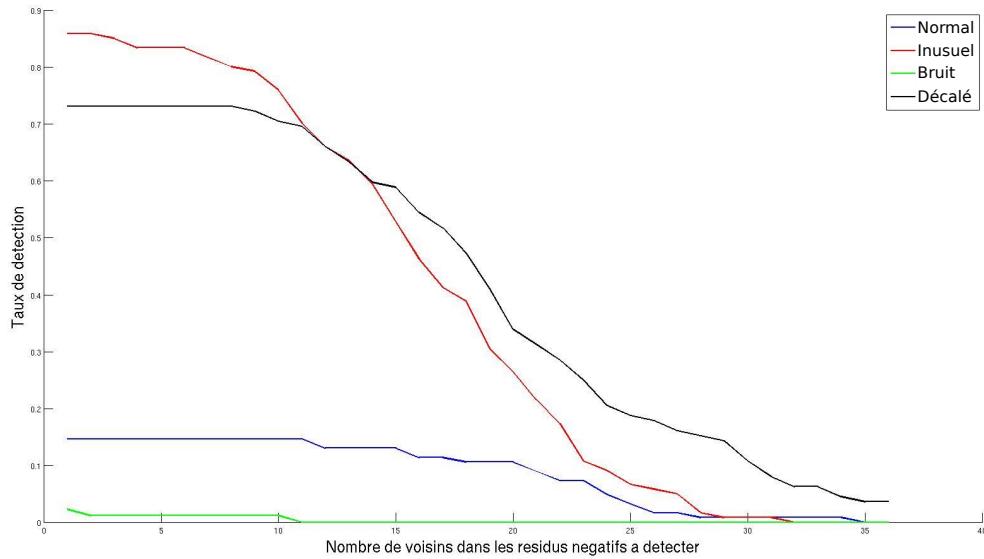


FIGURE 3.14 – Taux de détection des différentes classes de points dans Ω_{Val} à partir du seuil sur les p-valeurs en fonction du nombre de voisins devant être détectés dans les résidus négatifs. L'augmentation du nombre de voisins dans les résidus négatifs diminue les taux de détection. Afin d'obtenir de bons taux de détection des points atypiques, le nombre de points voisins devant être considérés dans les résidus négatifs doit être inférieur à 10.

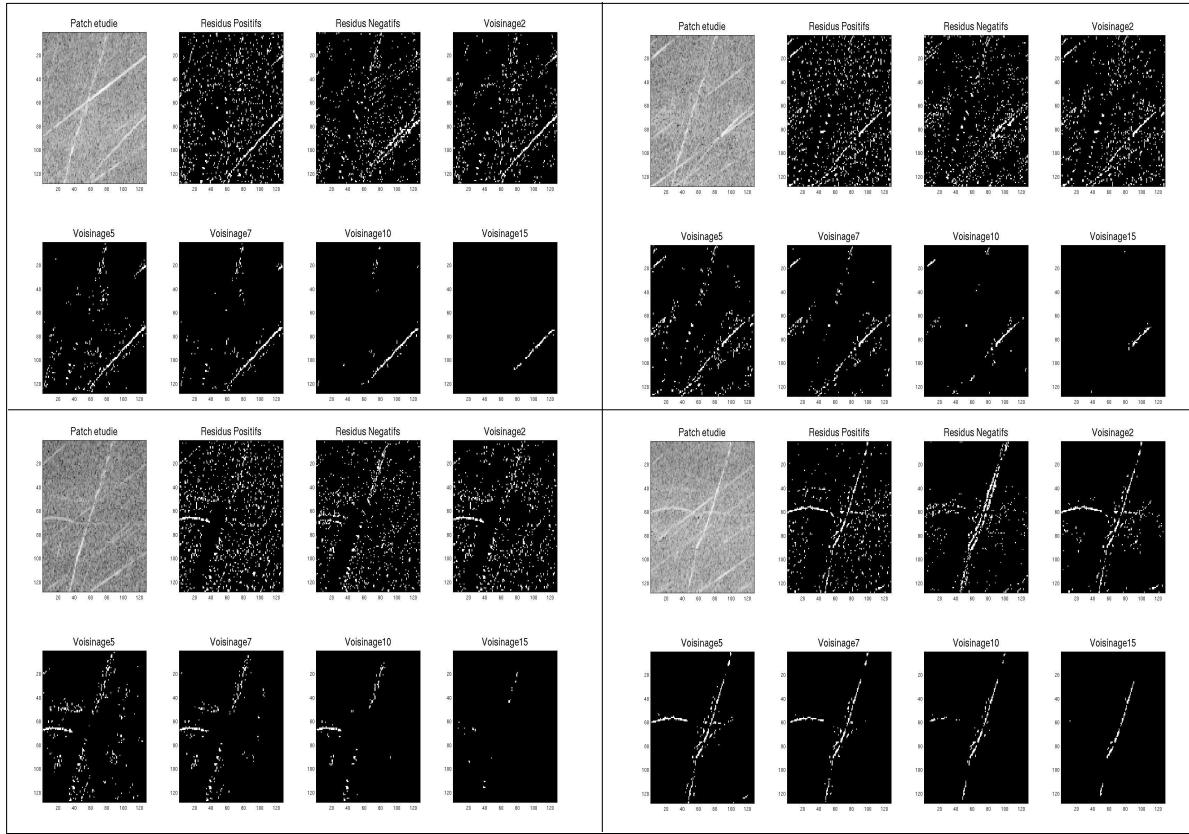


FIGURE 3.15 – Détection des points inusuels à partir du seuil sur les p-valeurs de 4 patchs contenant des signatures inusuelles, chaque sous-image correspond au résultats d'un patch. Chacune représentant le patch étudié, les points détectés par les résidus positifs et négatifs, et la détection en tenant compte du voisinage dans les résidus négatifs pour différents nombres de voisins. En considérant un nombre trop important de voisins les signatures atypiques ne sont pas détectées.

taux de détection se dégrade en augmentant le nombre de points voisins devant être détectés dans les résidus négatifs. Ce processus caractérise une exigence plus forte pour classifier un point comme inusuel. La figure 3.15 présente les détections sur 4 patchs différents contenant des signatures atypiques en fonction du nombre de voisins. La figure est divisée en 4 sous-figures, chacune contenant le patch étudié, les points détectés à partir des résidus positifs et négatifs, ainsi que la détection en filtrant la détection des résidus positifs par les détections de voisins dans les résidus négatifs. L'utilisation des résidus négatifs permet de réduire les fausses détections. Cependant une exigence trop forte du nombre de voisins entraîne également la non-détection des points inusuels (Figure 3.14). Il s'agit donc de définir un nombre de voisins limitant les fausses détections tout en conservant la détection des points inusuels

$$n_{voisins} = 7.$$

Calibration des paramètres des valeurs extrêmes

De manière analogue, nous estimons le nombre de résidus maximaux n_{max} à prendre en compte pour définir la distribution des valeurs extrêmes définies par une loi de Gumbel (la loi

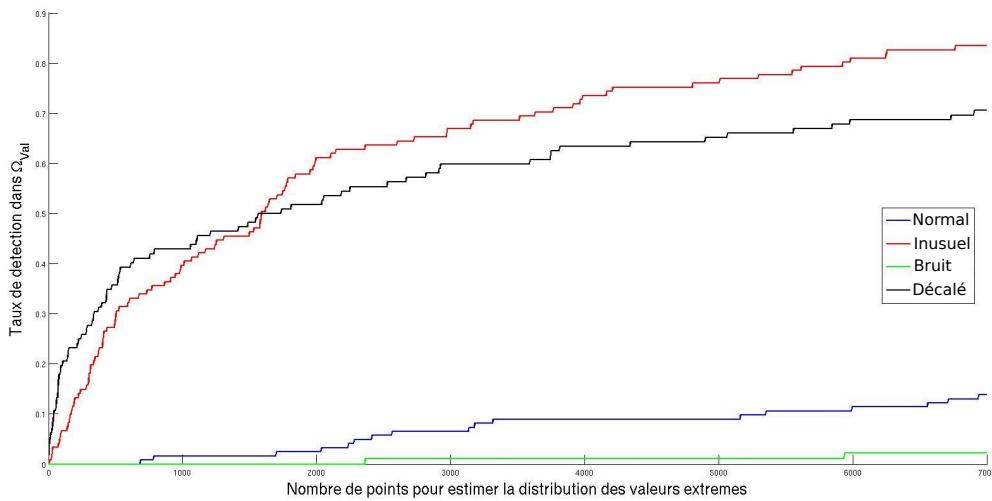


FIGURE 3.16 – Taux de détection des différentes classes de points dans Ω_{Val} en fonction du nombre de points n_{max} utilisé pour modéliser la distribution des valeurs extrêmes. Les taux de détection des points inusuels (rouge) et des points décalés (noir) augmentent fortement avec le nombre de points considérés pour estimer la distribution des extrêmes. Les taux de détection des points normaux (bleu) et du bruit (vert) augmentent également avec une pente beaucoup plus faible, les points normaux et le bruit sont faiblement détectés. Tenir compte d'un grand nombre de points pour estimer la distribution des valeurs extrêmes permet une bonne détection des points atypiques tout en limitant les fausses détections liées aux points normaux et au bruit.

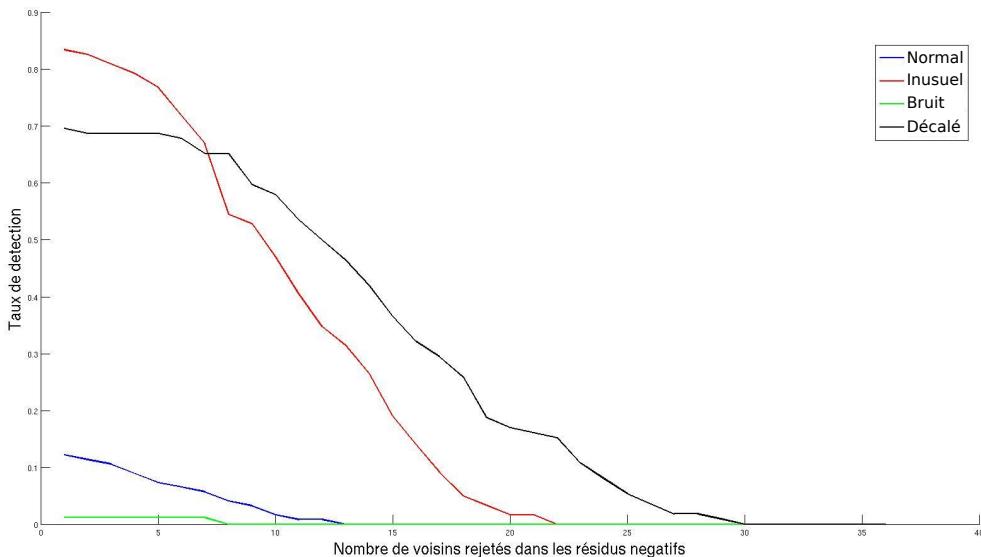


FIGURE 3.17 – Taux de détection des différentes classes de points dans Ω_{Val} à partir du seuil défini sur la distribution extrême en fonction du nombre de voisins devant être détectés dans les résidus négatifs. La prise en compte d'un nombre trop important de voisins au sein des résidus négatifs dégradent fortement la détection et permet également de réduire les fausses détections. Il est donc pertinent de limiter le nombre de voisins considérés.

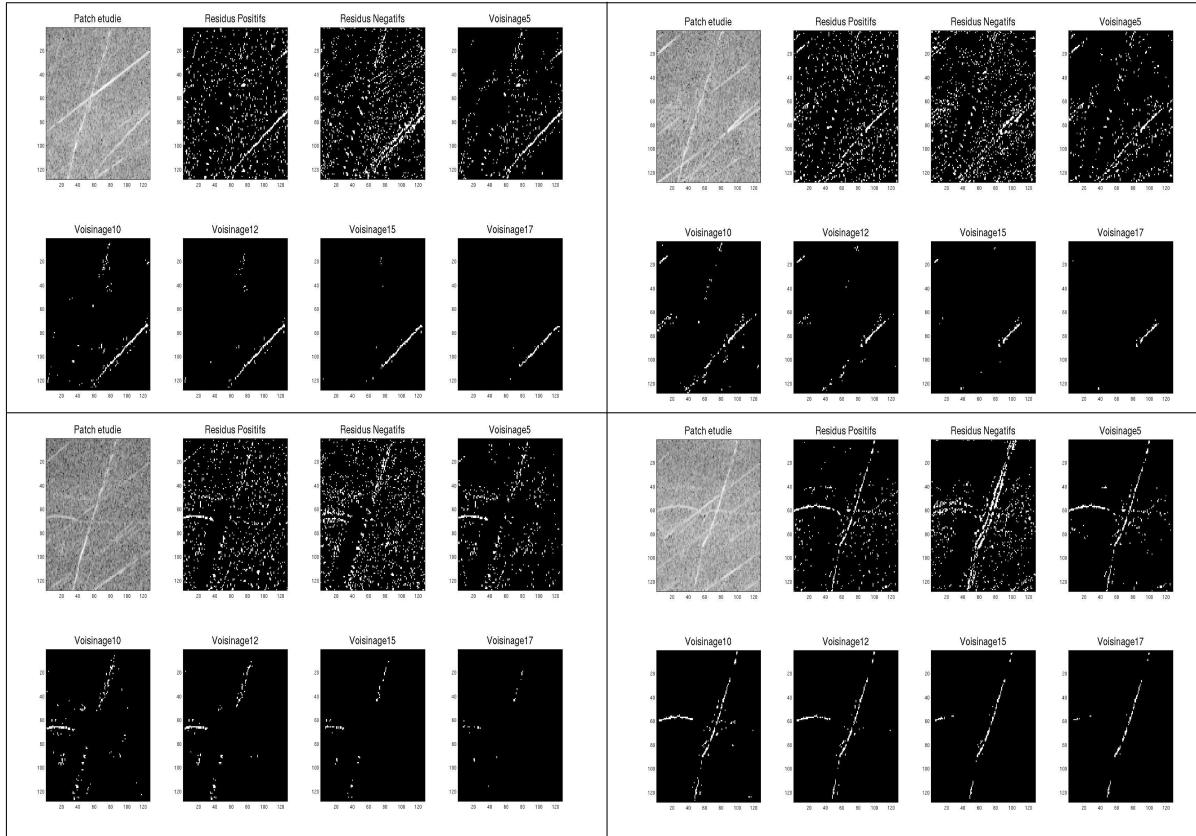


FIGURE 3.18 – Détection des points inusuels à partir du seuil défini sur la distribution extrême de 4 patchs contenant des signatures inusuelles, chaque sous-image correspond au résultats d'un patch. Chacune représentant le patch étudié, les points détectés par les résidus positifs et négatifs, et la détection en tenant compte du voisinage dans les résidus négatifs pour différents nombres de voisins.

gaussienne appartient au domaine d'attraction de Gumbel). Nous calculons donc les taux de détection des points des différentes classes de la base de validation \mathcal{B}_1 (Figure 3.16). Les taux de détection augmentent avec le nombre de points maximaux considérés pour estimer la distribution extrême car le mode de la distribution diminue en ajoutant des points pour l'estimation. Les nouveaux points ajoutés pour l'estimation sont toujours inférieurs, ils font reculer le mode et donc diminuer le seuil de détection. Le taux de détection des points inusuels et décalés augmentent bien plus rapidement avec le nombre de points considérés que les 2 autres classes. Cela montre la capacité du modèle à détecter principalement les points atypiques et ceux décalés spatialement sur les différents patchs. Nous choisissons comme nombre de points pour estimer la distribution des valeurs extrêmes

$$n_{max} = 6765.$$

Nous utilisons la même valeur pour estimer la distribution des valeurs extrêmes des résidus négatifs.

Le nombre de points voisins à considérer dans les résidus négatifs est calibré par les taux de détection des différentes classes en fonction du nombre de voisins (Figure 3.17) ainsi que par une représentation visuelle de la détection sur différents patchs pour différents nombres de voisins

à détecter (Figure 3.18). Comme précédemment les taux de détection diminuent en haussant l'exigence sur les résidus négatifs. Nous avons opté pour

$$n_{voisins} = 5.$$

3.6.4 Résultats sur la base de test Ω_{Test}

Nous présentons les résultats sous 3 formats sur les données de Ω_{Test} :

- par le calcul des taux de détection pour chaque classe de points annotés à partir des différentes approches de définition de seuil,
- par le calcul pour tous les patchs du spectrogramme du pourcentage de points détectés faisant partie d'une zone atypique extraite pour les patchs contenant des signatures inusuelles et le pourcentage de points détectés pour les patchs ne contenant pas de signatures inusuelles,
- par une représentation visuelle des points détectés sur les patchs à partir des résidus positifs, des résidus négatifs et du filtrage du premier par rapport au second.

Les paramètres des modèles correspondent à ceux calibrés sur Ω_{Val} .

Résultats des points annotés de Ω_{Test}

Les taux de détection des différentes classes de points de Ω_{Test} sont déterminés pour différentes données d'apprentissage permettant la définition du support des atomes de curvelets (Tableau 3.2). Le modèle proposé permet une bonne détection des points annotés comme inusuels. Cependant les points issus de raies vibratoires normales décalées spatialement sont également fortement détectés à tort. Les points normaux et le bruit sont très faiblement détectés. La définition du seuil à partir de la distribution des extrêmes donnent une légèrement meilleure classification des points atypiques. Les deux méthodes donnent des résultats très proches.

TABLE 3.2 – Taux de détection à partir du modèle défini par les curvelets des différentes classes de points de la base de test Ω_{Test} pour différentes données d'apprentissage

Classe de points	P-valeurs sur les résidus	Valeurs extrêmes sur les résidus
Classe "normal"	$4.1\% \pm 1.4\%$	$3.59\% \pm 3.44\%$
Classe "inusual"	$60\% \pm 1\%$	$66.98\% \pm 1.95\%$
Classe "noise"	0%	0%
Classe "shifted"	$68.21\% \pm 1.4\%$	$60\% \pm 3.44\%$

Résultats de détection sur l'ensemble des patchs \mathcal{K}_j^{128} des spectrogrammes

La méthode d'extraction permet des récupérer de zones atypiques contenant les signatures inusuelles, mais également de nombreux points normaux. Ainsi classifier tous les points de la zone comme inusuels et définir un critère d'erreur comparant la décision de l'algorithme à la vérité

terrain définie par l'extraction n'est pas pertinent. Nous définissons un critère d'erreur différent E_j^i (3.15) selon que la donnée test du patch étudié contient des zones atypiques annotées dans la base ou n'en contient pas. Dans le cas où l'intersection entre le patch test et les zones atypiques extraites de cette même donnée est non vide ($Y_{\mathcal{K}_j}^i = 1$), nous calculons la proportion des points détectés se trouvant dans les zones atypiques, ainsi la proportion inverse concerne uniquement les fausses détections. Dans le cas contraire ($Y_{\mathcal{K}_j}^i = 0$), nous calculons la proportion de points détectés par rapport à la dimension du patch.

$$E_j^i = \begin{cases} \frac{\text{card} \left\{ (f, N_2) : \hat{Y}_{f, N_2}^{i, C} = 1 \& \exists k | (f, N_2) \in \text{zone}_{ano}^i(k) \right\}}{\text{card} \left\{ (f, N_2) : \hat{Y}_{f, N_2}^{i, C} = 1 \right\}} & \text{si } Y_{\mathcal{K}_j}^i = 1 \\ \frac{\text{card} \left\{ (f, N_2) : \hat{Y}_{f, N_2}^{i, C} = 1 \right\}}{\text{card} \left\{ Z_{\mathcal{K}_j^{128}}^i \right\}} & \text{si } Y_{\mathcal{K}_j}^i = 0 \end{cases} \quad (3.15)$$

Ces résultats de détection (3.15) sont présentés dans le tableau 3.4 décomposé en plusieurs sous-tableaux sous le format défini dans le tableau 3.3. Chacun des sous-tableaux correspond à un des patchs de la subdivision des spectrogrammes. Les résultats ont été établis à partir de tous les moteurs de la base de test Ω_{Test} , nous mettons NA pour les patchs dans lesquels aucun moteur de la base de test ne possède de signature inusuelle. Le taux de points détectés par rapport au nombre de points pour les patchs sans signature atypique est très faible (autour de 2%). Les résultats sont beaucoup plus variés sur les patchs contenant des signatures inusuelles. Pour certains d'entre eux, la majorité des points détectés font partie des zones atypiques extraites proposant donc de bons résultats sur ces patchs, tandis que sur d'autres patchs, la proportion de points détectés appartenant aux zones atypiques est très faible. Cela peut provenir de la méthode d'extraction des zones atypiques récupérant une grande quantité d'information normale. Les résultats des deux approches de définition de seuil sont très proches.

TABLE 3.3 – Structure des sous-tableaux de résultats pour le modèle défini par le dictionnaire des curvelets

Taux de bonnes détection à partir du seuil sur les p-valeurs pour les patchs contenant des signatures inusuelles	Taux de points détectés à partir du seuil sur les p-valeurs pour les patchs sans signatures inusuelles
Taux de bonnes détection à partir de l'approche des valeurs extrêmes pour les patchs contenant des signatures inusuelles	Taux de points détectés à partir de l'approche des valeurs extrêmes pour les patchs sans signatures inusuelles

Visualisation des points rejetés sur la base de test Ω_{Test}

Nous présentons sur la figure 3.19 les résultats de détection sur les différents patchs de la base de test Ω_{Test} présentés dans le chapitre précédent (figure 2.3), ainsi que les résultats intermédiaires de détection à partir des résidus positifs et négatifs. Nous représentons les résultats pour un patch normal (1ère ligne) et pour 4 patchs contenant chacun des signatures atypiques

TABLE 3.4 – Taux de détection sur l'ensemble des patchs de la base de test à partir du modèle de normalité défini à partir des curvelets

<i>NA</i>	3.31% ± 0.02%	<i>NA</i>	3.66% ± 0.02%	0.9% ± 0.1%	3.58% ± 0.01%
<i>NA</i>	1.94% ± 0.01%	<i>NA</i>	2.50% ± 0.04%	0.4% ± 0.1%	2.57% ± 0.01%
<i>NA</i>	2.91% ± 0.02%	<i>NA</i>	2.95% ± 0.02%	84.3% ± 0.4%	2.56% ± 0.01
<i>NA</i>	1.33% ± 0.01%	<i>NA</i>	1.84% ± 0.01%	86.6% ± 1.4%	1.57% ± 0.02%
23.3% ± 0.3%	3.56% ± 0.03%	4.11% ± 0.2%	3.01% ± 0.03%	56.1% ± 0.6%	3.12% ± 0.01%
20.0% ± 0.3%	1.48% ± 0.01%	2.1% ± 1%	1.99% ± 0.03%	50.1% ± 1.1%	2.24% ± 0.02%
61.4% ± 0.1%	3.88% ± 0.03%	39.1% ± 0.3%	2.89% ± 0.02%	46.6% ± 0.4%	2.83% ± 0.01%
65.4% ± 0.6%	1.85% ± 0.02%	38.9% ± 0.9%	1.98% ± 0.02%	47.6% ± 0.9%	1.77% ± 0.01%
29.1% ± 0.3%	3.95% ± 0.03%	31.1% ± 0%	2.76% ± 0.04%	40.2% ± 0.6%	1.80% ± 0.01
30.9% ± 0.7%	1.74% ± 0.03%	30.1% ± 0.2%	1.72% ± 0.02%	40.0% ± 0.3%	1.23% ± 0.02%
56% ± 0.3%	4.24% ± 0.01%	51.1% ± 0.3%	3.08% ± 0.02%	81.6% ± 0.2%	1.48% ± 0.04%
56.7% ± 0.7%	1.62% ± 0.02%	53.7% ± 0.4%	1.81% ± 0.05%	81.9% ± 0.2%	1.06% ± 0.03%
53.7% ± 0.2%	3.85% ± 0.01%	45.4% ± 0%	2.88% ± 0.01%	59.5% ± 0.3%	2.49% ± 0.02%
52.8% ± 0.6%	1.32% ± 0.02%	46.2% ± 0.5%	1.89% ± 0.02%	61.5% ± 0.2%	1.61% ± 0.04%
19.4% ± 0.7%	4.06% ± 0.01%	46.9% ± 0.5%	2.62% ± 0.01%	59.8% ± 0%	2.67% ± 0.02%
21.2% ± 1.2%	1.75% ± 0.03%	50.8% ± 0.8%	1.62% ± 0.01%	62.3% ± 0.5%	1.60% ± 0%
3.2% ± 0.4%	4.30% ± 0.03%	18.4% ± 0.4%	3.19% ± 0%	39.7% ± 0.4%	2.74% ± 0.01%
3.4% ± 0.3%	1.82% ± 0.02%	15.2% ± 0.1%	2.07% ± 0.02%	37.7% ± 1%	1.79% ± 0.01%
<i>NA</i>	4.23% ± 0%	<i>NA</i>	3.21% ± 0%	19.4% ± 1.1%	2.42% ± 0.01%
<i>NA</i>	1.82% ± 0.02%	<i>NA</i>	2.00% ± 0.01%	17.2 ± 1.7%	1.79% ± 0.01%
23.7% ± 0.7%	3.80% ± 0%	<i>NA</i>	2.91% ± 0.02%	31.3% ± 0.8%	2.04% ± 0%
36.6% ± 1.3%	1.45% ± 0.01%	<i>NA</i>	1.73% ± 0.04%	29.4% ± 0.7%	1.47% ± 0.02%
4.8% ± 0.4%	3.86% ± 0.02%	2.9% ± 0.8%	2.10% ± 0.01%	9.2% ± 0.3%	1.88% ± 0.03%
0.4% ± 0.3%	1.76% ± 0.02%	3.0% ± 1.4%	1.60% ± 0.01%	9.5% ± 0.4%	1.30% ± 0.01%
5.5% ± 0.2%	3.81% ± 0.02%	19.7% ± 0.4%	2.08% ± 0.02%	16% ± 1.2%	1.91% ± 0.01%
7.8% ± 0.4%	1.22% ± 0.02%	18.3% ± 1.2%	1.45% ± 0.04%	24% ± 1.5%	1.37% ± 0.04%
<i>NA</i>	3.71% ± 0.03%	0.5% ± 0.1%	2.37% ± 0.01%	71.2% ± 0.6%	2.22% ± 0%
<i>NA</i>	1.11% ± 0.01%	0%	1.54% ± 0.01%	61.3% ± 2.2%	1.47% ± 0.01%
<i>NA</i>	3.74% ± 0.02%	56% ± 0.5%	2.36% ± 0.03%	56.1% ± 0.4%	2.34% ± 0.01%
<i>NA</i>	1.41% ± 0.01%	57.5% ± 0.3%	1.54% ± 0.02%	57.8% ± 0.3%	1.68% ± 0.01%
16.2% ± 1%	4.01% ± 0.03%	46.8% ± 0.8%	2.41% ± 0.03%	53.5% ± 0.3%	1.76% ± 0.03%
11.2% ± 2.3%	1.35% ± 0.01%	48.7% ± 1.5%	1.53% ± 0.02%	51.9% ± 0.4%	1.37% ± 0.01%
87.9% ± 0.6%	3.81% ± 0.01%	47% + 1.3%	2.48% ± 0.03%	15.6% ± 0.9%	1.49% ± 0.03%
95.1% ± 1.9%	1.50% ± 0	50.6% ± 2.2%	1.45% ± 0.01%	16.0% ± 0.2%	1.22% ± 0.03%
33.3% ± 0.9%	3.32% ± 0.01%	1.6% ± 0.4%	2.46% ± 0%	31.2% ± 0%	1.60% ± 0.01%
38.0% ± 0.7%	1.47% ± 0.02%	0.5% ± 0.5%	1.48% ± 0.02%	28.7% ± 4.7%	1.30% ± 0.02%

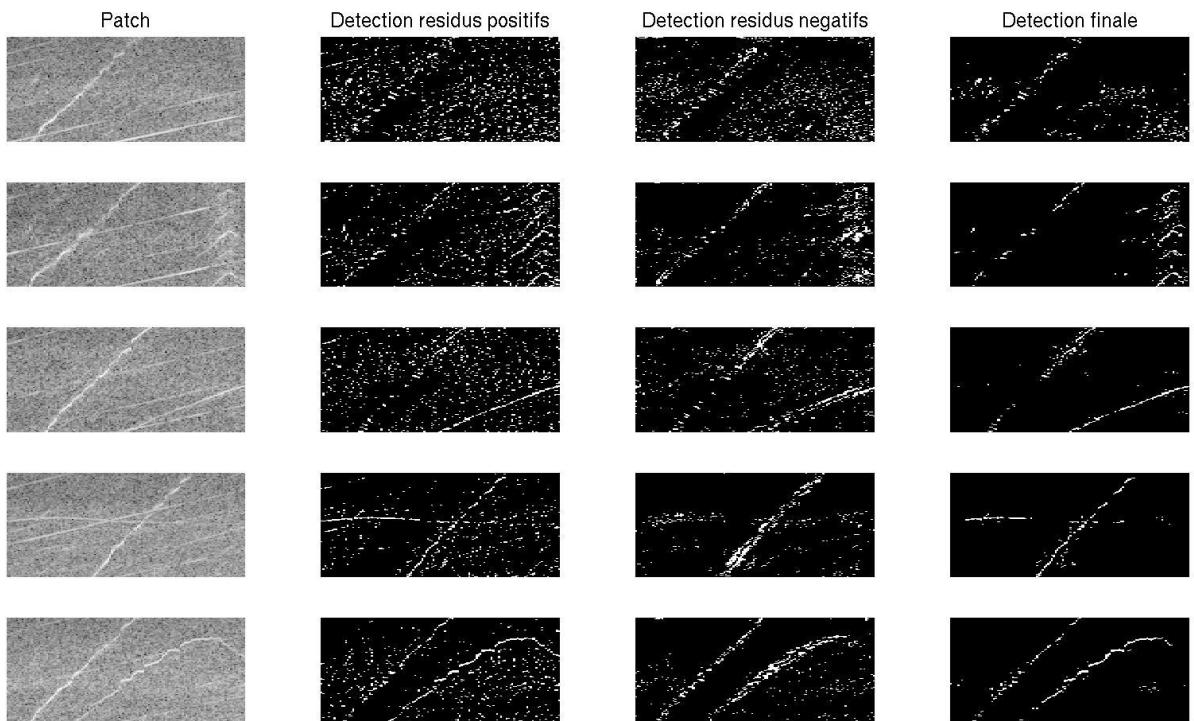


FIGURE 3.19 – Détection des points inusuels sur différents patchs. Chaque ligne correspond à un patch, les points détectés à partir des résidus positifs, les points inusuels détectés à partir des résidus négatifs et les points inusuels détectés sur les résidus positifs avec filtrage par les résidus négatifs. La première ligne correspond à un patch normal, les autres sont des patchs contenant des signatures atypiques. Les signatures atypiques se trouvent dans la détection finale établie à partir des résidus positifs et des résidus négatifs.

différentes. L’impact des résidus négatifs est visible, les points détectés au niveau de ces résidus se trouvent bien autour des signatures inusuelles et de la raie N_1 . Le filtrage des détections sur les résidus positifs par les résidus négatifs permet bien d’éliminer de nombreuses fausses détections. Pour les patchs contenant les signatures inusuelles, nous voyons apparaître principalement les signatures inusuelles et la raie N_1 dans la détection finale. L’approche basée sur la définition d’un modèle de normalité à partir du dictionnaire des curvelets est donc pertinente pour la détection des signatures inusuelles sur les spectrogrammes. Pour le patch normal, nous détectons principalement la raie N_1 qui reste détectée du fait de son décalage sur les différents spectrogrammes. Cependant de nombreux points restent détectés en dehors de cette raie. Cela provient de la définition du seuil de détection, ce dernier est déterminé intra-patch comme un quantile de la distribution des résidus. La définition de ce seuil ne tient pas compte de la présence ou non de signatures inusuelles sur le patch et entraîne une détection automatique de plusieurs points, y compris lorsque le patch ne contient pas de signature inusuelle. La définition du modèle de normalité à partir du dictionnaire des curvelets avec les résidus de reconstruction pour détecter les signatures atypiques permettent la mise en évidence des signatures inusuelles sur les patchs.